

1. Regresión lineal multivariada desde máxima verosimilitud

En regresión lineal se busca modelar una variable continua Y a partir de variables de entrada X . Una forma natural de hacerlo es suponer que la salida observada está formada por una parte determinista, $\theta^T x$, más una fluctuación aleatoria.

Considere

$$\mathcal{D} = \{(x^{(i)}, y^{(i)})\}_{i=1}^m,$$

con

$$x^{(i)} = \begin{bmatrix} 1 \\ x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix}, \quad \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}.$$

Suponga que

$$y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)}, \quad \varepsilon^{(i)} \sim \mathcal{N}(0, \sigma^2).$$

La hipótesis gaussiana permite construir una distribución para Y y, a partir de ella, una función de verosimilitud para los datos observados.

1. Determine la distribución de

$$Y^{(i)} \mid X = x^{(i)}.$$

2. Escriba

$$p(y^{(i)} \mid x^{(i)}; \theta).$$

3. Suponiendo independencia entre observaciones, construya

$$L(\theta).$$

4. Obtenga

$$\ell(\theta) = \log L(\theta).$$

5. Identifique los términos que dependen de θ .

6. Muestre que maximizar $\ell(\theta)$ equivale a minimizar la suma de residuos cuadrados.

7. Obtenga una función de coste de la forma

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2.$$

8. Explique por qué $1/2$ y $1/m$ no cambian el minimizador.

2. Gradiente y descenso por gradiente

Una vez construida $J(\theta)$, el aprendizaje puede verse como un problema de optimización. El gradiente indica cómo cambia el coste cuando cambia cada parámetro, y permite construir una regla iterativa para encontrar valores de θ que reduzcan el error.

Parta de

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2.$$

1. Calcule

$$\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j}.$$

2. Use la regla de la cadena para hallar

$$\frac{\partial J}{\partial \theta_j}.$$

3. Escriba el resultado como suma sobre los m datos.

4. Construya

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}.$$

5. Escriba la actualización para

$$j = 0, 1, \dots, n.$$

6. Explique por qué los parámetros deben actualizarse simultáneamente.

3. Ecuación normal

Para regresión lineal también existe una solución analítica. La idea es escribir el coste en forma matricial e imponer directamente la condición de mínimo.

Defina

$$X = \begin{bmatrix} 1 & x_1^{(1)} & \cdots & x_n^{(1)} \\ 1 & x_1^{(2)} & \cdots & x_n^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & \cdots & x_n^{(m)} \end{bmatrix},$$

$$y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix}, \quad J(\theta) = \frac{1}{2m} (X\theta - y)^T (X\theta - y).$$

1. Expanda

$$(X\theta - y)^T (X\theta - y).$$

2. Calcule

$$\nabla_{\theta} J(\theta).$$

3. Imponga

$$\nabla_{\theta} J(\theta) = 0.$$

4. Obtenga

$$X^T X \theta = X^T y.$$

5. Si $X^T X$ es invertible, despeje θ .

6. Compare esta solución con descenso por gradiente:

- ¿cuál es iterativa?
- ¿cuál es analítica?
- ¿cuándo puede fallar la inversión?

4. Regresión logística desde la familia exponencial

En clasificación binaria, Y toma dos valores posibles. Por ello, la distribución Bernoulli proporciona un punto de partida natural. Al escribirla como miembro de la familia exponencial se obtiene una relación entre su parámetro natural y una función lineal de x .

Considere

$$p(y; \eta) = b(y) \exp [\eta T(y) - a(\eta)],$$

y para $Y \in \{0, 1\}$,

$$p(y; \phi) = \phi^y (1 - \phi)^{1-y}.$$

1. Reescriba Bernoulli usando una exponencial.
2. Identifique el parámetro natural η .
3. Muestre que

$$\eta = \log \frac{\phi}{1 - \phi}.$$

4. Despeje ϕ en función de η .

5. Si

$$\eta = \theta^T x,$$

obtenga

$$P_{\theta}(Y = 1 \mid X = x).$$

6. Defina esta cantidad como

$$h_{\theta}(x).$$

7. Obtenga

$$P_{\theta}(Y = 0 \mid X = x).$$

5. Likelihood y función de coste logística

Una vez obtenida $h_{\theta}(x)$, cada observación puede interpretarse probabilísticamente. Para $y = 1$, el modelo asigna probabilidad $h_{\theta}(x)$; para $y = 0$, asigna $1 - h_{\theta}(x)$. A partir de ambas posibilidades se construye una única expresión para la verosimilitud.

1. Escriba una expresión única para

$$p(y^{(i)} \mid x^{(i)}; \theta)$$

válida para $y^{(i)} = 0$ y $y^{(i)} = 1$.

2. Construya la verosimilitud para m observaciones.

3. Calcule la log-verosimilitud.

4. Cambie el signo y normalice por m para obtener $J(\theta)$.

5. Identifique la entropía cruzada binaria.

6. Calcule

$$\frac{\partial J}{\partial \theta_j}.$$

7. Escriba la regla de descenso por gradiente.

8. Compare este gradiente con el de regresión lineal.

Puede ser útil recordar que

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad \sigma'(z) = \sigma(z) (1 - \sigma(z)).$$

6. Regularización

Un buen ajuste sobre los datos de entrenamiento no garantiza necesariamente una buena generalización. Una forma de controlar modelos con parámetros grandes es añadir una penalización a la función de coste. Para regularización L_2 ,

$$\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2.$$

El parámetro λ controla cuánto pesa esta penalización frente al ajuste a los datos.

1. Escriba el coste regularizado para regresión lineal.

2. Calcule

$$\frac{\partial J}{\partial \theta_j}, \quad j \geq 1.$$

3. Escriba por separado el caso $j = 0$.

4. Construya la actualización para $j \geq 1$.

5. Reorganice hasta obtener

$$\theta_j := \theta_j \left(1 - \frac{\alpha \lambda}{m} \right) - \text{término de datos.}$$

6. Interprete el factor

$$1 - \frac{\alpha \lambda}{m}.$$

7. Escriba el coste regularizado para regresión logística.

8. Obtenga el gradiente correspondiente.

9. Explique por qué normalmente no se regulariza θ_0 .

Referencias

Ng, A. Y. *CS229 Lecture Notes: Supervised Learning*. Stanford University.

Murphy, K. P. (2022). *Probabilistic Machine Learning: An Introduction*. MIT Press.

Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.

Variable continua: Y
Variables de entrada: X

Parte determinista $\theta^T x^{(i)}$
Fluctuación aleatoria $\varepsilon^{(i)} \sim \mathcal{N}(0, \sigma^2)$

conjunto de datos

$$\mathcal{D} = \{ (x^{(i)}, y^{(i)}) \}_{i=1}^m$$

m es el número de observaciones

Sea $y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)}$

Hipotesis Gaussiana: La distribución condicional también es normal

$$Y^{(i)} | X = x^{(i)} \sim \mathcal{N}(\underbrace{\theta^T x^{(i)}}_{\mu}, \underbrace{\sigma^2}_{\sigma^2})$$

Se escribe la expresión de probabilidad para observar $y^{(i)}$ dado $x^{(i)}$ y θ es de forma gaussiana

$$p(y|x; \theta) = \mathcal{N}(y | \theta^T x^{(i)}, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right]$$

Verosimilitud por Naive Bayes (observaciones independientes)

$$L(\theta) \equiv p(Y|X; \theta) = \prod_{i=1}^m p(y^{(i)} | x^{(i)}; \theta)$$

$$= \prod_{i=1}^m \left[\frac{1}{\sqrt{2\pi}\sigma} \exp \left(-\frac{[y^{(i)} - \theta^T x^{(i)}]^2}{2\sigma^2} \right) \right]$$

$$\ell(\theta) \equiv \log L(\theta) = \sum_{i=1}^m \log \left[\frac{1}{\sqrt{2\pi}\sigma} \exp \left(-\frac{[y^{(i)} - \theta^T x^{(i)}]^2}{2\sigma^2} \right) \right]$$

$$= \sum_{i=1}^m \left[\log \left(\frac{1}{\sqrt{2\pi}\sigma} \right) - \frac{[y^{(i)} - \theta^T x^{(i)}]^2}{2\sigma^2} \right]$$

$$= \underbrace{-\frac{m}{2} \log(2\pi\sigma^2)}_{\text{Independiente de } \theta} - \underbrace{\frac{1}{2\sigma^2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2}_{\text{Depende de } \theta}$$

Estimador de máxima verosimilitud θ_{MLE}

$$\theta_{MLE} = \arg \max_{\theta} \left[\underbrace{-\frac{m}{2} \log(2\pi\sigma^2)}_{\text{Independiente de } \theta} - \frac{1}{2\sigma^2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2 \right]$$

se ignora por que no depende de θ

Se ignoran términos independientes y factores de escala $\frac{1}{\sigma^2} > 0$

$$\begin{aligned}\theta_{MLE} &= \arg \max_{\theta} \left[- \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2 \right] = \arg \min_{\theta} \left[+ \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2 \right] \\ &= \arg \min_{\theta} [RSS(\theta)]\end{aligned}$$

Debido al término negativo, maximizar $\ell(\theta)$ equivale a minimizar la suma de los residuos cuadrados bajo la suposición de Naive Bayes y de Gauss

$$\theta_{MLE} = \arg \min_{\theta} RSS(\theta)$$

Optimización por mínimos cuadrados

Los escalares $\frac{1}{2}$, m , σ^2 son escalares independientes de θ y siempre positivos, no afectan a un procedimiento de optimización

Sin embargo un (-1) cambia una maximización por una minimización

Regresión lineal multivariada, hipótesis de modelo

$$h_{\theta}(x^{(i)}) \equiv \theta^T x^{(i)} \Rightarrow (y^{(i)} - \theta^T x^{(i)})^2 = (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Para definir la función de coste estándar solo nos interesa preservar las condiciones de optimización de $\ell(\theta) = \log L(\theta)$ para θ

Ignoramos los términos independientes y tomamos las siguientes interpretaciones para los escalares

- Varianza $\sigma^2 \rightarrow 1$
- Factor de normalización $\frac{1}{m}$ para evitar que la magnitud de la función de coste crezca con el tamaño de la muestra se añade manualmente por conveniencia al trabajar con subconjuntos
- Factor $\frac{1}{2}$, añadido por conveniencia para simplificar el cálculo de gradientes de forma similar a la $E_K = \frac{1}{2m} \bar{p} \cdot \bar{p}$

$$J(\theta) \equiv \frac{1}{2m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}]^2, \quad h_{\theta}(x^{(i)}) \equiv \theta^T x^{(i)}$$

Los escalares añadidos a mano son independientes de θ

$\frac{1}{2m}$ es un hiperparámetro independiente de las condiciones de optimizaciones de $\ell(\theta)$ con una ventaja en futuros algoritmos.

Descenso de gradiente

Optimización de un potencial m -dimensional parte de la idea en física de encontrar los puntos de equilibrio teniendo en cuenta el teorema trabajo-energía. Es conceptualmente similar/equivalente a una partícula rodando por un hiper-paisaje de energía potencial hasta eventualmente llegar a un mínimo local o global.

Es posible agregar ruido estocástico para agilizar o evitar mínimos metaestables. Espacios de muchas dimensiones permiten encontrar muchos puntos de silla que evitan que el algoritmo se estanque.

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}]^2, \quad h_{\theta}(x^{(i)}) = \theta^T x^{(i)} = \sum_{k=0}^n \theta_k x_k^{(i)}$$

Para cualquier constante positiva $\{ \nabla_{\theta} J(\theta) = \nabla_{\theta} [cf(\theta) + b] = c \nabla_{\theta} f(\theta) = 0$
la función escalada $J(\theta) = cf(\theta) + b$ $\{ \nabla_{\theta} J(\theta) = 0 \iff \nabla_{\theta} f(\theta)$

$$h_{\theta}(x^{(i)}) = \sum_{k=0}^n \theta_k x_k^{(i)} = \theta_0 x_0^{(i)} + \theta_1 x_1^{(i)} + \dots + \theta_n x_n^{(i)}$$

donde n es el número de parámetros, no confundir con m

$$\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} = \frac{\partial}{\partial \theta_j} \left(\sum_{k=0}^n \theta_k x_k^{(i)} \right) = x_j^{(i)}$$

Caso especial $x_0^{(i)} = 1 \Rightarrow \frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_0} = 1$

$$\begin{aligned} \frac{\partial J(\theta)}{\partial \theta_j} &= \frac{1}{m} \sum_{i=1}^m \frac{\partial}{\partial \theta_j} \left[\frac{1}{2} (h_{\theta}(x^{(i)}) - y^{(i)})^2 \right] && \text{Aquí cobra sentido el factor } 1/2 \text{ de antes} \\ &= \frac{1}{m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}] \frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} \\ &= \frac{1}{m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}] x_j^{(i)} \end{aligned}$$

Regla de descenso por gradiente $\theta_j \mapsto \theta_j - \alpha \partial J(\theta) / \partial \theta_j$

$$\theta_j \mapsto \theta_j - \frac{\alpha}{m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}] x_j^{(i)} = \theta_j + \frac{\alpha}{m} \sum_{i=1}^m [y^{(i)} - h_{\theta}(x^{(i)})] x_j^{(i)}$$

Indica una operación iterativa en la que la nueva lista de parámetros $\theta_j^{(t+1)} \leftarrow \theta_j^{(t)}$ sustituye la anterior

Formato Vectorial

$$\theta \mapsto \theta - \alpha \nabla_{\theta} J(\theta) = \theta - \frac{\alpha}{m} X^T (X\theta - Y)$$

Para $j=0$ caso especial $x_0^{(i)} = 1$:

$$\theta_0 \mapsto \theta_0 - \frac{\alpha}{m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}] x_0^{(i)} = \theta_0 + \frac{\alpha}{m} \sum_{i=1}^m [y^{(i)} - h_{\theta}(x^{(i)})]$$

Por cada iteración se deben actualizar el conjunto completo de parámetros $\theta = [\theta_0, \theta_1]$, si no se actualizan en su totalidad por cada iteración, el algoritmo falla.

Las librerías modernas usan SIMD (Instrucción Única, Múltiples Datos) para procesar múltiples objetos vectoriales en un solo ciclo de reloj sin la necesidad de múltiples bucles for, por ejemplo

Ecuación Normal

$$X = \begin{bmatrix} 1 & x_1^{(1)} & \dots & x_n^{(1)} \\ 1 & x_1^{(2)} & \dots & x_n^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & \dots & x_n^{(m)} \end{bmatrix}, \quad Y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix}, \quad J(\theta) = \frac{(X\theta - Y)^T (X\theta - Y)}{2m}$$

$$\theta^T = [\theta_0 \quad \theta_1 \quad \dots \quad \theta_n]$$

$$(X\theta - Y)^T (X\theta - Y) = (\theta^T X^T - Y^T) (X\theta - Y)$$

$$= \theta^T X^T X \theta - \theta^T X^T Y - Y^T X \theta + Y^T Y$$

$$(\theta^T X^T Y)^T = Y^T X \theta : [1, m] [m, (n+1)] [(n+1), 1] = [1, m] [m, 1] = [1]$$

Luego es un escalar $(\theta^T X^T Y)^T = \theta^T X^T Y = Y^T X \theta$, entonces

$$J(\theta) = \frac{\theta^T X^T X \theta - 2\theta^T X^T Y + Y^T Y}{2m} = \frac{\theta^T X^T X \theta - 2Y^T X \theta + Y^T Y}{2m}$$

$$\nabla_{\theta} J(\theta) = \frac{1}{2m} \left[\nabla_{\theta} (\theta^T X^T X \theta) - 2 \nabla_{\theta} (\theta^T X^T Y) + \nabla_{\theta} (Y^T Y) \right] = \frac{2X^T X - 2X^T Y}{2m}$$

$$\begin{aligned} \nabla_{\theta} (\theta^T A \theta) &= (A + A^T) \theta \\ &= 2A\theta \end{aligned}$$

$$\begin{aligned} \nabla_{\theta} (\theta^T b) &= b \\ \nabla_{\theta} (b^T \theta) &= b \end{aligned}$$

$\nabla_{\theta} (Y^T Y) = 0$
(vector nulo)

Donde $\begin{cases} A = X^T X \\ b = X^T Y \end{cases} (X^T X)^T = X X^T$ es simétrica

$$\nabla_{\theta} J(\theta) = \frac{1}{m} X^T (X\theta - Y)$$

$$\nabla_{\theta} J(\theta) = \frac{1}{n} X^T (X\theta - Y) = 0$$

$$X^T (X\theta - Y) = 0 \Rightarrow X^T X \theta = X^T Y \Rightarrow A\theta = b$$

$A = X^T X$ es simétrica: $[(n+1), 1][1, (n+1)] = [(n+1), (n+1)]$

Supongamos que es invertible (no singular)

$$A^{-1} A \theta = A^{-1} b \Rightarrow \mathbb{I} \theta = A^{-1} b = (X^T X)^{-1} X^T Y$$

$$\hat{\theta} = X^+ Y, \text{ donde } \underline{X^+ \equiv (X^T X)^{-1} X^T}$$

$\hat{\theta}$: Vector de Parámetros
óptimo MLE

pseudoinversa izquierda de Moore-Penrose de X

Descenso de Gradiente es iterativa: $\theta \mapsto \theta - \alpha \nabla_{\theta} J(\theta)$

Ecuación Normal es analítica (forma cerrada): $\hat{\theta} = (X^T X)^{-1} X^T Y$

La matriz $A = X^T X$ no siempre es invertible, $A\theta = b$ es degenerado cuando no tiene rango completo: $\text{rank}(X) < n+1$

Esto se puede dar por:

- Hay menos datos que parámetros a estimar: $m < n+1$
- Existen características x linealmente dependientes o correlacionadas por ejemplo variables repetidas o combinaciones lineales

En estos casos, se utiliza regularización (L_2 /Ridge) sumando λI

O se calcula descomposición en valores singulares (SVD) con la pseudoinversa de pinv

$$J_{\text{Ridge}}(\theta) = \frac{1}{2m} [(X\theta - Y)^T (X\theta - Y) + \lambda (\|\theta\|_2)^2], \quad \|\theta\|_2 \equiv \sqrt{\sum_{j=1}^n (\theta_j)^2} = \theta^T \theta$$

$$\text{SVD: } A^+ \equiv V \Sigma^+ U^T, \quad \Sigma^+ = \text{diag}(\frac{1}{\sigma_1}, \frac{1}{\sigma_2}, \dots, \frac{1}{\sigma_r}, 0, \dots, 0)^T, \quad r = \text{rank}(A)$$

Ponde U y V son matrices ortogonales

$$\hat{\theta} = A^+ Y \text{ minimiza el error cuadrático residual } (\|A\theta - Y\|_2)^2$$

Regresión logística

En clasificación binaria Y es un vector booleano (dos valores posibles)

Se usa la Distribución Bernoulli, se usa una regresión logística de la familia de las exponenciales. $p(y; \eta)$ relaciona el parámetro η y una función lineal de x

$$p(y; \eta) = b(y) \exp[\eta^T c(y) - a(\eta)]$$

Para $Y \in \{0, 1\}$ vector booleano $\{\text{False}, \text{True}\}$

$$p(y; \phi) = \phi^y (1 - \phi)^{1-y}$$

$$\text{Log } p(y; \phi) = y \text{Log } \phi + (1-y) \text{Log } (1-\phi)$$

$$= y [\text{Log } \phi - \text{Log } (1-\phi)] + \text{Log } (1-\phi)$$

$$= y \text{Log} \left(\frac{\phi}{1-\phi} \right) - [-\text{Log } (1-\phi)]$$

$$\exp(\text{Log } p(y; \phi)) = \underbrace{1}_{b(y)=1} \cdot \exp \left[\underbrace{y}_{T(y)=y} \underbrace{\text{Log} \left(\frac{\phi}{1-\phi} \right)}_{\eta} - \underbrace{[-\text{Log } (1-\phi)]}_{a(\eta) = -\text{Log } (1-\phi)} \right]$$

$$\eta = \text{Log} \left(\frac{\phi}{1-\phi} \right) \Rightarrow \phi = \frac{1}{1+e^{-\eta}} = \frac{e^{\eta}}{1+e^{\eta}}$$

$$\Rightarrow 1-\phi = \frac{1+e^{\eta}}{1+e^{\eta}} - \frac{e^{\eta}}{1+e^{\eta}} = \frac{1}{1+e^{\eta}} = [1+e^{\eta}]^{-1} \quad \text{forma sigmoide}$$

$$a(\eta) = -\text{Log } (1-\phi) = -\text{Log}[(1+e^{\eta})^{-1}] = \text{Log}(1+e^{\eta})$$

$$p(y; \phi) = \exp \left[y \eta - \text{Log}(1+e^{\eta}) \right] = \frac{e^{y\eta}}{1+e^{\eta}}$$

Para $y=1$

Para $y=0$

$$p(y=1; \eta) = \frac{e^{\eta}}{1+e^{\eta}} = \frac{1}{1+e^{-\eta}} = \phi \quad \left| \quad p(y=0; \eta) = \frac{e^0}{1+e^{\eta}} = \frac{1}{1+e^{\eta}} = 1-\phi$$

Sea $\eta = \theta^T x$, $h_\theta(x) \equiv \phi$

$$P_\theta(Y=1|X=x) = \phi = \frac{1}{1+e^{-\theta^T x}} = [1 + \exp(-\theta^T x)]^{-1} = h_\theta(x)$$

$$P_\theta(Y=0|X=x) = 1-\phi = \frac{1}{1+e^{\theta^T x}} = [1 + \exp(+\theta^T x)]^{-1} = 1-h_\theta(x)$$

$h_\theta = P_\theta(Y=1|X=x)$, $1-h_\theta = P_\theta(Y=0|X=x)$

$$1 = \sum_{i=0}^1 P_\theta(Y=i|X=x) = P_\theta(Y=0|X=x) + P_\theta(Y=1|X=x)$$

Verosimilitud general Aprovechando que $y^{(i)} \in \{0,1\}$

$$\begin{aligned} P(y^{(i)}|x^{(i)}; \theta) &= [h_\theta(x^{(i)})]^{y^{(i)}} [1-h_\theta(x^{(i)})]^{1-y^{(i)}} \\ &= \left[\frac{1}{1+\exp(-\theta^T x)} \right]^{y^{(i)}} \left[\frac{1}{1+\exp(+\theta^T x)} \right]^{1-y^{(i)}} \end{aligned}$$

Para m observaciones, con la hipotesis Naive Bayes

$$L(\theta) = \prod_{i=0}^m P(y^{(i)}|x^{(i)}; \theta)$$

$$\log L(\theta) = \sum_{i=0}^m \log(P(y^{(i)}|x^{(i)}; \theta)) = \sum_{i=0}^m [y^{(i)} \log[h_\theta(x^{(i)})] + (1-y^{(i)}) \log[1-h_\theta(x^{(i)})]]$$

$$\ell(\theta) = \sum_{i=0}^m \left[y^{(i)} \log \left[\frac{h_\theta(x^{(i)})}{1-h_\theta(x^{(i)})} \right] + \log [1-h_\theta(x^{(i)})] \right]$$

$$J(\theta) \equiv -\frac{\ell(\theta)}{m} = -\frac{1}{m} \sum_{i=0}^m \left[y^{(i)} \underbrace{\log \left[\frac{\phi}{1-\phi} \right]}_{h=\theta^T x} + \log \underbrace{[1-\phi]}_{[1+e^\eta]^{-1}} \right]$$

$$J(\theta) = \frac{1}{m} \sum_{i=0}^m [y^{(i)} \theta^T x^{(i)} - \log [1 + \exp(\theta^T x)]]$$

Entropia cruzada binaria
tambien $f(\theta) = J(\theta)$

$$\frac{\partial}{\partial \theta_j} (y^{(i)} \theta^T x^{(i)}) = y^{(i)} x_j^{(i)}$$

$$\frac{\partial}{\partial \theta_j} \log [1 + e^{\theta^T x^{(i)}}] = \frac{1}{1 + \exp(\theta^T x^{(i)})} \frac{\partial}{\partial \theta_j} (1 + e^{\theta^T x^{(i)}}) = \frac{\exp(\theta^T x^{(i)})}{1 + \exp(\theta^T x^{(i)})} x_j^{(i)}$$

$$\frac{\partial}{\partial \theta_j} \log(1 + e^{\theta^T x^{(i)}}) = \frac{1}{1 + \exp(-\theta^T x^{(i)})} x_j^{(i)} = h_{\theta}(x^{(i)}) x_j^{(i)}$$

$$\frac{\partial}{\partial \theta_j} [y^{(i)} \theta^T x^{(i)} - \log(1 + \exp(\theta^T x^{(i)}))] = y^{(i)} x_j^{(i)} - h_{\theta} x_j^{(i)} = (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)}$$

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{\partial F(\theta)}{\partial \theta_j} = \frac{-1}{m} \sum_{i=1}^m (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

$$\underbrace{\nabla_{\theta} F(\theta)}_{[n+1, 1]} = \frac{1}{m} \underbrace{X^T}_{[n+1, m]} \underbrace{[h_{\theta}(X) - Y]}_{[m, 1]}$$

Descenso de gradiente para la cross-entropía binaria

$$0 = \nabla_{\theta} F(\theta) = \frac{1}{m} X^T [h_{\theta}(X) - Y]$$

$$X^T (X\theta^* - Y) = 0$$

$$\theta_j \mapsto \theta_j - \left(\frac{\alpha}{m}\right) \partial F(\theta) / \partial \theta_j \quad \text{o} \quad \theta \mapsto \theta - \frac{\alpha}{m} \nabla_{\theta} F(\theta) = \theta - \left(\frac{\alpha}{m}\right) X^T [h_{\theta}(X) - Y]$$

Aunque su objetivo de optimización es distinto al de una regresión lineal multivariada, sus expresiones de optimización son matemáticamente equivalentes, aunque el costo computacional puede variar dependiendo de cómo se definan los vectores en memoria

Regularización L_2

$$\left. \begin{array}{l} \text{Sumamos una penalización} \\ \text{con el hiperparámetro } \lambda \end{array} \right\} \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2 = \frac{\lambda}{2m} \theta^T \theta \quad \left| \begin{array}{l} \text{Excepto para} \\ j=0 \end{array} \right.$$

Para la Regresión lineal

$$J(\theta) = \frac{1}{2m} [(X\theta - Y)^T (X\theta - Y) + \lambda \theta^T \mathbb{I} \theta], \quad \mathbb{I} = \begin{bmatrix} 0 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}_{(n+1) \times (n+1)}$$

$$\text{Para } j=0: \theta_0 \mapsto \theta_0 - \left(\frac{\alpha}{m}\right) \sum (h_{\theta}(x^{(i)}) - y^{(i)}), \quad x_0^{(i)} = 1$$

$$\text{Para } j>0: \theta_j \mapsto \theta_j \left(1 - \frac{\alpha \lambda}{m}\right) - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

El factor $(1 - \alpha \frac{\lambda}{m})$ es llamado factor de decaimiento o contracción de pesos. Dado que $\alpha > 0$, $\lambda > 0$, $m > 0$, y Teniendo $0 < (1 - \alpha \frac{\lambda}{m}) < 1 \Leftrightarrow \alpha < \frac{m}{\lambda}$, como $m \gg 1$ y $\alpha \approx 0 \} \rightarrow \lambda \approx 1$

En cada iteración, antes de que el modelo aprenda del error de los datos Θ_j , para $j \geq 1$ se multiplica por una constante positiva menor que 1, lo que reduce el parámetro

Para Θ_0 este parámetro no aparece ya que este solo es el nivel base $x_0^{(i)} = 1$ es decir el intercepto

Regularización Regresión logística binaria

$$F(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(h_\theta(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)}))] + \frac{\lambda}{2m} \sum_{j=0}^n \theta_j^2$$

$$\nabla F = \frac{1}{m} X^T [h_\theta(X) - Y] + \frac{\lambda}{m} \theta^T \mathbb{I} \theta, \quad \mathbb{I} \begin{cases} i=j=0 : 0 \\ i=j \neq 0 : 1 \\ j \neq i : 0 \end{cases} \left| \begin{array}{l} \text{se excluye el} \\ \text{intercepto} \end{array} \right.$$

$$\theta_0 \mapsto \theta_0 - \left(\frac{\alpha}{m}\right) \sum_{i=1}^m [y^{(i)} \log(h_\theta(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)}))]$$

$$\theta_j \mapsto \theta_j (1 - \alpha \frac{\lambda}{m}) - \frac{\alpha}{m} \sum_{i=1}^m [y^{(i)} \log(h_\theta(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)}))]$$

Tanto en la regresión lineal como en la logística se suele excluir θ_0 de la regularización L_2 para que al aprendizaje no dependa del centro ponderado de las características del modelo, penalizar el aprendizaje en los demás parámetros y evitar sobreajustes e incluso subajustes con buenos hiperparámetros.

Con ayuda de NotebookLM / Gemini Notebook alimentado de la bibliografía indicada en el documento.