

1. Regresión lineal multivariada desde máxima verosimilitud

En regresión lineal se busca modelar una variable continua Y a partir de variables de entrada X . Una forma natural de hacerlo es suponer que la salida observada está formada por una parte determinista, $\theta^T x$, más una fluctuación aleatoria.

Considere

$$\mathcal{D} = \{(x^{(i)}, y^{(i)})\}_{i=1}^m,$$

con

$$x^{(i)} = \begin{bmatrix} 1 \\ x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix}, \quad \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}.$$

Suponga que

$$y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)}, \quad \varepsilon^{(i)} \sim \mathcal{N}(0, \sigma^2).$$

La hipótesis gaussiana permite construir una distribución para Y y, a partir de ella, una función de verosimilitud para los datos observados.

1. Determine la distribución de

$$Y^{(i)} \mid X = x^{(i)}.$$

2. Escriba

$$p(y^{(i)} \mid x^{(i)}; \theta).$$

3. Suponiendo independencia entre observaciones, construya

$$L(\theta).$$

4. Obtenga

$$\ell(\theta) = \log L(\theta).$$

5. Identifique los términos que dependen de θ .

6. Muestre que maximizar $\ell(\theta)$ equivale a minimizar la suma de residuos cuadrados.

7. Obtenga una función de coste de la forma

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2.$$

8. Explique por qué $1/2$ y $1/m$ no cambian el minimizador.

2. Gradiente y descenso por gradiente

Una vez construida $J(\theta)$, el aprendizaje puede verse como un problema de optimización. El gradiente indica cómo cambia el coste cuando cambia cada parámetro, y permite construir una regla iterativa para encontrar valores de θ que reduzcan el error.

Parta de

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2.$$

1. Calcule

$$\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j}.$$

2. Use la regla de la cadena para hallar

$$\frac{\partial J}{\partial \theta_j}.$$

3. Escriba el resultado como suma sobre los m datos.

4. Construya

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}.$$

5. Escriba la actualización para

$$j = 0, 1, \dots, n.$$

6. Explique por qué los parámetros deben actualizarse simultáneamente.

3. Ecuación normal

Para regresión lineal también existe una solución analítica. La idea es escribir el coste en forma matricial e imponer directamente la condición de mínimo.

Defina

$$X = \begin{bmatrix} 1 & x_1^{(1)} & \cdots & x_n^{(1)} \\ 1 & x_1^{(2)} & \cdots & x_n^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & \cdots & x_n^{(m)} \end{bmatrix},$$

$$y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix}, \quad J(\theta) = \frac{1}{2m} (X\theta - y)^T (X\theta - y).$$

1. Expanda

$$(X\theta - y)^T (X\theta - y).$$

2. Calcule

$$\nabla_{\theta} J(\theta).$$

3. Imponga

$$\nabla_{\theta} J(\theta) = 0.$$

4. Obtenga

$$X^T X \theta = X^T y.$$

5. Si $X^T X$ es invertible, despeje θ .

6. Compare esta solución con descenso por gradiente:

- ¿cuál es iterativa?
- ¿cuál es analítica?
- ¿cuándo puede fallar la inversión?

4. Regresión logística desde la familia exponencial

En clasificación binaria, Y toma dos valores posibles. Por ello, la distribución Bernoulli proporciona un punto de partida natural. Al escribirla como miembro de la familia exponencial se obtiene una relación entre su parámetro natural y una función lineal de x .

Considere

$$p(y; \eta) = b(y) \exp [\eta T(y) - a(\eta)],$$

y para $Y \in \{0, 1\}$,

$$p(y; \phi) = \phi^y (1 - \phi)^{1-y}.$$

1. Reescriba Bernoulli usando una exponencial.
2. Identifique el parámetro natural η .
3. Muestre que

$$\eta = \log \frac{\phi}{1 - \phi}.$$

4. Despeje ϕ en función de η .

5. Si

$$\eta = \theta^T x,$$

obtenga

$$P_{\theta}(Y = 1 \mid X = x).$$

6. Defina esta cantidad como

$$h_{\theta}(x).$$

7. Obtenga

$$P_{\theta}(Y = 0 \mid X = x).$$

5. Likelihood y función de coste logística

Una vez obtenida $h_{\theta}(x)$, cada observación puede interpretarse probabilísticamente. Para $y = 1$, el modelo asigna probabilidad $h_{\theta}(x)$; para $y = 0$, asigna $1 - h_{\theta}(x)$. A partir de ambas posibilidades se construye una única expresión para la verosimilitud.

1. Escriba una expresión única para

$$p(y^{(i)} \mid x^{(i)}; \theta)$$

válida para $y^{(i)} = 0$ y $y^{(i)} = 1$.

2. Construya la verosimilitud para m observaciones.

3. Calcule la log-verosimilitud.

4. Cambie el signo y normalice por m para obtener $J(\theta)$.

5. Identifique la entropía cruzada binaria.

6. Calcule

$$\frac{\partial J}{\partial \theta_j}.$$

7. Escriba la regla de descenso por gradiente.

8. Compare este gradiente con el de regresión lineal.

Puede ser útil recordar que

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad \sigma'(z) = \sigma(z) (1 - \sigma(z)).$$

6. Regularización

Un buen ajuste sobre los datos de entrenamiento no garantiza necesariamente una buena generalización. Una forma de controlar modelos con parámetros grandes es añadir una penalización a la función de coste. Para regularización L_2 ,

$$\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2.$$

El parámetro λ controla cuánto pesa esta penalización frente al ajuste a los datos.

1. Escriba el coste regularizado para regresión lineal.

2. Calcule

$$\frac{\partial J}{\partial \theta_j}, \quad j \geq 1.$$

3. Escriba por separado el caso $j = 0$.

4. Construya la actualización para $j \geq 1$.

5. Reorganice hasta obtener

$$\theta_j := \theta_j \left(1 - \frac{\alpha \lambda}{m} \right) - \text{término de datos.}$$

6. Interprete el factor

$$1 - \frac{\alpha \lambda}{m}.$$

7. Escriba el coste regularizado para regresión logística.

8. Obtenga el gradiente correspondiente.

9. Explique por qué normalmente no se regulariza θ_0 .

Referencias

Ng, A. Y. *CS229 Lecture Notes: Supervised Learning*. Stanford University.

Murphy, K. P. (2022). *Probabilistic Machine Learning: An Introduction*. MIT Press.

Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.

I. Regresión lineal multivariada desde máxima verosimilitud.

Sea $y^{(i)} = \theta^T x^{(i)} + \epsilon^{(i)}$ con $\epsilon^{(i)} \sim \mathcal{N}(0, \sigma^2)$

1-2 $\epsilon^{(i)} \sim \mathcal{N}(0, \sigma^2) \Rightarrow f_{\epsilon}(\epsilon^{(i)}) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(\epsilon^{(i)})^2}{2\sigma^2}}$

La probabilidad de encontrar $\epsilon^{(i)}$ entre $\epsilon^{(i)}$ y $\epsilon^{(i)} + d\epsilon^{(i)}$ es:

$$P = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(\epsilon^{(i)})^2}{2\sigma^2}} d\epsilon^{(i)}$$

Determinista $\Rightarrow$ constante.

Despejando: $\epsilon^{(i)} = y^{(i)} - \theta^T x^{(i)} \Rightarrow d\epsilon^{(i)} = dy^{(i)}$

$$P = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}} dy^{(i)} \Rightarrow f_{y^{(i)}|X=x^{(i)}}(y^{(i)}) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}}$$

$$\Rightarrow y^{(i)}|X=x^{(i)} \sim \mathcal{N}(\theta^T x^{(i)}, \sigma^2)$$

3 $L(\theta) = \prod_{i=1}^m P(y^{(i)}|x^{(i)}; \theta)$
 $= \prod_{i=1}^m \left[\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}} \right]$

$$L(\theta) = \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^m e^{-\frac{1}{2\sigma^2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2}$$

4-5 $l(\theta) = \log L(\theta)$
 $= \log \left[\left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^m e^{-\frac{1}{2\sigma^2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2} \right]$

$$l(\theta) = \underbrace{-\frac{m}{2} \log(2\pi\sigma^2)}_{\text{No depende de } \theta} - \underbrace{\frac{1}{2\sigma^2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2}_{\text{Depende de } \theta}$$

6 $\hat{\theta}_{MLE} = \arg \max_{\theta} l(\theta) = \arg \max_{\theta} \left[\underbrace{-\frac{m}{2} \log(2\pi\sigma^2)}_{\text{cte}} - \underbrace{\frac{1}{2\sigma^2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2}_{\text{cte positiva}} \right]$

$$\hat{\theta}_{MLE} = \arg \max_{\theta} \left[-\sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2 \right] \Rightarrow -\sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2 < 0$$

pero maximizar una función f definida negativa equivale a minimizar $-f$, definida positiva.

$$\Rightarrow \hat{\theta}_{MLE} = \arg \min_{\theta} \left[\sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2 \right], \text{ donde } \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2 > 0 \text{ es justamente}$$

la suma de residuos al cuadrado.

(7.8) Ya que hay que minimizar $\sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2$, se define $h_{\theta}(x^{(i)}) \equiv \theta^T x^{(i)} = \sum_{j=0}^n \theta_j x_j^{(i)}$.

la función de coste es $J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$, donde los factores $\frac{1}{m}$ y $\frac{1}{2}$

responden a la normalización y a una convención matemática, respectivamente.

Ya que $\frac{1}{2m}$ es una constante multiplicativa positiva, no cambia la posición ni la naturaleza de los extremos de la función, únicamente el valor de esta en dichos puntos, de modo que este factor no afecta la minimización.

I. Gradiente y descenso por gradiente.

(1) $h_{\theta}(x^{(i)}) = \sum_{k=0}^n \theta_k x_k^{(i)} \rightarrow \frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} = \sum_{k=0}^n x_k^{(i)} \frac{\partial \theta_k}{\partial \theta_j} \Rightarrow \frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} = x_j^{(i)}$

δ_{kj}
Pars. independientes.

(2) $\frac{\partial J}{\partial \theta_j} = \frac{\partial J}{\partial h_{\theta}(x^{(i)})} \frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j}$

$\frac{\partial}{\partial h_{\theta}(x^{(i)})} \left[\frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 \right] = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$

$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$

(4) $\theta_j := \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$

(5) Para $j=0$: $\theta_0 := \theta_0 - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$

Para $j=1, \dots, n$: $\theta_j := \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$

(6) Porque la función de coste depende de todos los parámetros, de modo que no actualizar los parámetros simultáneamente significaría que la trayectoria del gradiente descendente se está evaluando en "instantes" distintos para un parámetro u otro. Para que el método tenga sentido, todos los parámetros deben evaluarse en el mismo instante, esto es, deben actualizarse simultáneamente.

III. Ecuación normal.

(1) $(X^T X - Y^T Y)^T (X\theta - y) = (X^T X - Y^T Y)(X\theta - y) = X^T X^T X\theta - X^T X^T y - y^T X\theta + y^T y$

Matriz $m \times (n+1)$ Vector $(n+1) \times 1$ Vector $m \times 1$

$$\begin{aligned}
 \textcircled{2} \quad \nabla_{\theta} J(\theta) &= \frac{1}{2m} \nabla_{\theta} [\theta^T X^T X \theta - \theta^T X^T y - y^T X \theta + y^T y] \\
 &= \frac{\partial}{\partial \theta_i} [\theta_j X_{jk} X_{kl} \theta_l - \theta_j X_{jk} y_k - y_j X_{jk} \theta_k + y_j y_k] \\
 &= \delta_{ij} X_{jk} X_{kl} \theta_l + \theta_j X_{jk} X_{kl} \delta_{il} - \delta_{ij} X_{jk} y_k - y_j X_{jk} \delta_{ik} \\
 &= X_{ik} X_{kl} \theta_l + \theta_j X_{jk} X_{ki} - X_{ik} y_k - y_j X_{ji} \\
 &\quad \swarrow \text{simétrica.} \\
 &= X_{ik} X_{kl} \theta_l + X_{ik} X_{kj} \theta_j - X_{ik} y_k - X_{ij} y_j \\
 &= 2X_{ik} X_{kl} \theta_l - 2X_{ik} y_k
 \end{aligned}$$

$$\nabla_{\theta} J(\theta) = \frac{1}{m} (X^T X \theta - X^T y)$$

$$\textcircled{3-4} \quad \nabla_{\theta} J(\theta) = 0 \Rightarrow X^T X \theta = X^T y$$

$$\textcircled{5} \quad \text{si } X^T X \text{ es invertible} \Rightarrow \theta = (X^T X)^{-1} X^T y$$

- $\textcircled{6}$ • Iterativa: gradiente descendente.
 • Analítica: ecuación normal.
 • La inversión falla cuando $\det(X^T X) = 0$, lo cual ocurre cuando hay redundancia entre los datos, esto es, cuando las columnas y/o las filas no son L.I.

IV. Regresión logística desde la familia exponencial.

$$\begin{aligned}
 \textcircled{1} \quad \text{Bernoulli} &\rightarrow P(y; \phi) = \phi^y (1-\phi)^{1-y} \\
 P(y; \phi) &= e^{\log[\phi^y (1-\phi)^{1-y}]} = e^{[y \log \phi + \log(1-\phi) - y \log(1-\phi)]}
 \end{aligned}$$

$$P(y; \phi) = e^{[y \log \frac{\phi}{1-\phi} + \log(1-\phi)]}$$

$$\textcircled{2-3} \quad \text{Comparando con } P(y; \eta) = b(\eta) e^{[\eta^T T(y) - a(\eta)]}$$

$$\text{encontramos que } b(\eta) = 1, T(\eta) = y \text{ y } \eta = \log \frac{\phi}{1-\phi}$$

$$\textcircled{4} \quad \eta = \log \frac{\phi}{1-\phi} \Rightarrow \frac{\phi}{1-\phi} = e^{\eta} \Rightarrow \phi = e^{\eta} - \phi e^{\eta} \Rightarrow \phi(1+e^{\eta}) = e^{\eta}$$

$$\phi = \frac{e^{\eta}}{1+e^{\eta}} \Rightarrow \phi = \frac{1}{1+e^{-\eta}}$$

$$\textcircled{5} \quad \text{sea } \eta = \theta^T x \Rightarrow P(Y=1|X=x) = \phi = \frac{1}{1+e^{-\theta^T x}}$$

$$\textcircled{6} \quad h_{\theta}(x) = \frac{1}{1+e^{-\theta^T x}}$$

$$\textcircled{7} \quad P_{\theta}(Y=0|X=x) = 1-\phi = 1 - \frac{1}{1+e^{-\theta^T x}} = \frac{1+e^{-\theta^T x} - 1}{1+e^{-\theta^T x}} = \frac{1}{1+e^{\theta^T x}}$$

V. Likelihood y función de coste logística.

① $P(y^{(i)} | x^{(i)}; \theta) = \phi^y (1-\phi)^{1-y}$, pero $\phi = h_\theta(x^{(i)})$

$$P(y^{(i)} | x^{(i)}; \theta) = [h_\theta(x^{(i)})]^y [1 - h_\theta(x^{(i)})]^{1-y}$$

② Para m observaciones:

$$L(\theta) = \prod_{i=1}^m [h_\theta(x^{(i)})]^y [1 - h_\theta(x^{(i)})]^{1-y}$$

③ $\ell(\theta) = \log L(\theta) = \sum_{i=1}^m [y^{(i)} \log(h_\theta(x^{(i)})) + (1-y^{(i)}) \log(1 - h_\theta(x^{(i)}))]$

4-5 $J(\theta) = -\frac{1}{m} \ell(\theta)$

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(h_\theta(x^{(i)})) + (1-y^{(i)}) \log(1 - h_\theta(x^{(i)}))]$$

→ Entropía cruzada binaria

⑥ $\frac{\partial J}{\partial \theta_j} = \underbrace{\frac{\partial J}{\partial h_\theta}}_{①} \underbrace{\frac{\partial h_\theta}{\partial \eta}}_{②} \underbrace{\frac{\partial \eta}{\partial \theta_j}}_{③}$

① $\frac{\partial J}{\partial h_\theta} = -\frac{1}{m} \sum_{i=1}^m \left[\frac{y^{(i)}}{h_\theta(x^{(i)})} - \frac{1-y^{(i)}}{1-h_\theta(x^{(i)})} \right]$

② $\frac{\partial h_\theta}{\partial \eta} = h_\theta(x^{(i)}) (1 - h_\theta(x^{(i)}))$

③ $\frac{\partial \eta}{\partial \theta_j} = x_j^{(i)}$

$$\rightarrow \frac{\partial J}{\partial \theta_j} = -\frac{x_j^{(i)}}{m} \sum_{i=1}^m [y^{(i)} (1 - h_\theta(x^{(i)})) - (1 - y^{(i)}) h_\theta(x^{(i)})]$$

$$\frac{\partial J}{\partial \theta_j} = -\frac{x_j^{(i)}}{m} \sum_{i=1}^m [y^{(i)} - h_\theta(x^{(i)})] = \frac{x_j^{(i)}}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)})$$

⑦ $\theta_j := \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}$

⑧ Para el caso lineal, la regla de actualización es la misma que para la función logística, con la única diferencia de la definición de la hipótesis

Caso lineal: $h_\theta(x^{(i)}) = \theta^T x$

Caso logístico: $h_\theta(x^{(i)}) = \frac{1}{1 + e^{-\theta^T x}}$

VI. Regularización

$$\textcircled{1} \quad J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

$$\textcircled{2} \quad \text{Para } j \geq 1 \quad \frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j$$

$$\textcircled{3} \quad \text{Para } j=0 \quad \frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

$$\textcircled{4} \quad \text{La actualización para } j \geq 1: \quad \theta_j := \theta_j - \frac{\alpha}{m} \left[\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \lambda \theta_j \right]$$

$$\textcircled{5} \quad \theta_j := \theta_j \left(1 - \frac{\alpha \lambda}{m} \right) - \underbrace{\frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}}_{\text{Término de datos}}$$

$\textcircled{6}$ El factor $1 - \frac{\alpha \lambda}{m} < 1$ hace que θ_j decaiga en cada iteración, que tenderá entonces a 0 al final, a menos que el término de datos contrarreste este efecto, causando que al final se prefieran parámetros no muy grandes.

$$\textcircled{7} \quad J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})) \right] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

$$\textcircled{8} \quad \text{Para } j \geq 1: \quad \frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j$$

$\textcircled{9}$ Porque al no interactuar directamente con los datos $x_j^{(i)}$, no contribuye a la pendiente o a la curvatura y penalizarlo no reduce el sobreajuste; además, esto forzaría a que el modelo pase cerca del origen, introduciendo un sesgo en el ajuste.