

Taller: regresión lineal, regresión logística y regularización

Nombre: Valentina Lobo Ruiz - 1067912359

① Regresión lineal multivariada desde máxima verosimilitud.

1.1 Considere $\mathcal{D} = \{(x^{(i)}, y^{(i)})\}_{i=1}^m$ con $x^{(i)} = \begin{bmatrix} 1 \\ x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix}$, $\theta = \begin{bmatrix} \theta_0 \\ \vdots \\ \theta_n \end{bmatrix}$

Suponga que $y^{(i)} = \theta^T x^{(i)} + \epsilon^{(i)}$

donde $\theta^T x^{(i)}$ es una parte determinista de la salida, y $\epsilon^{(i)}$ es una fluctuación aleatoria con una distribución gaussiana.

Para determinar la distribución de $y^{(i)} | X = x_i$, se condiciona el término determinista $\theta^T x^{(i)}$ es una constante. Mientras $\epsilon^{(i)}$ sigue una distribución normal $\mathcal{N}(0, \sigma^2)$, por lo tanto, la variable $y^{(i)}$ es una constante más una gaussiana centrada en cero. De manera que: $y^{(i)} | X = x_i \sim \mathcal{N}(\theta^T x^{(i)}, \sigma^2)$

② Sustituyendo la media y la varianza en la densidad normal

$$p(y^{(i)} | x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}}$$

1.3 Sea $L(\theta)$ la probabilidad conjunta dada por

$$L(\theta) = p(y^{(1)}, y^{(2)}, \dots, y^{(m)} | X; \theta)$$

Suponiendo las observaciones independientes entre sí:

$$\begin{aligned} L(\theta) &= p(y^{(1)}, \dots, y^{(m)} | X; \theta) = \prod_{i=1}^m p(y^{(i)} | x^{(i)}; \theta) \\ &= \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}} \end{aligned}$$

1.4 Sea $l(\theta) = \log L(\theta)$

$$= \log \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}}$$

$$= \sum_{i=1}^m \log \left[\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}} \right]$$

$$= \sum_{i=1}^m \left[\log \frac{1}{\sqrt{2\pi}\sigma} - \frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right]$$

De manera que

$$l(\theta) = m \log \frac{1}{\sqrt{2\pi}\sigma} - \frac{1}{2\sigma^2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2$$

(1.5) De la expresión $l(\theta)$ el único término que depende de θ es la suma de los residuos al cuadrado

$$\sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)})^2$$

(1.6) Para maximizar $l(\theta)$ se realiza la derivación de $l(\theta)$ con respecto a θ .

$$\frac{d}{d\theta} l(\theta) = \frac{d}{d\theta} \left[m \log \frac{1}{\sqrt{2\pi}\sigma} - \frac{1}{2\sigma^2} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)})^2 \right]$$

$$= \frac{d}{d\theta} \left(\frac{1}{2\sigma^2} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)})^2 \right)$$

Como el máximo se encuentra en $\frac{d}{d\theta} l(\theta) = 0$ y $\frac{1}{2\sigma^2} \neq 0$

$$\frac{d}{d\theta} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)})^2 = 0$$

lo que es equivalente a los puntos críticos de la suma de los residuos cuadrados.

$$MSE = \frac{d}{d\theta} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)})^2 = \sum_{i=1}^m 2x^{(i)} (\theta^T x^{(i)} - y^{(i)})$$

$$\frac{\partial}{\partial \theta} (x^{(i)}) = x^{(i)}$$

(1.7) Para obtener la función de coste se define una hipótesis
 $h_{\theta}(x^{(i)}) = \theta^T x^{(i)} = \theta_0 + \theta_1 x_1^{(i)} + \dots + \theta_n x_n^{(i)}$

Así la suma de errores cuadrados hallado en la sección anterior queda como:

$$SSR = \sum_{i=1}^m (y^{(i)} - h_{\theta}(x^{(i)}))^2$$

$$SSR = \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Normalizando queda como:

$$MSE = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

lo cual se renombra como función de coste

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

(1.8) Sea $g(\theta) = SSR$ y $J(\theta) = \frac{1}{2m} J(\theta)$. Para cualesquiera θ_a, θ_b
 $g(\theta_a) \leq g(\theta_b)$ se cumple que $\frac{1}{2m} g(\theta_a) \leq \frac{1}{2m} g(\theta_b)$

dado que $\frac{1}{2m} > 0$

El conjunto de minimizadores no se ve modificado debido a que el ordenamiento de los puntos del espacio de parámetros es idéntico

2. Gradiente y descenso por gradiente

(2.1) Para calcular $\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j}$ recordemos $h_{\theta}(x^{(i)}) = \sum_{k=0}^n \theta_k x_k^{(i)}$

$$\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} = \frac{\partial}{\partial \theta_j} \sum_{k=0}^n \theta_k x_k^{(i)} = \sum_{k=0}^n \delta_{jk} x_k^{(i)}$$

$$\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} = x_j^{(i)}$$

(2.2) Usando la regla de la cadena para hallar $\frac{\partial J}{\partial \theta_j}$ se obtiene:

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{2m} \sum_{i=1}^m \frac{\partial}{\partial \theta_j} (r^{(i)})^2 \quad r^{(i)} = h_{\theta}(x^{(i)}) - y^{(i)}$$

$$= \frac{1}{2m} \sum_{i=1}^m 2 r^{(i)} \frac{\partial r^{(i)}}{\partial \theta_j}$$

$$= \frac{1}{2m} \sum_{i=1}^m 2 r^{(i)} \frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j}$$

$$= \frac{1}{2m} \sum_{i=1}^m 2 r^{(i)} x_j^{(i)}$$

$$= \frac{1}{m} \sum_{i=1}^m 2 (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

(2.3) Reescrito como la suma sobre los m datos queda entonces

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} \quad j = 0, 1, \dots, n$$

(2.4) Para construir $\theta_j = \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$

Se tiene entonces

$$\theta_j = \theta_j - \alpha \frac{\partial J}{\partial \theta_j} = \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} \quad j = 0, 1, \dots, n$$

(2.5) Escriba la actualización para $j = 0, 1, \dots, n$

Para $j=0$ $\theta_0 = \theta_0 - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)}$

$$\theta_0 = \theta_0 - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

Para $j=1$ $\theta_1 = \theta_1 - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_1^{(i)}$

$\vdots$

Para $j=n$ $\theta_n = \theta_n - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_n^{(i)}$

Reescrito de forma vectorial queda como $\theta = \theta - \frac{\alpha}{m} X^T (X\theta - \tilde{y})$

(2.6) ¿Por qué la actualización debe ser simultánea?

Dado que la regla de descenso por gradiente es: $\theta^{(t+1)} = \theta^{(t)} - \alpha \nabla_{\theta} J(\theta^{(t)})$

Las $n+1$ derivadas $\nabla_{\theta} J(\theta^{(t)})$ deben calcularse todas con los mismos valores antiguos $\theta^{(t)}$. Esto debido a que modificar/actualizar cualquier componente θ_j altera las predicciones $h(x^{(i)})$ y con ello todas las derivadas parciales. Las componentes del gradiente no son independientes entre sí.

En el caso de que si se modifican, cada componente quedan evaluadas en un punto distinto y el vector resultante no es el gradiente de J en ningún punto del espacio de parámetros, ya que, es una mezcla de mediciones tomadas en lugares diferentes. De esa forma se pierde la garantía de que $J(\theta^{(t+1)}) \leq J(\theta^{(t)})$; además la trayectoria pasa a depender del orden en que se recorren las coordenadas.

(3.1) Dado $X = \begin{bmatrix} 1 & x_1^{(1)} & \dots & x_n^{(1)} \\ 1 & x_1^{(2)} & \dots & x_n^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & \dots & x_n^{(m)} \end{bmatrix} \quad y = \begin{bmatrix} y^{(1)} \\ \vdots \\ y^{(m)} \end{bmatrix}$

Se define $J(\theta) = \frac{1}{2m} (X\theta - y)^T (X\theta - y)$

Veamos que ocurre al expandir $(X\theta - y)^T (X\theta - y)$

$$(X\theta - y)^T (X\theta - y) = (X\theta)^T - y^T (X\theta - y)$$

$$= \theta^T X^T - y^T (X\theta - y)$$

$$= \theta^T (X^T X) \theta - 2 (X^T y)^T \theta + y^T y$$

De manera que la función de coste queda como

$$J(\theta) = \frac{1}{2m} (\theta^T X^T X \theta - 2 y^T X \theta + y^T y)$$

(3.2) Para calcular $\nabla_{\theta} J(\theta)$

Teniendo en cuenta que $\nabla_{\theta} (b^T \theta) \Rightarrow \frac{\partial}{\partial \theta_j} \sum_{k=0}^n b_k \theta_k$

$$= \sum_{k=0}^n b_k \frac{\partial \theta_k}{\partial \theta_j}$$
$$= \sum_{k=0}^n b_k \delta_{kj} = b_j$$

Además que $\nabla_{\theta} (\theta^T A \theta) \Rightarrow \frac{\partial}{\partial \theta_j} (\theta^T A \theta) = \sum_k \sum_l A_{kl} \frac{\partial}{\partial \theta_j} (\theta_k \theta_l)$

$$= \sum_{k,l} A_{kl} (\delta_{kj} \theta_l + \theta_l \delta_{lj})$$
$$= \sum_k A_{kj} \theta_k + \sum_l A_{jl} \theta_l$$
$$= (A\theta)_j + (A^T \theta)_j$$
$$= (A + A^T) \theta$$

Con estas dos equivalencias se tiene que:

$$\nabla_{\theta} J(\theta) = \frac{1}{2m} (2X^T X \theta - 2X^T y)$$
$$= \frac{1}{m} (X^T X \theta - X^T y) = \frac{1}{m} X^T (X \theta - y) \quad (1.A)$$

(3.3) Si $\nabla_{\theta} J = 0 \Rightarrow \frac{1}{m} (X^T X \theta - X^T y) = 0$

(3.4) Así queda entonces $X^T X \theta = X^T y$

(3.5) Si $X^T X$ es invertible

$$(X^T X)^{-1} (X^T X) \theta = (X^T X)^{-1} X^T y \quad (2.A)$$

$$\theta = (X^T X)^{-1} X^T y$$

3.6 Al comparar $\theta = (X^T X)^{-1} X^T y$ obtenido a través de la ecuación normal con la solución obtenida a través del descenso de gradiente $\theta^{(t+1)} = \theta^{(t)} - \alpha \nabla_{\theta} J(\theta^{(t)})$ la primera diferencia es que el descenso de gradiente es el método iterativo y la ecuación normal es un método analítico. Otra diferencia notoria es que el descenso de gradiente requiere y depende de la elección de unos hiperparámetros como α y el número de iteraciones, mientras que la solución por ecuación normal no requiere de ellos.

¿Cuándo puede fallar la inversión?

La matriz $X^T X$ deja de ser invertible cuando X no tiene rango columna completo $\text{rang}(X) < n+1$. Este escenario puede ocurrir por la colinealidad exacta o por tener más parámetros que datos, es decir, $m < n+1$

4.1 Partiendo de $p(y; \phi) = \phi^y (1-\phi)^{1-y}$ con $y \in \{0, 1\}$

$$\begin{aligned} p(y; \phi) &= \exp[\log(\phi^y (1-\phi)^{1-y})] \\ &= \exp[y \log(\phi) + (1-y) \log(1-\phi)] \\ &= \exp[y \log \phi - y \log(1-\phi) + \log(1-\phi)] \\ &= \exp\left[y \log \frac{\phi}{1-\phi} + \log(1-\phi)\right] \end{aligned}$$

4.2 Comparando con la forma canónica $p(y; \eta) = b(y) e^{\eta^T T(y) - a(\eta)}$

Se tiene que

$$b(y) = 1 \quad T(y) = y \quad \eta = \log \frac{\phi}{1-\phi} \quad a(\eta) = -\log(1-\phi)$$

$$a(\eta) = \log(1 + e^{\eta})$$

(4.3) Evaluando a la forma canonica para:

$$y=1 \quad p(1;\eta) = e^{\eta \cdot 1 - a(\eta)}$$

$$p(0;\eta) = e^{\eta \cdot 0 - a(\eta)} = e^{-a(\eta)}$$

Dividiendo estas dos expresiones

$$\frac{p(1;\eta)}{p(0;\eta)} = \frac{e^{\eta - a(\eta)}}{e^{-a(\eta)}} = e^{\eta}$$

Por otro lado $p(1;\phi) = \phi^1 (1-\phi)^0 = \phi$

$$p(0;\phi) = 1 - \phi$$

Así queda entonces

$$e^{\eta} = \frac{\phi}{1-\phi} \rightarrow \eta = \log \frac{\phi}{1-\phi}$$

(4.4) Para despejar de ϕ

$$e^{\eta} = \frac{\phi}{1-\phi}$$

$$e^{\eta}(1-\phi) = \phi$$

$$e^{\eta} = \phi(1+e^{\eta})$$

$$\phi = \frac{e^{\eta}}{1+e^{\eta}}$$

$$\phi = \frac{1}{1+e^{-\eta}}$$

(4.5) Si $\eta = \theta^T x$

Obtenga $P_{\theta}(Y=1|X=x)$

$$P_{\theta}(Y=1|X=x) = \frac{1}{1+e^{-\theta^T x}}$$

Esta expresion ahora la definimos como h_{θ} que corresponde a una probabilidad

$$h_{\theta} = \frac{1}{1+e^{-\theta^T x}}$$

4.7 Obtenga $P_0(Y=0|X=x)$

$$P_0(Y=0|X=x) = 1 - h_0(x) \\ = 1 - \frac{1}{1 + e^{-\theta^T x}} = \frac{e^{-\theta^T x}}{1 + e^{-\theta^T x}}$$

Al multiplicar por $e^{\theta^T x}$ arriba y abajo

$$P_0(Y=0|X=x) = \frac{1}{e^{\theta^T x} + 1}$$

5.1 Escriba una expresión única para $p(y^{(i)}|x^{(i)}; \theta)$ válida para $y^{(i)}=0$ y $y^{(i)}=1$

Se sabe que $p(0|x; \theta) = 1 - h_\theta(x)$ y $p(1|x; \theta) = h_\theta(x)$

Una opción que se puede utilizar para generalizar estas expresiones es a través del uso de exponentes

$$p(y^{(i)}|x^{(i)}; \theta) = h_\theta(x^{(i)})^{y^{(i)}} (1 - h_\theta(x^{(i)}))^{1-y^{(i)}}$$

5.2 Construya la verosimilitud para m observaciones.

Para ello se asume la independencia condicional de las m observaciones

$$L(\theta) = \prod_{i=1}^m p(y^{(i)}|x^{(i)}; \theta)$$

$$= \prod_{i=1}^m h_\theta(x^{(i)})^{y^{(i)}} (1 - h_\theta(x^{(i)}))^{1-y^{(i)}}$$

5.3 La log-verosimilitud corresponde a:

$$l(\theta) = \log L(\theta) = \log \prod_{i=1}^m h_\theta(x^{(i)})^{y^{(i)}} (1 - h_\theta(x^{(i)}))^{1-y^{(i)}}$$

$$= \sum_{i=1}^m [y^{(i)} \log h_\theta(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_\theta(x^{(i)}))]$$

5.4 Cambie el signo y normalice por m para obtener $J(\theta)$

$$-\frac{1}{m} \ell(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1-y^{(i)}) \log (1-h_{\theta}(x^{(i)}))]$$

5.5 Identifique la entropía cruzada binaria

La entropía cruzada entre dos distribuciones p, q sobre el mismo espacio se define como: $H(p, q) = -\sum_k p_k \log q_k$

Para cada observación i , se toma

$$p^{(i)} = (y^{(i)}, 1-y^{(i)})$$

$$\text{Entonces } H(p^{(i)}, q^{(i)}) = -[y^{(i)} \log h_{\theta}(x^{(i)}) + (1-y^{(i)}) \log (1-h_{\theta}(x^{(i)}))]$$

De esta manera queda

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m H(p^{(i)}, q^{(i)})$$

5.6 Calcule $\frac{\partial J}{\partial \theta_j}$

$$\text{Derivando primero } \frac{\partial \ell}{\partial \theta_j} = \frac{\partial}{\partial \theta_j} [y \log h_{\theta} + (1-y) \log (1-h_{\theta})]$$

$$\begin{aligned} \frac{\partial h_{\theta}}{\partial \theta_j} &= \sigma(\theta^T x^{(i)}) (1 - \sigma(\theta^T x^{(i)})) x_j^{(i)} \\ &= h_{\theta} (1 - h_{\theta}) x_j^{(i)} \end{aligned} \quad \left| \begin{aligned} &= \frac{y}{h_{\theta}} \frac{\partial h}{\partial \theta_j} - \frac{1-y}{1-h_{\theta}} \frac{\partial h}{\partial \theta_j} \\ &= \left[\frac{y}{h_{\theta}} - \frac{1-y}{1-h_{\theta}} \right] h_{\theta} (1-h_{\theta}) x_j^{(i)} \\ &= [y(1-h_{\theta}) - (1-y)h_{\theta}] x_j^{(i)} \\ &= [y - y h_{\theta} + y h_{\theta} - h_{\theta}] \\ &= (y - h_{\theta}) x_j^{(i)} \end{aligned} \right.$$

De esta manera queda otra vez

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{j=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

5.7 Escriba la regla de descenso de gradiente
 La regla de descenso por gradiente queda de la forma:

$$\theta_j = \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} \quad j = 0, \dots, n$$

$$\text{con } h_{\theta}(x^{(i)}) = \sigma(\theta^T x^{(i)})$$

5.8 Al comparar el anterior resultado con el obtenido con por la regresión lineal se observa una mayor diferencia en particular en h_{θ} , donde para la regresión lineal es $\theta^T x$ y en la solución logística corresponde a $\sigma(\theta^T x)$.
 Otra diferencia es que h_{θ} es lineal en θ para la regresión lineal, mientras que para la regresión logística h_{θ} es una función no lineal sin solución cerrada.

6.1 Escriba el coste regularizado para regresión lineal.
 Recordando la función de coste para ello

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m h_{\theta}(x^{(i)} - y^{(i)})^2 + \lambda_2$$

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m h_{\theta}(x^{(i)} - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2 \quad \lambda \geq 0$$

6.2 Calcule $\frac{\partial J}{\partial \theta_j}$, $j \geq 1$

El término de penalización al derivarse se obtiene

$$\frac{\partial}{\partial \theta_j} \frac{\lambda}{2m} \sum_{k=1}^n \theta_k^2 = \frac{\lambda}{2m} \cdot 2\theta_j = \frac{\lambda}{m} \theta_j$$

Por tanto,

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \quad j = 1, \dots, n$$

6.3 Caso $j=0$

Como θ_0 no aparece en la penalización, su derivada es la del caso no regularizado.

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

(6.4) Construya la actualización para $j \geq 1$

$$\theta_j := \theta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \right]$$

(6.5)
$$:= \theta_j - \frac{\alpha \lambda}{m} \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

Si factorizamos θ_j de los primeros términos nos queda entonces

$$\theta_j := \theta_j \left(1 - \frac{\alpha \lambda}{m}\right) - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

De esta forma, el último término corresponde a la forma del descenso de gradiente no regularizado o también conocido como término de datos.

(6.6) Interprete el factor $1 - \frac{\alpha \lambda}{m}$

Suponiendo $\frac{\alpha \lambda}{m} < 1$, se tiene entonces $0 < 1 - \frac{\alpha \lambda}{m} < 1$ con lo cual este factor corresponde a una contracción, es decir, en cada iteración el parámetro se encoge hacia cero.

Un parámetro sobrevive con valor grande sólo si el gradiente de datos sostiene de forma consistente en cada iteración, contrariando la contracción.

En el caso $\lambda = 0$, el factor es 1, sin contracción.

Para el caso λ pequeño y positivo, minimiza J .

λ muy grande, el ajuste de datos deja de ser efectivo ya que $\theta_j \rightarrow 0$ y el modelo cae en un sesgo alto (subajuste).

Si $\frac{\alpha \lambda}{m} > 1$ el factor se vuelve negativo y la iteración oscila de signo.

6.7) Escriba el coste regularizado para regresión logística

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1-y^{(i)}) \log (1-h_{\theta}(x^{(i)}))] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

con $h_{\theta}(x) = \sigma(\theta^T x)$

6.8) Obtenga el gradiente correspondiente.

Análogo a los resultados previos

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \quad \frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \quad (j \geq 1)$$

6.9) ¿Por qué normalmente no se regulariza θ_0 ?

- ① θ_0 no controla la complejidad del modelo. El valor de θ_0 solo desplaza verticalmente el intercepto sin cambiar la forma
- ② Si se reemplaza $y^{(i)} \rightarrow y^{(i)} + c$, el modelo correcto es el mismo con $\theta_0 \rightarrow \theta_0 + c$; pero el término $\lambda \theta_0^2$ penalizaría de forma distinta el modelo.
- ③ Regularizando θ_0 se empuja $h_{\theta}(x) \rightarrow 0$ en promedio. Así se sesga sistemáticamente todas las predicciones hacia cero.
- ④ x_0 realmente no es una característica real, es una notación incluida para escribir el intercepto dentro del producto $\theta^T x$; por lo tanto, ya no se justifica.