

laboratorio 04

1. Regresión lineal multivariada desde máxima verosimilitud

En la regresión lineal se busca modelar una variable continua y a partir de variables de entrada x . Una forma natural de hacerlo es suponer que la salida observada está formada por una parte determinista, $\theta^T x$ más una fluctuación aleatoria.

Considere $D = \{(x^{(i)}, y^{(i)})\}_{i=1}^m$

con

$$x^{(i)} = \begin{bmatrix} 1 \\ x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix}, \quad \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}$$

suponga que $y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)}$, $\varepsilon^{(i)} \sim N(0, \sigma^2)$.

La hipótesis gaussiana permite construir una distribución para y , a partir de ella, una función de verosimilitud para los datos observados.

① Determinar la distribución de $y^{(i)} | X = x^{(i)}$

Partimos del modelo $y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)}$ con $\varepsilon^{(i)} \sim N(0, \sigma^2)$

↪ términos aleatorios:

Si fijamos $x^{(i)}$ y θ , la única fuente de aleatoriedad de $y^{(i)}$ es $\varepsilon^{(i)}$

Si $z \sim N(\mu, \sigma^2)$, entonces cualquier cte c : $c + z \sim N(c + \mu, \sigma^2)$. En el caso original, $z = \varepsilon^{(i)} \sim N(0, \sigma^2)$ y la cte $c = \theta^T x$.

$$\Rightarrow y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)} = c + z$$

si $\mu = 0$: $\theta \sim N(\theta^T x^{(i)}, \sigma^2)$

de esta manera $\underbrace{y^{(i)} | X = x^{(i)}}_{\text{distribución gaussiana}}; \theta \sim N(\underbrace{\theta^T x^{(i)}}_{\text{media}}, \underbrace{\sigma^2}_{\text{varianza}})$

② Escriba $p(y^{(i)} | x^{(i)}, \theta)$

La densidad de una variable $Z \sim N(\mu, \sigma^2)$ evaluada en un punto z es:

$$p(z) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(z-\mu)^2}{2\sigma^2}\right]$$

del punto anterior: $\left. \begin{array}{l} \cdot \text{media } \mu = \theta^T x^{(i)} \\ \cdot \text{varianza: } \sigma^2 \end{array} \right\} \begin{array}{l} \mu \rightarrow \theta^T x^{(i)} \\ z \rightarrow y^{(i)} \end{array}$

$$\Rightarrow p(y^{(i)} | x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right]$$

③ Suponiendo independencia entre observaciones, construya $L(\theta)$

Def La función verosimilitud $L(\theta)$ es la probabilidad conjunta de observar todos los datos $y = (y^{(1)}, \dots, y^{(m)})$ dado X (que contiene todos los $x^{(i)}$), vista como función de θ :

$$L(\theta) = L(\theta; X, y) = p(y | X; \theta)$$

Si las observaciones $(x^{(i)}, y^{(i)})$ son independientes entre sí, entonces la densidad conjunta de y dado X es el producto de las densidades individuales.

$$P(A_1, A_2, \dots, A_m) = p(A_1)p(A_2)\dots p(A_m)$$

Aplicando esto con $A_i = y^{(i)}$ dado $x^{(i)}$:

$$L(\theta) = \prod_{i=1}^m p(y^{(i)} | x^{(i)}; \theta)$$

$$L(\theta) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi} \sigma} \exp \left[-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right]$$

④ Obtenga $l(\theta) = \log L(\theta)$

$$\log\{L(\theta)\} = \log \left\{ \prod_{i=1}^m \frac{1}{\sqrt{2\pi} \sigma} \exp \left[-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right] \right\} \quad \text{propiedad: } \log(\prod_i a_i) = \sum_i \log(a_i)$$

$$l(\theta) = \sum_{i=1}^m \log \left\{ \frac{1}{\sqrt{2\pi} \sigma} \exp \left[-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right] \right\}$$

$$l(\theta) = \sum_{i=1}^m \left[\log \frac{1}{\sqrt{2\pi} \sigma} + \log \exp \left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right) \right]$$

$$l(\theta) = \sum_{i=1}^m \log \frac{1}{\sqrt{2\pi} \sigma} - \frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}$$

$$l(\theta) = \sum_{i=1}^m \log \frac{1}{\sqrt{2\pi} \sigma} - \sum_{i=1}^m \frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}$$

$$l(\theta) = m \log \frac{1}{\sqrt{2\pi} \sigma} - \frac{1}{2\sigma^2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2$$

⑤ Identifique los términos dependientes de θ .

$$l(\theta) = \underbrace{m \log \frac{1}{\sqrt{2\pi} \sigma}}_{\text{independiente de } \theta} - \frac{1}{2\sigma^2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2 = m \log \frac{1}{\sqrt{2\pi} \sigma} - \frac{1}{2\sigma^2} S(\theta)$$

dependiente de θ : $S(\theta)$

⑥ Muestre que maximizar $l(\theta)$ equivale a minimizar la suma de los residuos cuadrados

Partimos de

$$l(\theta) = m \log \frac{1}{\sqrt{2\pi} \sigma} - \frac{1}{2\sigma^2} S(\theta)$$

Lo que queremos encontrar es $\theta_m = \arg \max_{\theta} l(\theta)$

$$\Rightarrow \arg \max_{\theta} l(\theta) = \arg \max \left[m \log \frac{1}{\sqrt{2\pi} \sigma} - \frac{1}{2\sigma^2} S(\theta) \right]$$

Propiedad $\left\{ \text{si } c \text{ es cte entonces } \arg \max_{\theta} [c + f(\theta)] = \arg \max_{\theta} f(\theta) \right\}$

$$\arg \max_{\theta} l(\theta) = \arg \max \left[-\frac{1}{2\sigma^2} S(\theta) \right]$$

Propiedad $\left\{ \arg \max_{\theta} [K \cdot f(\theta)] = \arg \max_{\theta} f(\theta) \text{ si } K > 0 \right\}$

en nuestro caso, $\sigma^2 > 0$, así que $K = 1/2\sigma^2 > 0$.

$$\arg \max_{\theta} l(\theta) = \arg \max_{\theta} [-S(\theta)]$$

Propiedad $\left\{ \begin{array}{l} \text{maximizar } -f(\theta) \text{ equivale a minimizar } f(\theta) \\ \arg \max_{\theta} [-f(\theta)] = \arg \min_{\theta} f(\theta) \end{array} \right\}$

$$\arg \max_{\theta} l(\theta) = \arg \min_{\theta} [S(\theta)]$$

$$\operatorname{argmax}_{\theta} \ell(\theta) = \operatorname{argmin}_{\theta} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2$$

⑦ y ⑧ Obtener la función de costo $J(\theta)$

Definimos por hipótesis $h_{\theta}(x) = \theta^T x$

$$\Rightarrow S(\theta) = \sum_{i=1}^m (y^{(i)} - h_{\theta}(x^{(i)}))^2$$

$$S(\theta) = \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Si elegimos una cte $K = 1/2m$ con $m > 0$, entonces $K > 0$. Ya vimos que $\operatorname{argmin}_{\theta} [K \cdot f(\theta)] = \operatorname{argmin}_{\theta} f(\theta)$. Así que podemos agregar esa K en $S(\theta)$ y renombramos la expresión.

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}]^2$$

sosteniendo la equivalencia entre $\operatorname{argmax} \ell(\theta) = \operatorname{argmin} J(\theta)$

2. Gradiente y descenso por gradiente

Una vez construido $J(\theta)$, el aprendizaje puede verse como un problema de optimización. El gradiente indica cómo cambia el coste cuando cambia cada parámetro, y permite construir una regla iterativa para encontrar valores de θ que reduzcan el error. Parta de

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

① Calcule $\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j}$

Sabiendo que $h_{\theta}(x^{(i)}) = \theta_0 x_0^{(i)} + \theta_1 x_1^{(i)} + \dots + \theta_j x_j^{(i)} + \dots + \theta_n x_n^{(i)}$

$$\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} = \frac{\partial}{\partial \theta_j} (\theta_0 x_0^{(i)} + \theta_1 x_1^{(i)} + \dots + \theta_j x_j^{(i)} + \dots + \theta_n x_n^{(i)})$$

$$\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} = x_j^{(i)}$$

② y ③ Use la regla de la cadena para hallar $\partial J / \partial \theta_j$ y escriba el resultado como una suma

la fun de coste es: $J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{2m} \sum_{i=1}^m \frac{\partial}{\partial \theta_j} (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{2m} \sum_{i=1}^m \left\{ 2 [h_{\theta}(x^{(i)}) - y^{(i)}] \cdot \frac{\partial [h_{\theta}(x^{(i)}) - y^{(i)}]}{\partial \theta_j} \right\} \quad \text{Regla de la cadena}$$

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m \left\{ [h_{\theta}(x^{(i)}) - y^{(i)}] \frac{\partial [h_{\theta}(x^{(i)}) - y^{(i)}]}{\partial \theta_j} \right\}$$

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}] \frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j}$$

no depende de θ_j
ya lo habíamos calculado en ①

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}] x_j^{(i)}$$

④ Construya $\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}] x_j^{(i)}$$

para todos los parámetros:

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}] x_0^{(i)}$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}] x_1^{(i)}$$

⋮

$$\theta_n := \theta_n - \alpha \frac{1}{m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}] x_n^{(i)}$$

⑥ Explique por qué los parámetros deben actualizarse simultáneamente

- El gradiente $\nabla J(\theta)$ es un vector que apunta en la dirección de máx. crecimiento de la función en un punto específico del espacio de parámetros. Si actualizamos θ_0 y luego usamos ese nuevo valor de θ_0 para calcular la derivada con respecto a θ_1 , ya no estamos calculando el gradiente en el punto "original". Se estarían mezclando puntos.

3. Ecuación normal

Para regresión lineal también existe una sol. analítica. La idea es escribir el coste en forma matricial e imponer directamente la condición de mínimo. Definir:

$$X = \begin{bmatrix} 1 & x_1^{(1)} & \dots & x_n^{(1)} \\ 1 & x_1^{(2)} & \dots & x_n^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & \dots & x_n^{(m)} \end{bmatrix}, \quad y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix}, \quad J(\theta) = \frac{1}{2m} (X\theta - y)^T (X\theta - y)$$

① Expanda $(X\theta - y)^T (X\theta - y)$

$$\text{Propiedad } \left\{ \begin{array}{l} (A-B)^T = A^T - B^T \\ (AB)^T = B^T A^T \end{array} \right\}$$

$$\begin{aligned} \Rightarrow (X\theta - y)^T (X\theta - y) &= [(X\theta)^T - y^T] (X\theta - y) \\ &= (\theta^T X^T - y^T) (X\theta - y) \\ &= \theta^T X^T X \theta - \underbrace{\theta^T X^T y + y^T X \theta}_{\text{Notemos: } (\theta^T X^T y)^T = y^T (X^T)^T (\theta^T)^T = y^T X \theta} \end{aligned}$$

$$(X\theta - y)^T (X\theta - y) = \theta^T X^T X \theta - 2\theta^T X^T y + y^T y$$

② Calcule $\nabla_{\theta} J(\theta)$

$$\text{Sabemos } J(\theta) = \frac{1}{2m} [\theta^T X^T X \theta - 2\theta^T X^T y + y^T y]$$

$$\nabla_{\theta} J(\theta) = \frac{1}{2m} \left[\underset{1}{\nabla_{\theta} \theta^T X^T X \theta} - 2 \underset{2}{\nabla_{\theta} \theta^T X^T y} + \underset{3}{\nabla_{\theta} y^T y} \right]$$

$$\text{Propiedades } \left\{ \begin{array}{l} \nabla_w (w^T A w) = 2Aw \\ \nabla_w (w^T b) = b \\ \nabla_w (c) = 0 \end{array} \right\}$$

$$\begin{aligned} \Rightarrow 1: \nabla_{\theta} [\theta^T (X^T X) \theta] &= 2X^T X \theta \\ 2: \nabla_{\theta} [2\theta^T (X^T y)] &= 2X^T y \\ 3: \nabla_{\theta} (y^T y) &= 0 \end{aligned}$$

$$\nabla_{\theta} J(\theta) = \frac{1}{2m} (2X^T X \theta - 2X^T y)$$

$$\nabla_{\theta} J(\theta) = \frac{1}{m} (X^T X \theta - X^T y)$$

③ y ④ $\nabla_{\theta} J(\theta) = 0$

$$\frac{1}{n} (X^T X \theta - X^T y) = 0$$

$$X^T X \theta - X^T y$$

$$X^T X \theta = X^T y \rightarrow \text{ec. normal}$$

⑤ Si $X^T X$ es invertible, despeje θ

$$\underbrace{(X^T X)^{-1}}_{\text{condición invertible}} (X^T X) \theta = (X^T X)^{-1} X^T y$$

$$1 \theta = (X^T X)^{-1} X^T y$$

$$\theta = (X^T X)^{-1} X^T y$$

⑥ Compare esta solución con descenso por gradiente

• ¿Cuál es iterativa?

Descenso por gradiente. Requiere muchos pasos para converger al min y depende de elegir un buen α (tasa de aprendizaje)

• ¿Cuál es analítica?

La ec. normal. Es una sol. directa de un solo paso matemático. No requiere α ni iteraciones.

• ¿Cuándo puede fallar la inversión?

La matriz $X^T X$ no es invertible porque si tenemos más variables que datos de entrenamiento, el sistema está subentrenado y no tiene una solución única mediante inversión simple o puede haber redundancia de características cuando sean linealmente dependientes.

4. Regresión logística desde la familia exponencial

En clasificación binaria, Y toma dos valores posibles. Por ello, la distribución de Bernoulli proporciona un punto de partida natural. Al escribirla como miembro de la familia exponencial se obtiene una relación entre su parámetro natural y una fun. lineal de x . Considere

$$p(y; \eta) = b(y) \exp [\eta T(y) - a(\eta)],$$

y para $Y \in \{0, 1\}$, $p(y; \phi) = \phi^y (1 - \phi)^{1-y}$.

① Reescriba Bernoulli usando una exponencial

$$p(y; \phi) = \phi^y (1 - \phi)^{1-y}$$

usamos $e^{\ln(x)} = x$

$$p(y; \phi) = \exp \left\{ \ln [\phi^y (1 - \phi)^{1-y}] \right\}$$

$$= \exp [y \ln \phi + (1-y) \ln (1-\phi)]$$

$$= \exp [y \ln \phi + \ln (1-\phi) - y \ln (1-\phi)]$$

$$p(y; \phi) = \exp \left[y \ln \left(\frac{\phi}{1-\phi} \right) + \ln (1-\phi) \right]$$

② y ③ Identifique el parámetro natural η y muestre que $\eta = \ln [\phi / (1-\phi)]$

Sabemos de la def. general: $p(y; \eta) = b(y) \exp \left[\underbrace{\ln \left(\frac{\phi}{1-\phi} \right)}_{\eta} y - \underbrace{(-\ln (1-\phi))}_{a(\eta)} \right]$

al comparar con: $p(y; \phi) = \exp \left[y \ln \left(\frac{\phi}{1-\phi} \right) + \ln (1-\phi) \right]$

$b(\eta) = 1$, $\pi(\eta) = y$, $\eta = \ln \left(\frac{\phi}{1-\phi} \right)$ y $a(\eta) = -\ln (1-\phi)$

④ Despeje ϕ en función de η

Partimos de $\eta = \ln\left(\frac{\phi}{1-\phi}\right)$

$$e^\eta = \frac{\phi}{1-\phi}$$

$$e^\eta - e^\eta \phi = \phi$$

$$e^\eta = \phi(1 + e^\eta)$$

$$\frac{e^\eta / e^\eta}{1 + e^\eta / e^\eta} = \phi$$

$$\frac{1}{e^\eta + 1} = \phi$$

⑤ Si $\eta = \theta^T x$, obtenga $P_\theta(Y=1|X=x)$

En la dist. de Bernoulli, la probabilidad de éxito es ϕ . Es decir, $P(Y=1|X=x; \phi) = \phi$. Sustituimos el valor de $\phi = \theta^T x$ que despejamos en el punto anterior y reemplazamos el parámetro natural η por la combinación lineal de las características $\theta^T x$.

$$P_\theta(Y=1|X=x) = \frac{1}{1 + e^{-\theta^T x}}$$

⑥ Defina esta cantidad como $h_\theta(x)$

$$h_\theta(x) = P_\theta(Y=1|X=x) = \frac{1}{1 + e^{-\theta^T x}} \rightarrow \text{función logística llamada } g(z) = \frac{1}{1 + e^{-z}} \text{ con } z = \theta^T x$$

⑦ Obtenga $P_\theta(Y=0|X=x)$

Como Y es una variable aleatoria de Bernoulli, solo tiene dos resultados posibles $\{0, 1\}$. Por los axiomas de probabilidad, la suma de la prob. de todos los eventos debe ser 1.

$$P_\theta(Y=0|X=x) + P_\theta(Y=1|X=x) = 1$$

$$P_\theta(Y=0|X=x) = 1 - P_\theta(Y=1|X=x)$$

$$P_\theta(Y=0|X=x) = 1 - h_\theta(x)$$

$$\begin{aligned} P_\theta(Y=0|X=x) &= 1 - \frac{1}{1 + e^{-\theta^T x}} \\ &= \frac{1 + e^{-\theta^T x} - 1}{1 + e^{-\theta^T x}} \\ &= \frac{e^{-\theta^T x}}{1 + e^{-\theta^T x}} \end{aligned}$$

$$P_\theta(Y=0|X=x) = \frac{1}{e^{\theta^T x} + 1}$$

5. Likelihood y fun. de coste algebraico

Una vez obtenida $h_\theta(x)$, cada observación puede interpretarse probabilísticamente. Para $y=1$, el modelo asigna probabilidad $h_\theta(x)$; para $y=0$, asigna $1 - h_\theta(x)$. A partir de ambas posibilidades se construye una única expresión para la verosimilitud.

① Escriba una expresión única para $p(y^{(i)}|x^{(i)}; \theta)$ válida para $y^{(i)} = 0$ y $y^{(i)} = 1$

$$p(y^{(i)}|x^{(i)}; \theta) = [h_\theta(x^{(i)})]^{y^{(i)}} [1 - h_\theta(x^{(i)})]^{1-y^{(i)}}$$

• Si $y^{(i)} = 1$. El término $(1-h)^{1-1} = 0 \Rightarrow p = h_\theta(x^{(i)})$

• Si $y^{(i)} = 0$. El término h^0 se vuelve 1 $\Rightarrow p = 1 - h_\theta(x^{(i)})$

② Verosimilitud para m observaciones

Si los datos son independientes, la verosimilitud conjunta es el producto de las prob. individuales.

$$\begin{aligned} l(\theta) &= \prod_{i=1}^m p(y^{(i)} | x^{(i)}; \theta) \\ &= \prod_{i=1}^m [h_\theta(x^{(i)})]^{y^{(i)}} [1 - h_\theta(x^{(i)})]^{1-y^{(i)}} \end{aligned}$$

③ Calcule log-verosimilitud

$$\ell(\theta) = \log l(\theta)$$

$$\ell(\theta) = \sum_{i=1}^m \left\{ \log [h_\theta(x^{(i)})]^{y^{(i)}} + \log [1 - h_\theta(x^{(i)})]^{1-y^{(i)}} \right\}$$

$$\ell(\theta) = \sum_{i=1}^m \left[y^{(i)} \log [h_\theta(x^{(i)})] + (1 - y^{(i)}) \log [1 - h_\theta(x^{(i)})] \right]$$

④.⑤ Obtenga $J(\theta)$ e identifique la entropía cruzada binaria

En optimización, se prefiere minimizar una función de pérdida de maximizar la verosimilitud. Por eso cambiamos el signo y normalizamos el número de datos m :

$$J(\theta) = -\frac{1}{m} \ell(\theta)$$

$$= -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log [h_\theta(x^{(i)})] + (1 - y^{(i)}) \log [1 - h_\theta(x^{(i)})] \right]$$

entropía cruzada binaria: mide la distancia entre la distribución real y y la predicción de prob. $h_\theta(x)$

⑥ Calcule $\partial J / \partial \theta_j$

$$\frac{\partial}{\partial \theta_j} [y \log(h) + (1-y) \log(1-h)] = \frac{\partial}{\partial \theta_j} y \log(h) + \frac{\partial}{\partial \theta_j} (1-y) \log(1-h)$$

$$\text{debemos recordar } g(z) = \frac{1}{1+e^{-z}}$$

$$\text{con } g'(z) = g(z)(1-g(z)), \text{ como } h_\theta(x) = g(\theta^T x)$$

$$\Rightarrow \frac{\partial h}{\partial \theta_j} = h(1-h)x_j$$

$$\Rightarrow \frac{\partial}{\partial \theta_j} [y \log(h) + (1-y) \log(1-h)] = \frac{\partial}{\partial \theta_j} y \log(h) + \frac{\partial}{\partial \theta_j} (1-y) \log(1-h)$$

$$= y \frac{1}{h} \frac{\partial h}{\partial \theta_j} + (1-y) \left(\frac{-1}{1-h} \right) \frac{\partial h}{\partial \theta_j}$$

$$= y \frac{h(1-h)}{h} x_j - (1-y) h \frac{(1-h)}{1-h} x_j$$

$$= y(1-h)x_j - (1-y)hx_j$$

$$= (y - yh - h + yh)x_j$$

$$\frac{\partial J}{\partial \theta_j} = (y - h)x_j$$

si multiplicamos por $-1/m$, obtenemos:

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}] x_j^{(i)}$$

⑦ Regla de descenso por gradiente

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}] x_j^{(i)}$$

⑧ Este gradiente vs el de la regresión lineal

- la ec. es igual a la de la regresión lineal

- Diferencia en la def. de hipótesis $h_{\theta}(x)$:
$$\left\{ \begin{array}{ll} \text{Reg. lineal} & h_{\theta}(x) = \theta^T x \\ \text{Reg. logística} & h_{\theta}(x) = \sigma(\theta^T x) \end{array} \right.$$

6. Regularización

Un buen ajuste sobre los datos de entrenamiento no garantiza necesariamente una buena generalización. Una forma de controlar modelos con parámetros grandes es añadir una penalización a la fn. de coste. Para regularización L_2 ,

$$\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2.$$

el parámetro λ controla cuánto pesa esta penalización frente al ajuste a los datos.

① Escriba el coste regularizado para regresión lineal.

$$J(\theta)_{\text{original}} = \frac{1}{2m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}]^2$$

$$\Rightarrow J(\theta)_{\text{regularizado}} = \frac{1}{2m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}]^2 + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

$$J(\theta)_{\text{reg}} = \frac{1}{2m} \left[\sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}]^2 + \lambda \sum_{j=1}^n \theta_j^2 \right]$$

② Calcular $\partial J / \partial \theta_j$ para $j \geq 1$

$$\frac{\partial J}{\partial \theta_j} = \underbrace{\frac{1}{m} \sum_{i=1}^n [h_{\theta}(x^{(i)}) - y^{(i)}] x_j^{(i)}}_{\text{calculada previamente}} + \frac{\lambda}{2m} \sum_{j=1}^n 2\theta_j$$

$$= \frac{1}{m} \sum_{i=1}^n [h_{\theta}(x^{(i)}) - y^{(i)}] x_j^{(i)} + \frac{\lambda}{m} \theta_j$$

③ $j = 0$

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^n [h_{\theta}(x^{(i)}) - y^{(i)}] x_0^{(i)}$$

④ y ⑤ Construir la actualización para $j \geq 1$ y reorganice

La regla de actualización es $\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$

$$\theta_j := \theta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \right]$$

$$\theta_j := \theta_j - \frac{\alpha \lambda}{m} \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

$$\theta_j := \theta_j \left(1 - \frac{\alpha \lambda}{m} \right) - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

⑥ Interpretar $1 - \alpha \lambda / m$

- Se conoce como decaimiento de pesos.
- Como α, λ y m son > 0 , el término $\alpha \lambda / m > 0$. Así que $1 - \alpha \lambda / m < 1$
- El término ayuda a que los pesos crezcan sin control. Si hay ruido en los datos, el decaimiento terminará llevando su valor hacia cero.

⑦ Escriba el coste regularizado para regresión logística

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(h_\theta(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)}))] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

igual que en la reg. lineal
fun. coste original + penalización L_2

⑧ Gradiente correspondiente

Debido a la linealidad de la derivada, el gradiente del coste es la suma del gradiente de coste original más el gradiente del término de penalización.

$$\rightarrow \text{para } j=0: \quad \frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m [h_\theta(x^{(i)}) - y^{(i)}] x_0^{(i)}$$

$$\rightarrow j=1, \dots, n: \quad \frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m [h_\theta(x^{(i)}) - y^{(i)}] x_j^{(i)} + \frac{\lambda}{m} \theta_j$$

Escribiendo de una forma vectorial la expresión, el gradiente sería $\nabla J(\theta) = \frac{1}{m} X^T [h_\theta(X) - y] + \frac{\lambda}{m} \theta_{reg}$

$h_\theta(x) = \frac{1}{1 + e^{-\theta^T x}}$
 $\downarrow$
 $[0, \theta_1, \theta_2, \dots, \theta_n]^T$

⑨ Explique por qué normalmente no se regulariza θ_0

- θ_0 es el intercepto. No multiplica ninguna característica de datos ($x_0 = 1$). Mientras que los θ_j controlan la pendiente o sensibilidad del modelo ante los cambios de las variables
- Un valor grande de θ_0 no hace que el modelo sea más complejo, solo indica dónde se sitúa la base de la predicción.