

1. Regresión lineal multivariada desde máxima verosimilitud

En regresión lineal se busca modelar una variable continua Y a partir de variables de entrada X . Una forma natural de hacerlo es suponer que la salida observada está formada por una parte determinista, $\theta^T x$, más una fluctuación aleatoria.

Considere

$$\mathcal{D} = \{(x^{(i)}, y^{(i)})\}_{i=1}^m,$$

con

$$x^{(i)} = \begin{bmatrix} 1 \\ x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix}, \quad \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}.$$

Suponga que

$$y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)}, \quad \varepsilon^{(i)} \sim \mathcal{N}(0, \sigma^2).$$

La hipótesis gaussiana permite construir una distribución para Y y, a partir de ella, una función de verosimilitud para los datos observados.

1. Determine la distribución de

$$Y^{(i)} \mid X = x^{(i)}.$$

2. Escriba

$$p(y^{(i)} \mid x^{(i)}; \theta).$$

3. Suponiendo independencia entre observaciones, construya

$$L(\theta).$$

4. Obtenga

$$\ell(\theta) = \log L(\theta).$$

Assumiendo que $\varepsilon^{(i)}$ son independientes e idénticamente distribuidos y dado que con $x^{(i)}$ fijo $\rightarrow \theta^T x^{(i)}$ es una cantidad determinista. Por la propiedad de traslación de la normal.

$$\text{Si } \varepsilon^{(i)} \sim \mathcal{N}(0, \sigma^2) \rightarrow$$

$$\text{Entonces } Y^{(i)} \mid X = x^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)} \sim \mathcal{N}(\theta^T x^{(i)}, \sigma^2)$$

La densidad de $\varepsilon^{(i)}$ es

$$p(\varepsilon^{(i)}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(\varepsilon^{(i)})^2}{2\sigma^2}\right)$$

$$\gamma \text{ como } \varepsilon^{(i)} = y^{(i)} - \theta^T x^{(i)}$$

$$p(y^{(i)} \mid x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$$

La verosimilitud es la probabilidad conjunta de los datos observados, vista como función de θ , en este caso, con independencia

$$L(\theta) = \prod_{i=1}^m p(y^{(i)} \mid x^{(i)}; \theta) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$$

γ por tanto

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^m \log \left[\frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right) \right]$$

5. Identifique los términos que dependen de θ .
6. Muestre que maximizar $\ell(\theta)$ equivale a minimizar la suma de residuos cuadrados.
7. Obtenga una función de coste de la forma

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2.$$

$$\ell(\theta) = \sum_{i=1}^m \left[\log \frac{1}{\sqrt{2\pi}\sigma} - \frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right]$$

$$\ell(\theta) = m \log \frac{1}{\sqrt{2\pi}\sigma} - \frac{1}{2\sigma^2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2$$

8. Explique por qué $1/2$ y $1/m$ no cambian el minimizador.

así $\ell(\theta) = A - \frac{B}{2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2$

donde A es constante respecto a θ y B es una constante positiva. $\therefore$
maximizar $\ell(\theta)$ respecto a θ es equivalente a minimizar

$$\frac{1}{2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2 \rightarrow \text{suma de residuos cuadrados}$$

Ahora, definimos la hipótesis como $h_{\theta}(x^{(i)}) = \theta^T x^{(i)}$ y considerando $(a-b)^2 = (b-a)^2$ y que el objetivo de minimizar no cambia si se multiplica por una constante positiva. Llegamos a

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Esto es así pues al $\frac{1}{2m} > 0 \rightarrow \theta^* = \arg \min f(\theta) \hookrightarrow \theta^* = \arg \min [cf(\theta)]$, pues $cf(\theta)$ es una transformación estrictamente creciente, se preserva cuál θ produce el valor mínimo

2. Gradiente y descenso por gradiente

Una vez construida $J(\theta)$, el aprendizaje puede verse como un problema de optimización. El gradiente indica cómo cambia el coste cuando cambia cada parámetro, y permite construir una regla iterativa para encontrar valores de θ que reduzcan el error.

Parta de

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2.$$

1. Calcule

$$\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j}.$$

2. Use la regla de la cadena para hallar

$$\frac{\partial J}{\partial \theta_j}.$$

3. Escriba el resultado como suma sobre los m datos.

4. Construya

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}.$$

5. Escriba la actualización para

$$j = 0, 1, \dots, n.$$

6. Explique por qué los parámetros deben actualizarse simultáneamente.

Recordemos que la hipótesis es

$$h_{\theta}(x^{(i)}) = \theta^T x^{(i)} = \sum_{k=0}^n \theta_k x_k^{(i)}$$

$$\begin{aligned} \therefore \frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} &= \frac{\partial}{\partial \theta_j} \sum_{k=0}^n \theta_k x_k^{(i)} = \sum_{k=0}^n \delta_{kj} x_k^{(i)} \\ &= x_j^{(i)} \end{aligned}$$

Ahora, tomando el interior de la suma en $J(\theta)$

$$\begin{aligned} \frac{\partial}{\partial \theta_j} (h_{\theta}(x^{(i)}) - y^{(i)})^2 &= 2 (h_{\theta}(x^{(i)}) - y^{(i)}) \frac{\partial}{\partial \theta_j} (h_{\theta}(x^{(i)}) - y^{(i)}) \\ &= 2 (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} \end{aligned}$$

$$\begin{aligned} \therefore \frac{\partial J}{\partial \theta_j} &= \frac{\partial}{\partial \theta_j} \left[\frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 \right] \\ &= \frac{1}{2m} \sum_{i=1}^m 2 (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} \end{aligned}$$

Para dar repetidamente un paso en la dirección de decrecimiento más pronunciado de J se hace

$$\begin{aligned} \theta_j &:= \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta) \\ &:= \theta_j - \alpha \cdot \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} \end{aligned}$$

Esto no se aplica una sola vez, sino que se repite para cada componente de θ

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_1^{(i)}$$

$$\dots \quad \theta_n := \theta_n - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_n^{(i)}$$

$$x_0^{(i)} = 1$$

Cada derivada parcial $\frac{\partial J}{\partial \theta_j}$ está definida en función del mismo punto $\vec{\theta}$, asen que es la dirección de mayor crecimiento de J evaluada con todos los parámetros actuales fijos. Por eso se deben calcular todos los $\frac{\partial J}{\partial \theta_j}$ usando los valores actuales y solo después de eso, se reemplazan los θ_j por los calculados.

3. Ecuación normal

Para regresión lineal también existe una solución analítica. La idea es escribir el coste en forma matricial e imponer directamente la condición de mínimo.

Defina

$$X = \begin{bmatrix} 1 & x_1^{(1)} & \dots & x_n^{(1)} \\ 1 & x_1^{(2)} & \dots & x_n^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & \dots & x_n^{(m)} \end{bmatrix},$$

$$y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix}, \quad J(\theta) = \frac{1}{2m} (X\theta - y)^T (X\theta - y).$$

1. Expanda

$$(X\theta - y)^T (X\theta - y).$$

2. Calcule

$$\nabla_{\theta} J(\theta).$$

3. Imponga

$$\nabla_{\theta} J(\theta) = 0.$$

4. Obtenga

$$X^T X \theta = X^T y.$$

5. Si $X^T X$ es invertible, despeje θ .

6. Compare esta solución con descenso por gradiente:

- ¿cuál es iterativa?
- ¿cuál es analítica?
- ¿cuándo puede fallar la inversión?

y por tanto

$$(X\theta - y)^T (X\theta - y) = \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 = 2m J(\theta)$$

de otra forma

$$\begin{aligned} (X\theta - y)^T (X\theta - y) &= (X\theta)^T X\theta - (X\theta)^T y - y^T (X\theta) + y^T y \\ &= \theta^T X^T X \theta - \theta^T X^T y - y^T X \theta + y^T y \\ &= \theta^T (X^T X) \theta - 2(X^T y)^T \theta + y^T y \end{aligned}$$

$$a^T b = b^T a$$

teniendo en cuenta que $\nabla_x b^T x = b$ y $\nabla_x x^T A x = 2Ax$ (A simétrica)
queremos obtener $\nabla_{\theta} J(\theta)$

término a término

$$- \nabla_{\theta} [\theta^T (X^T X) \theta] = 2X^T X \theta$$

$$- \nabla_{\theta} [-2(X^T y)^T \theta] = -2X^T y$$

$$- \nabla_{\theta} [y^T y] = 0$$

$$\begin{aligned} \therefore \nabla_{\theta} J(\theta) &= \frac{1}{2m} [2X^T X \theta - 2X^T y] \\ &= \frac{1}{m} (X^T X \theta - X^T y) \end{aligned}$$

$$\begin{aligned} X\theta - y &= \begin{bmatrix} (x^{(1)})^T \theta \\ \vdots \\ (x^{(m)})^T \theta \end{bmatrix} - \begin{bmatrix} y^{(1)} \\ \vdots \\ y^{(m)} \end{bmatrix} \\ &= \begin{bmatrix} (x^{(1)})^T \theta - y^{(1)} \\ \vdots \\ (x^{(m)})^T \theta - y^{(m)} \end{bmatrix} \end{aligned}$$

Definiendo la hipótesis como $h_{\theta}(x^{(i)}) = (x^{(i)})^T \theta$

$$X\theta - y = \begin{bmatrix} h_{\theta}(x^{(1)}) - y^{(1)} \\ \vdots \\ h_{\theta}(x^{(m)}) - y^{(m)} \end{bmatrix}$$

igualando el gradiente a cero $\rightarrow X^T X \theta = X^T y$

y asumiendo $X^T X$ invertible $\rightarrow \theta = (X^T X)^{-1} X^T y$

- El descenso por gradiente parte de un valor inicial arbitrario de θ y aplica repetitivamente actualización (iterativo)
- En la ecuación normal θ se calcula en un solo paso, mediante operaciones matriciales (analítico)

Cuando n es muy grande, la inversión $X^T X$ se vuelve muy costosa, pero cuando es pequeño evita la complejidad de iterar.

La inversión de $X^T X$ falla cuando:

1. El número de ejemplos de entrenamiento m es menor al número de parámetros $n+1$, $X^T X$ no tiene rango completo.
2. Si alguna columna de X es combinación lineal de otras, $X^T X$ es singular.

4. Regresión logística desde la familia exponencial

En clasificación binaria, Y toma dos valores posibles. Por ello, la distribución Bernoulli proporciona un punto de partida natural. Al escribirla como miembro de la familia exponencial se obtiene una relación entre su parámetro natural y una función lineal de x . Considere

$$p(y; \eta) = b(y) \exp [\eta T(y) - a(\eta)],$$

y para $Y \in \{0, 1\}$,

$$p(y; \phi) = \phi^y (1 - \phi)^{1-y}.$$

1. Reescriba Bernoulli usando una exponencial.

2. Identifique el parámetro natural η .

3. Muestre que

$$\eta = \log \frac{\phi}{1-\phi}.$$

4. Despeje ϕ en función de η .

5. Si

$$\eta = \theta^T x,$$

obtenga

$$P_\theta(Y = 1 \mid X = x).$$

$$\begin{aligned} p(y; \phi) &= \exp(\log[\phi^y (1-\phi)^{1-y}]) \\ &= \exp(y \log \phi + (1-y) \log(1-\phi)) \end{aligned}$$

expandiendo el término

$$y \log \phi + \log(1-\phi) - y \log(1-\phi) = y[\log \phi - \log(1-\phi)] + \log(1-\phi)$$

$$= y \log\left(\frac{\phi}{1-\phi}\right) + \log(1-\phi)$$

$$\therefore p(y; \phi) = \exp\left[y \log\left(\frac{\phi}{1-\phi}\right) + \log(1-\phi)\right]$$

comparando con la familia exponencial

$$\eta = \log\left(\frac{\phi}{1-\phi}\right), \quad T(y) = y, \quad a(\eta) = -\log(1-\phi), \quad b(y) = 1$$

veamos que

$$e^\eta = \frac{\phi}{1-\phi} \rightarrow e^\eta (1-\phi) = \phi \rightarrow e^\eta = \phi + \phi e^\eta = \phi (1 + e^\eta)$$

$$\phi = \frac{e^\eta}{1 + e^\eta} \cdot \frac{e^{-\eta}}{e^{-\eta}} = \frac{1}{1 + e^{-\eta}}$$

Ahora, si $\eta = \theta^T x$, podemos definir la hipótesis como la esperanza condicional de y dado x

$$h_\theta(x) = E[y \mid x; \theta]$$

para $y \mid x; \theta \sim \text{Bernoulli}(\phi) \rightarrow E[y \mid x; \theta] = \phi$ ($P(Y=1) = \phi$, su esperanza es ϕ)

$$\therefore h_\theta(x) = \phi = \frac{1}{1 + e^{-\eta}}$$

$$\text{así } P_\theta(Y=1 \mid X=x) = h_\theta(x) = \frac{1}{1 + e^{-\theta^T x}}$$

6. Defina esta cantidad como

$$h_{\theta}(x).$$

$$P_{\theta}(Y=1|X=x) + P_{\theta}(Y=0|X=x) = 1$$

7. Obtenga

$$P_{\theta}(Y=0|X=x).$$

$$P_{\theta}(Y=0|X=x) = 1 - h_{\theta}(x)$$

$$= 1 - \frac{1}{1 + e^{-\theta^T x}}$$

$$\therefore P_{\theta}(Y=0|X=x) = \frac{1}{1 + e^{\theta^T x}}$$

5. Likelihood y función de coste logística

Una vez obtenida $h_{\theta}(x)$, cada observación puede interpretarse probabilísticamente. Para $y = 1$, el modelo asigna probabilidad $h_{\theta}(x)$; para $y = 0$, asigna $1 - h_{\theta}(x)$. A partir de ambas posibilidades se construye una única expresión para la verosimilitud.

1. Escriba una expresión única para

$$p(y^{(i)} | x^{(i)}; \theta)$$

válida para $y^{(i)} = 0$ y $y^{(i)} = 1$.

2. Construya la verosimilitud para m observaciones.
3. Calcule la log-verosimilitud.
4. Cambie el signo y normalice por m para obtener $J(\theta)$.
5. Identifique la entropía cruzada binaria.

6. Calcule

$$\frac{\partial J}{\partial \theta_j}$$

7. Escriba la regla de descenso por gradiente.
8. Compare este gradiente con el de regresión lineal.

Puede ser útil recordar que

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad \sigma'(z) = \sigma(z)(1 - \sigma(z)).$$

En lugar de dos formulas separadas, se busca una que reproduzca cada caso

$$p(y|x; \theta) = (h_{\theta}(x))^y (1 - h_{\theta}(x))^{1-y}$$

$$\text{Si } y=1 \rightarrow (h_{\theta}(x))^1 (1 - h_{\theta}(x))^0 = h_{\theta}(x)$$

$$\text{Si } y=0 \rightarrow (h_{\theta}(x))^0 (1 - h_{\theta}(x))^1 = 1 - h_{\theta}(x)$$

para el i -ésimo cs

$$p(y^{(i)} | x^{(i)}; \theta) = (h_{\theta}(x^{(i)}))^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{1-y^{(i)}}$$

Asumiendo independencia $L(\theta) = p(y|x; \theta) = \prod_{i=1}^m (h_{\theta}(x^{(i)}))^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{1-y^{(i)}}$

$$\begin{aligned} \gamma \quad \ell(\theta) &= \sum_{i=1}^m \log \left[(h_{\theta}(x^{(i)}))^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{1-y^{(i)}} \right] \\ &= \sum_{i=1}^m \left[y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right] \end{aligned}$$

γ definimos $J(\theta) = -\frac{1}{m} \ell(\theta) \rightarrow$ Entropía cruzada binaria

La pérdida logística para un par (t, y) es $\lambda_{\log}(t, y) = y \log(1 + e^{-t}) + (1 - y) \log(1 + e^t)$ y sustituyendo $t = \theta^T x$, la negativa de la log-verosimilitud es esta pérdida. Por tanto cada término de $J(\theta)$ es la entropía cruzada binaria entre la etiqueta real y y la probabilidad predicha $h_{\theta}(x)$, y $J(\theta)$ es su promedio sobre los m ejemplos

Ahora, derivando un solo término y llamando $h_{\theta}(x) = \sigma(\theta^T x)$

$$\frac{\partial \ell(\theta)}{\partial \theta_j} = y \frac{1}{\sigma(\theta^T x)} \frac{\partial}{\partial \theta_j} \sigma(\theta^T x) - (1 - y) \frac{1}{1 - \sigma(\theta^T x)} \frac{\partial}{\partial \theta_j} \sigma(\theta^T x)$$

$$\gamma \quad \frac{\partial}{\partial \theta_j} \sigma(\theta^T x) = \sigma(\theta^T x) (1 - \sigma(\theta^T x)) \frac{\partial \theta^T x}{\partial \theta_j}$$

$$\begin{aligned} \therefore \quad \frac{\partial l(\theta)}{\partial \theta_j} &= \left[y \frac{1}{\sigma(\theta^T x)} - (1-y) \frac{1}{1-\sigma(\theta^T x)} \right] \sigma(\theta^T x) (1 - \sigma(\theta^T x)) x_j \\ &= [y(1 - \sigma(\theta^T x)) - (1-y)\sigma(\theta^T x)] x_j \\ &= (y - h_\theta(x)) x_j \end{aligned}$$

$$\text{como } J(\theta) = -\frac{1}{m} l(\theta) \quad \rightarrow \quad \frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

La regla de descenso por gradiente es entonces

$$\theta_j := \theta_j - \alpha \cdot \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

El cual es idéntico en forma al gradiente de regresión lineal, considerando que en un caso $h_\theta(x) = \theta^T x$ es lineal y en otro $h_\theta(x) = \sigma(\theta^T x)$ es no-lineal

6. Regularización

Un buen ajuste sobre los datos de entrenamiento no garantiza necesariamente una buena generalización. Una forma de controlar modelos con parámetros grandes es añadir una penalización a la función de coste. Para regularización L_2 ,

$$\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2.$$

El parámetro λ controla cuánto pesa esta penalización frente al ajuste a los datos.

1. Escriba el coste regularizado para regresión lineal.

2. Calcule

$$\frac{\partial J}{\partial \theta_j}, \quad j \geq 1.$$

3. Escriba por separado el caso $j = 0$.

4. Construya la actualización para $j \geq 1$.

5. Reorganice hasta obtener

$$\theta_j := \theta_j \left(1 - \frac{\alpha \lambda}{m}\right) - \text{término de datos}.$$

6. Interprete el factor

$$1 - \frac{\alpha \lambda}{m}.$$

Para $J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$

El coste regularizado es $J_{\lambda}(\theta) = J(\theta) + \lambda R(\theta)$

y para regularización L_2

$$J_{\lambda}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

En este caso podemos ver $\frac{\partial J}{\partial \theta_j} \quad j \geq 1$

$$\frac{\partial}{\partial \theta_j} \left[\frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 \right] = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

y $\frac{\partial}{\partial \theta_j} \left[\frac{\lambda}{2m} \sum_{k=1}^n \theta_k^2 \right] = \frac{\lambda}{2m} 2 \theta_j = \frac{\lambda}{m} \theta_j$

$\therefore \frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \quad j \geq 1$

para $j=0$ solo sobrevive la parte del ajuste $\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$

$$x_0^{(i)} = 1$$

Aplicando la regla del descenso por gradiente

$$\theta_j := \theta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \right]$$

$$\theta_j := \theta_j - \frac{\alpha \lambda}{m} \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

$$\theta_j := \theta_j \left(1 - \frac{\alpha \lambda}{m}\right) - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

Cada θ_j para $j \geq 1$ se multiplica por un factor menor a uno, encojiendolo ligeramente hacia cero, evitando que crezca.

7. Escriba el coste regularizado para regresión logística.
8. Obtenga el gradiente correspondiente.
9. Explique por qué normalmente no se regulariza θ_0 .

para regresión logística

$$J_{\lambda}(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log h_{\theta}(x^{(i)}) + (1-y^{(i)}) \log (1-h_{\theta}(x^{(i)})) \right] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

$$\text{y} \quad \frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j$$

$$\text{para } j=0 \quad \frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)}$$

por lo que se cumple lo mismo en la regla de actualización.

Finalmente, recordemos que θ_0 es el valor de $h_{\theta}(x)$ cuando todas las características $x_1, \dots, x_n$ son cero. y que la regularización quiere penalizar coeficientes grandes que hagan que el modelo dependa demasiado de ciertas características.

Pero un valor grande de θ_0 solo refleja que la variable objetivo está lejos de cero, si se penalizara, se introduciría un sesgo hacia valores bajos.