

$y = \theta^T x^i + \varepsilon^i$ dado que $\theta^T x^i$ es un escalar y por hipótesis $\varepsilon^i \rightarrow \mathcal{N}(0, \sigma^2)$ distribución normal el término $\theta^T x^i$ corre la gaussiana esa cantidad a la derecha

$$\mathcal{N}(\theta^T x^i, \sigma^2)$$



$$p(y^{(i)}, x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^i - \theta^T x^i)^2}{2\sigma^2}\right) \text{ dado que es la normal}$$

Basandonos en el texto tenemos que función likelihood

$$L(\theta) = p(\overset{\text{Matriz}}{\vec{y}} | X, \theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(\vec{y} - \theta^T X)^2}{2\sigma^2}\right)$$

Suponiendo independencia entre observaciones podemos escribir esta función

$$L(\theta) = \prod_{i=1}^n p(y^{(i)} | x^{(i)}; \theta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$$

Tomando el Logaritmo en ambos lados de la igualdad

$$\ln L(\theta) = n \ln \frac{1}{\sqrt{2\pi}\sigma} - \sum_{i=1}^n \frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}$$

Terminos dependientes θ

dado el signo negativo que antecede al término a analizar si minimizar es equivalente a maximizar

La función es aquella que posee el parámetro en nuestro caso

$$\frac{1}{2\sigma^2} \sum_{i=1}^n (y^{(i)} - \theta^T x^{(i)})^2$$

↳ mínimos cuadrados

Dado que al minimizar igualamos a cero, y además suponemos $\sigma \neq 0$ el término $\frac{1}{2\sigma^2}$ es irrelevante $\therefore$ la función $J(\theta)$ será

$$J(\theta) = \frac{1}{2\sigma^2} \sum_{i=1}^n (\underbrace{\theta^T x^i}_{h_\theta(x^i)} - y^i)^2 \quad \text{derivamos con respecto a } \theta$$

$$\frac{\partial h_\theta(x^i)}{\partial \theta_j} = \frac{\partial (\theta^T x^i)}{\partial \theta_j} = \frac{\partial \sum_{i=1}^n \theta_i x_i}{\partial \theta_j} = \sum_{i=1}^n x_i \delta_{ij} = x_j \quad \text{ahora derivamos}$$

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{\sigma^2} \sum_{i=1}^n (\theta^T x^i - y^i) \frac{\partial h_\theta}{\partial \theta_j} = \frac{1}{\sigma^2} \sum_{i=1}^n (\theta^T x^i - y^i) x_j^i$$

nota $\partial/\partial \theta$ puede entrar en la sumatoria por ser una función bien comportada

al partir de un parámetro inicial para definir el próximo iteramos de la siguiente manera

$$\theta_j := \theta_j - \alpha \frac{\partial J(\theta)}{\partial \theta_j} \quad \leftarrow \text{parámetro de aprendizaje (depende de mi muestra)}$$

Si iteramos en el conjunto de Muestra o de entrenamiento

$$\theta_i := \theta_i + \alpha \sum_{i=1}^n (y^{(i)} - h_\theta(x^i)) \quad \text{notas que debemos correr sobre } i$$

es decir debemos actualizar cada dato.

Podemos tener un conjunto de entrenamiento con diferentes características lo que nos lleva a tener una matriz donde cada columna equivale a una observación por tanto la matriz de entrenamiento tendría la forma

$$X = \begin{bmatrix} | & x_1^{(1)} & \dots & x_n^{(1)} \\ | & x_1^{(2)} & & \vdots \\ | & \vdots & & \vdots \\ | & x_r^{(m)} & \dots & x_n^{(m)} \\ | & & & \end{bmatrix} \quad \text{y sea } \vec{y} = \begin{bmatrix} y^1 \\ y^2 \\ \vdots \\ y^m \end{bmatrix} \quad \text{datos de salida}$$

$$J(\theta) = \frac{1}{2m} (\underbrace{X\theta - \vec{y}}_{\substack{(\theta^T X^T \vec{y})^T = y^T X\theta}})^T (X\theta - \vec{y}) = \frac{1}{2m} (\theta^T X^T - \vec{y}^T) (X\theta - \vec{y}) = \frac{1}{2m} \underbrace{\theta^T X^T X \theta}_{\substack{(\theta^T X^T \vec{y})^T = y^T X\theta}} - \theta^T X^T \vec{y} - y^T X \theta + \vec{y} \cdot \vec{y}$$

$$J(\theta) = \frac{1}{2m} (\theta^T X^T X \theta - 2 \vec{y}^T X \theta + \|\vec{y}\|^2) \quad \text{tomando el gradiente para minimizar a } J(\theta) \text{ que recordamos es maximizar la función } L(\theta)$$

$$\nabla_{\theta} J(\theta) = \frac{1}{2m} \nabla_{\theta} (\theta^T \underline{X^T X} \theta - 2(X^T y)^T \theta + \| \vec{y} \|^2) \quad \nabla_x b^T x = b \quad \nabla_x x^T A x = 2Ax$$

$$\nabla_{\theta} J(\theta) = \frac{1}{2m} (2 X^T X \theta - 2 X^T y) = 0 \quad \therefore X^T X \theta = X^T y \quad \therefore \text{dado}$$

que supone una independencia estadística podemos decir que el determinante de X es $\neq 0$ y por lo tanto tenemos invertibilidad

$$\cancel{(X^T X)^{-1}} X^T X \theta = (X^T X)^{-1} X^T y \quad \theta = X^T y \quad \text{que es nuestra hipótesis}$$

$$p(y; \phi) = \phi^y (1-\phi)^{1-y} \quad \text{utilizando el hecho } e^{\ln} = 1 \text{ podemos}$$

$$\exp \{ \ln \phi^y + \ln (1-\phi)^{1-y} \} = \exp \{ y \ln \phi + \ln (1-\phi) - y \ln (1-\phi) \} \\ = \cancel{\exp \{ \ln (1-\phi) \}} \exp \{ y \ln \phi - y \ln (1-\phi) \} = (1-\phi) \exp \left\{ y \ln \left(\frac{\phi}{1-\phi} \right) \right\} \quad \checkmark$$

La manera general de una familia de funciones exponenciales tiene la forma:

$$* p(y; \eta) = b(y) g(\eta) \exp(\eta^T u(y)) \quad \text{en el contexto estadístico}$$

η = parámetro natural

$b(y)$ = parámetro conjunto entrenado

$u(y)$ = Datos de entrenamiento

$g(\eta)$ = Normalización, como la suma de las probabilidades estadísticas es 1

$$g(\eta) \int \underline{b(y) \exp \{ \eta^T u(y) \} dy} = 1 \quad \text{obteniendo} \quad \text{que la función de probabilidad}$$

$$p(y; \eta) = b(y) \exp \{ \eta^T u(y) - a(\eta) \} \quad \text{con} \quad g(\eta) = \frac{1}{\mathbb{I}}$$

$a(\eta) = -\log g(\eta)$ Con esto llegamos a la forma del documento

y comparando con la general $* \text{obtenemos } \eta = \log \left(\frac{\phi}{1-\phi} \right)$

$$e^{\eta} = \frac{\phi}{1-\phi} \quad \longrightarrow \quad 1-\phi e^{\eta} = \phi \quad 1 = \phi (1 + e^{\eta}) \quad \phi = \frac{1}{1 + e^{\eta}}$$

$$\phi = \frac{1}{1+e^{-\eta}} \rightarrow \text{funcion logistica}$$

$$p(y:\eta) = \left(1 - \frac{1}{1+e^{-\eta}}\right) e^{\eta} = \left(\frac{1+e^{-\eta}-1}{1+e^{-\eta}}\right) e^{\eta} = \frac{e^{(y-1)\eta}}{1+e^{-\eta}}$$

$$p(1:\theta^T x) = \frac{1}{1+e^{-\theta^T x}}$$

definimos entonces $h_{\theta}(x)$

$$h_{\theta}(x) = \frac{1}{1+e^{-\theta^T x}}$$

obtenemos entonces el complemento

$$p(y=0|x=x)$$

sera

$$p(y=0|x=x) = 1 - h_{\theta}(x) = 1 - \frac{1}{1+e^{-\theta^T x}} = \frac{1+e^{-\theta^T x}-1}{1+e^{-\theta^T x}} = \frac{e^{-\theta^T x}}{1+e^{-\theta^T x}}$$

Basandonos en los resultados anteriores escribimos la expresion para la verosimilitud con independencia tenemos

$$p(y^{(i)}|x^{(i)}, \theta) = h_{\theta}(x^{(i)})^{y^{(i)}} (1 - h_{\theta}(x^{(i)})^{1-y^{(i)}} \quad \text{si queremos tener } m$$

observaciones tendríamos la productoria **Likelihood**

$$L(\theta) = \prod_{i=1}^m h_{\theta}(x^{(i)})^{y^{(i)}} (1 - h_{\theta}(x^{(i)})^{1-y^{(i)}} \quad \text{apliquemos el logaritmo}$$

para obtener el log-verosimilitud

$$l(\theta) = \log \prod_{i=1}^m h_{\theta}(x^{(i)})^{y^{(i)}} (1 - h_{\theta}(x^{(i)})^{1-y^{(i)}} \quad \text{el } \log \prod_{i=1}^m = \sum_{i=1}^m \log$$

$$l(\theta) = \sum_{i=1}^n \log(h_{\theta}(x^{(i)})^{y^{(i)}} (1 - h_{\theta}(x^{(i)})^{1-y^{(i)}}) \quad \checkmark$$

$$= \sum_{i=1}^n y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \quad ; \text{multiplicamos}$$

$-\frac{1}{n}$ para cambiar el problema en uno de minimización así la funcion coste

$$J(\theta) = -\frac{1}{n} \sum_{i=1}^n y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \quad \checkmark$$

recordemos $h = h_{\theta}(x)$ y $z = \theta^T x$

$$\frac{\partial J}{\partial \theta_j} = \frac{\partial J}{\partial h} \frac{\partial h}{\partial z} \frac{\partial z}{\partial \theta_j}$$

para el caso de las derivadas tomaremos las funciones sin indices
entonces sea f :

$$f = y \log h + (1-y) \log(1-h) \rightarrow \frac{\partial f}{\partial h} = y \frac{1}{h} - (1-y) \frac{1}{1-h}$$

$$\frac{\partial f}{\partial h} = \frac{y}{h} - \frac{1-y}{1-h} = \frac{y - \cancel{yh} - \cancel{h} + \cancel{yh}}{h(1-h)} = \frac{y-h}{h(1-h)} \quad \text{aplicando la sugerencia}$$

$$\sigma'(z) = \sigma(z)(1-\sigma(z)) \quad \therefore \quad \frac{\partial h}{\partial z} = h(1-h) \quad \checkmark \quad z \text{ tiene la forma}$$

$$z = \theta_0 x_0 + \theta_1 x_1 + \dots \theta_j x_j + \dots \theta_n x_n \quad \frac{\partial z}{\partial \theta_j} = x_j \quad \text{asi pues tenemos}$$

$$\frac{\partial f}{\partial \theta_j} = \frac{y-h}{\cancel{h(1-h)}} \cancel{h(1-h)} x_j = (y-h)x_j \quad \checkmark \quad \text{volviendo a forma general}$$

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} \quad \checkmark ; \text{ con esta expresi3n}$$

obtenemos la actualizaci3n de parámetros

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j} \rightarrow \theta_j := \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} \quad \checkmark$$

Regularizaci3n vimos en el punto dos que para una regresi3n lineal

$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$, dado que queremos analizar con el término de penalizaci3n obtenemos

$$J_p(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^d \theta_j^2 \quad \text{con } d \text{ número de caracteristicas}$$

recordando que $h_{\theta}(x^{(i)}) = \theta^T x^{(i)}$

$$\begin{aligned} \frac{\partial J_p(\theta)}{\partial \theta_j} &= \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} + \frac{\lambda}{2m} \sum_{k=1}^d 2\theta_k \frac{\partial \theta_k}{\partial \theta_j} \\ &= \frac{1}{m} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \quad \text{veamos para } j=0 \end{aligned}$$

$$\frac{\partial J_p(\theta)}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)}) x_0^{(i)} \quad \text{notamos } \frac{\lambda}{m} \theta_j \quad j=0 \text{ no aparece pues este término es desde } j=1, \text{ ahora basandonos en la regla del descenso de gradiente el término de actualizaci3n del parámetro}$$

$$\theta_j := \theta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \right]$$

$$:= \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)}) x_j^{(i)} - \frac{\alpha \lambda}{m} \theta_j$$

$$\theta_j := \left(1 - \frac{\lambda}{m}\right) \theta_j - \frac{\lambda}{m} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)}) x_j^{(i)} \quad \text{analizamos} \quad *$$

como $\alpha, \lambda, m > 0$ pero asumiendo que $\frac{\lambda \alpha}{m} \neq 0$ y < 1 tenemos que el término $*$ será menor que 1 y por lo tanto en cada iteración θ_j se reduce hacia el cero y previene sobreajuste.

Pensando en la regresión logística podemos también incluir penalización

$$J_{rp}(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))] + \frac{\lambda}{2m} \sum_{j=1}^d \theta_j^2$$

$\frac{\partial J_{rp}(\theta)}{\partial \theta_j} \Rightarrow$ el primer término ya lo obtuvimos y el segundo igual en el punto anterior $\therefore$

$$\frac{\partial J_{rp}(\theta)}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m \left(\frac{1}{1 + e^{-\theta^T x^{(i)}}} - y^{(i)} \right) x_j^{(i)} + \frac{\lambda}{m} \theta_j \quad \text{para } j=0 \text{ tenemos que}$$

$$= \frac{1}{m} \sum_{i=1}^m \left(\frac{1}{1 + e^{-\theta^T x^{(i)}}} - y^{(i)} \right) x_0^{(i)} \quad \text{el término } \theta_0 \text{ solo realiza}$$

desplazamientos globales, no añade cambios significativos como oscilaciones o sobreajustes, si lo regularizamos obligamos al modelo a pasar (0,0) dañando la posición de este