

④ Regresión Lineal y Multivariada

Se busca modelar una variable continua Y (variable objetivo) a partir de unas variables de entrada X . El par $(x^{(i)}, y^{(i)})$ constituye una muestra de entrenamiento y el conjunto $D = \{(x^{(i)}, y^{(i)})\}_{i=1}^m$ constituye el conjunto de entrenamiento del problema.

$$\begin{cases} x_i \in X \\ y_i \in Y \end{cases}$$

Dado D , se busca encontrar una función $h: X \rightarrow Y$ de tal forma que $h(x)$ es una buena predicción del valor correspondiente y .

Supongamos que $y^{(i)} = \theta^T x^{(i)} + \epsilon^{(i)}$; $\epsilon^{(i)}$ representa efectos no modelados por la regresión, o ruido aleatorio.

Suponemos que $\epsilon^{(i)}$ es idénticamente e independientemente distribuido de acuerdo a una distribución Gaussiana: $\epsilon^{(i)} \sim N(0, \sigma^2)$

→ Término determinista

1. Para un valor específico $x^{(i)}$, $\theta^T x^{(i)}$ es constante y no influye en la naturaleza de la distribución de $y^{(i)}$, simplemente produce un desplazamiento en la distribución gaussiana del ruido. De esta forma:

$$y^{(i)} | X = x^{(i)} \sim N(-\theta^T x^{(i)}, \sigma^2)$$

2. $\epsilon^{(i)} \sim N(0, \sigma^2)$ significa que $p(\epsilon^{(i)}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(\epsilon^{(i)})^2}{2\sigma^2}\right)$

$$\leadsto p(y^{(i)} | x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$$

(→ distribución de $y^{(i)}$ dado $x^{(i)}$, parametrizado por θ .)

3. La función de likelihood se establece cuando, dado nuestro conjunto D , queremos determinar cuáles son los mejores parámetros θ :

$$L(\theta) = L(\theta; X, \tilde{y}) = p(\tilde{y} | X; \theta)$$

A diferencia de la probabilidad $p(\tilde{y} | X; \theta)$
= donde dado θ y $x^{(i)}$ buscamos y .

Si suponemos independencia estadística entre las observaciones, entonces:

$$L(\theta) = \prod_{i=1}^n p(y^{(i)} | x^{(i)}; \theta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$$

Los valores de θ se deben escoger de tal forma que nuestras datos tengan la mayor probabilidad posible. $\rightarrow$ Escoger θ de tal forma que $L(\theta)$ sea máxima.

4. Podemos calcular $l(\theta) = \log L(\theta)$ y maximizar esta función por simplicidad:

$$l(\theta) = \log L(\theta) = \log \left\{ \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp \left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right) \right\}$$

$$= \sum_{i=1}^n \log \left\{ \frac{1}{\sqrt{2\pi}\sigma} \exp \left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right) \right\}$$

$$= \sum_{i=1}^n \left\{ \log \left(\frac{1}{\sqrt{2\pi}\sigma} \right) + \log \left(\exp \left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right) \right) \right\}$$

$$= n \log \left(\frac{1}{\sqrt{2\pi}\sigma} \right) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y^{(i)} - \theta^T x^{(i)})^2$$

$\sim$ Término que depende de θ .

$\hookrightarrow$ Debido al signo negativo, debemos minimizar este término, que corresponde justamente a la función de costo de mínimos cuadrados, con $m = \sigma^2$.

8. El factor $1/2$, $1/m$ solo son constantes positivas por fuera del término θ , por lo que no cambian el minimizador.

//

② Gradiente y descenso por gradiente

Una vez construida la función de costo $J(\theta)$, el problema de aprendizaje constituye un problema de optimización. Para esto, se parte de un valor inicial de θ y se itera hasta llegar al mínimo de $J(\theta)$. El algoritmo de gradiente descendente se define de la siguiente forma:

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

$$\text{Con } J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$\begin{aligned} \text{1. } \frac{\partial h_{\theta}(x)}{\partial \theta_j} &= \frac{\partial}{\partial \theta_j} \left(\sum_{i=0}^d \theta_i x_i \right) ; \text{ pues definimos } h(x) = \sum_{i=0}^d \theta_i x_i = \theta^T x \\ &= x_i \delta_{ij} = x_j \end{aligned}$$

$$2. \frac{\partial J}{\partial \theta_j} = \frac{\partial}{\partial \theta_j} \left\{ \frac{1}{2} (h_{\theta}(x) - y)^2 \right\} = \frac{1}{2} \cdot 2 (h_{\theta}(x) - y) \cdot \frac{\partial h_{\theta}(x)}{\partial \theta}$$

$$\boxed{\frac{\partial J}{\partial \theta_j} = (h_{\theta}(x) - y) x_j}$$

y la actualización:

$$\theta_j := \theta_j + \alpha (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)}$$

3. Para el caso del m conjunto de datos, la escritura es directa:

$$\frac{\partial J}{\partial \theta_j} = \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j$$

4. y el algoritmo queda escrito como: $\theta_j := \theta_j + \alpha (y^{(i)} - h_{\theta}(x^{(i)}))$

5. La actualización para $j = 1, \dots, n$ queda como:

$$\theta_j := \theta_j + \alpha \sum_{i=1}^m (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)}, \text{ siendo } \theta \text{ un vector que contiene todos los } \theta_j$$

6. Se corre sobre el mismo i para actualizar de manera consistente.

③ Ecuación Normal

Para un conjunto de datos de entrenamiento, escribamos la matriz con sus valores:

$$X = \begin{bmatrix} 1 & x_1^{(1)} & \dots & x_n^{(1)} \\ 1 & x_1^{(2)} & \dots & x_n^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & \dots & x_n^{(m)} \end{bmatrix}$$

y el vector $\vec{y}$ que contiene las valores objetivo:

$$\vec{y} = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{bmatrix}$$

$$\Rightarrow J(\theta) = \frac{1}{2m} (X\theta - \vec{y})^T (X\theta - \vec{y})$$

$$a^T b = b^T a$$

$$\hookrightarrow (X\theta)^T \vec{y} = \vec{y}^T (X\theta)$$

$$1. (X\theta - \vec{y})^T (X\theta - \vec{y}) = \{ (X\theta)^T X\theta - (X\theta)^T \vec{y} - \vec{y}^T (X\theta) + \vec{y}^T \vec{y} \}$$

$$= \{ \theta^T (X^T X) \theta - 2 \vec{y}^T (X\theta) + \vec{y}^T \vec{y} \}$$

$$= \{ \theta^T (X^T X) \theta - 2 (X^T \vec{y})^T \theta + \vec{y}^T \vec{y} \}$$

2. Teniendo en cuenta que $\nabla_x b^T x = b$ y $\nabla_x x^T A x = 2Ax$

$$\begin{aligned} \Rightarrow \nabla_{\theta} J(\theta) &= \frac{1}{2n} \nabla_{\theta} (\theta^T (x^T x) \theta - 2(x^T \tilde{y})^T \theta + \tilde{y}^T \tilde{y}) \\ &= \frac{1}{2n} (2x^T x \theta - 2x^T \tilde{y}) = x^T x \theta - x^T \tilde{y} \end{aligned}$$

3-4. Imporemos $\nabla_{\theta} J(\theta) = 0$, lo que resulta en $x^T x \theta = x^T \tilde{y}$

5. Suponiendo que $(x^T x)$ es invertible: $\theta = (x^T x)^{-1} x^T \tilde{y}$
 $\theta = x^T \tilde{y} \rightarrow \boxed{y = \theta^T x}$

6. El método de descenso por gradiente es iterativo, mientras que este método corresponde a una solución analítica, siempre que X sea invertible.

X puede ser no invertible cuando no se cumple la independencia estadística

④ Regresión logística desde la familia exponencial //

1. En clasificación binaria, Y toma 2 valores posibles. La distribución de Bernoulli la podemos escribir como miembro de la familia exponencial.

Para $y \in \{0, 1\}$: $p(y; \varphi) = \varphi^y (1-\varphi)^{1-y}$; dado que $\ln e^x = x$, podemos hacer:

$$p(y; \varphi) = \exp \{ \log \{ \varphi^y (1-\varphi)^{1-y} \} \} = \exp \{ y \log \varphi + \log(1-\varphi) - y \log(1-\varphi) \}$$

$$p(y; \varphi) = \exp \{ \log(1-\varphi) \} \cdot \exp \{ y \log \varphi - y \log(1-\varphi) \}$$

$$p(y; \varphi) = (1-\varphi) \cdot \exp \left\{ y \log \left(\frac{\varphi}{1-\varphi} \right) \right\} \quad (4)$$

Una familia exponencial (de distribuciones de probabilidad) se puede escribir como:

$$p(y; \eta) = b(y) g(\eta) \exp \{ \eta \cdot T(y) \} \quad (2), \quad \text{con } \eta: \text{ parámetro natural}$$

$u(y)$: es el conjunto de entrenamiento
 $g(\eta)$: factor de normalización

De tal modo que:

$$g(\eta) \int b(y) \exp \{ \eta \cdot T(y) \} dy = 1 \rightarrow g(\eta) = \frac{1}{\int b(y) \exp \{ \eta \cdot T(y) \} dy}$$

↳ ② se puede escribir como:

$$p(y|\eta) = \frac{b(y) \exp\{\eta T(y)\}}{\int b(y) \exp\{\eta T(y)\} dy} = \frac{b(y) \exp\{\eta T(y)\}}{\exp\{\log(a(\eta))\}}$$

$$= b(y) \cdot \exp\{\eta T(y)\} \cdot \exp\{-\log(a(\eta))\} = b(y) \cdot \exp\{\eta T(y) - \log(a(\eta))\} \quad ③$$

Comparando ① con ② y teniendo en cuenta ③, obtenemos que:

④ $\eta = \log \frac{\psi}{1-\psi}$ parámetro natural.

↳

4. $e^\eta = \frac{\psi}{1-\psi} \Rightarrow \psi(1-e^\eta) = 1$

↳ $e^\eta - \psi e^\eta = \psi \Rightarrow \psi(1+e^\eta) = e^\eta \rightarrow \psi = \frac{1}{1+e^{-\eta}} \quad ⑤$

↳ función logística.

5. Definimos $\eta = \theta^T x$

→ $P(y=1|\psi) = (1-\psi) \cdot \exp\left\{\log\left(\frac{\psi}{1-\psi}\right)\right\}$ y reemplazamos ⑤:

$$P(y=1|\eta) = \left(1 - \frac{1}{1+e^{-\eta}}\right) \cdot e^\eta \quad y \quad \eta = \theta^T x$$

$$P(y=1|X=x) = \frac{1}{1+e^{-\theta^T x}} = h(\theta x) = g(\theta^T x)$$

7. Dado que Y solo toma 2 valores $\Rightarrow P_0(Y=0|X=x) = 1 - h_0(x)$

$$P_0(Y=0|X=x) = 1 - \frac{1}{1+e^{\theta^T x}} = \frac{e^{-\theta^T x}}{1+e^{-\theta^T x}} = \frac{1}{e^{\theta^T x} + 1}$$

5. Likelihood y Función de coste logística

1. Podemos escribir una única expresión para $p(y^{(i)} | x^{(i)}; \theta)$ en los resultados que ya conocemos:

$$P_{\theta}(Y=y | X=x) = h_{\theta}(x)^y (1 - h_{\theta}(x))^{1-y}, \quad \text{con } y = \{0, 1\}$$

2. Para un conjunto de m observaciones independientes, la función de likelihood es

$$\mathcal{L}(\theta) = p(\tilde{y} | X; \theta) = \prod_{i=1}^m p(y^{(i)} | x^{(i)}; \theta) = \prod_{i=1}^m (h_{\theta}(x^{(i)}))^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{1-y^{(i)}}$$

3. $l(\theta) = \log \mathcal{L}(\theta) = \sum_{i=1}^m \{y^{(i)} \log \{h_{\theta}(x^{(i)})\} + (1 - y^{(i)}) \log \{1 - h_{\theta}(x^{(i)})\}\}$

4. $J(\theta) = -\frac{1}{m} \sum_{i=1}^m \{y^{(i)} \log \{h_{\theta}(x^{(i)})\} + (1 - y^{(i)}) \log \{1 - h_{\theta}(x^{(i)})\}\}$

↳ Entropía cruzada binaria.

6.

Calculemos $\partial_{\theta_j} J$ para un solo ejemplo de entrenamiento:

$$\begin{aligned} \frac{\partial J(\theta)}{\partial \theta_j} &= y \cdot \frac{1}{g(\theta^T x)} \frac{\partial g(\theta^T x)}{\partial \theta} - \frac{(1-y)}{1-g(\theta^T x)} \frac{\partial g(\theta^T x)}{\partial \theta_j} \quad \left| \begin{array}{l} g(z) = (1+e^{-z})^{-1} \\ g'(z) = -(1+e^{-z})^{-2} \cdot e^{-z} \\ = \frac{1}{(1+e^{-z})} \cdot \left(1 - \frac{1}{(1+e^{-z})}\right) \\ = g(z) \cdot (1-g(z)) \end{array} \right. \\ &= \left\{ y \frac{1}{g(\theta^T x)} - (1-y) \cdot \frac{1}{1-g(\theta^T x)} \right\} \cdot g(\theta^T x) (1-g(\theta^T x)) \cdot \frac{\partial \theta^T x}{\partial \theta_j} \quad \left| \begin{array}{l} = g(z) \cdot (1-g(z)) \end{array} \right. \end{aligned}$$

$$= \{y(1-g(\theta^T x)) - (1-y)g(\theta^T x)\} x_j = (y - h_{\theta}(x)) x_j$$

$$\Rightarrow \text{para } m \text{ observaciones: } \frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

7. Para una sola observación, la regla de descenso por gradiente queda escrita como:

$$\theta_j := \theta_j + \alpha (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)}$$

y la actualización simultánea para todos los parámetros

$$\theta_j := \theta_j - \alpha \cdot \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

8. En la regresión lineal, el gradiente tiene la misma forma, la diferencia está en la función $h_0(x)$.

• En regresión lineal: $h_0(x) = \theta^T x$; en regresión logística: $h = \frac{1}{1 + e^{-\theta^T x}}$

⑥ Una forma de controlar modelos con parámetros grandes es añadir un factor de penalización a la función de coste. Esto para evitar problemas de overfitting. La idea es penalizar parámetros θ_j que sean muy grandes directamente en la función de coste. Si la regularización es de tipo L_2 , se penalizan fuertemente los valores grandes de θ_j pero se garantiza diferenciabilidad en todas partes, lo que es importante para el método de gradiente descendente.

1. Para regresión lineal, el coste regularizado queda como:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_0(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2; \text{ con } h_0(x) = \theta^T x$$

↳ El término θ_0 se excluye, pues solo da el intercepto.

2.
$$\frac{\partial}{\partial \theta_j} \left\{ \frac{1}{2m} \sum_{i=1}^m (h_0(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{k=1}^n \theta_k^2 \right\}$$

Para el primer término, ya conocemos el resultado:

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_0(x^{(i)}) - y^{(i)}) + \frac{\lambda}{m} \theta_j; \quad j \geq 1$$

3. Para el caso $j=0$, θ_0 no aparece en la regularización, entonces simplemente

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_0(x^{(i)}) - y^{(i)}) x_0^{(i)}$$

4. Aplicamos descenso por gradiente:

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j} = \theta_j - \alpha \left\{ \frac{1}{m} \sum_{i=1}^m (h_0(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \right\}; \quad j \geq 1$$

Para $j=0$, simplemente:
$$\theta_0 := \theta_0 - \alpha \cdot \frac{1}{m} \sum_{i=1}^m (h_0(x^{(i)}) - y^{(i)}) x_0^{(i)}$$

$$5. \quad \theta_j := \theta_j \left(1 - \frac{\alpha \lambda}{n}\right) - \alpha \cdot \underbrace{\frac{1}{n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}}_{\text{Término de datos.}}$$

Se conoce como weight decay.

$\lambda, m > 0$ y típicamente $\alpha \lambda < m \Rightarrow 0 < 1 - \frac{\alpha \lambda}{m} < 1$ (no depende de los datos)

6. En cada iteración del método de descenso por gradiente, θ_j se ve reducido hacia cero, llevando el modelo hacia parámetros más pequeños.