

*) T[al] pr.

(1)

1) Regresión lineal multivariada desde máxima verosimilitud

x) En Regresión lineal se busca modelar una variable continua Y a partir de variables de entrada X . Una forma natural de hacerlo es suponer que la salida observada es la formada por una parte determinista, $\theta^T X$, más una fluctuación aleatoria.

Considerar:

$$D = \{ (X^{(i)}, y^{(i)}) \}_{i=1}^M$$

con:

$$X^{(i)} = \begin{bmatrix} 1 \\ x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix}, \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}$$

Suponga que:

$$y^{(i)} = \theta^T X^{(i)} + \epsilon^{(i)} \quad \epsilon^{(i)} \sim \mathcal{N}(0, \sigma^2)$$

La hipótesis gaussiana permite construir una distribución para Y a partir de ella, una función de verosimilitud para los datos observados.

1) Determinar la distribución de $y^{(i)} | X = X^{(i)}$

Solución primer numeral:

Partimos de: $y^{(i)} = \theta^T X^{(i)} + \epsilon^{(i)}$

donde: $\epsilon^{(i)} \sim \mathcal{N}(0, \sigma^2)$

(2)

Como $x^{(i)}$ es conocido y θ se considera fijo, el término

$\theta^T x^{(i)}$ se considera una constante. Entonces $y^{(i)}$ es una variable normal desplazada por esa constante

La propiedad que se usa es:

$$\epsilon \sim N(0, \sigma^2) \Rightarrow a + \epsilon \sim N(a, \sigma^2)$$

Por lo tanto:

$$y^{(i)} | x = x^{(i)} \sim N(\theta^T x^{(i)}, \sigma^2)$$

Identifiquemos la media:

$$E[y^{(i)} | x = x^{(i)}] = \theta^T x^{(i)}$$

Por lo que se tiene que:

$$E[y^{(i)} | x = x^{(i)}] = E[\theta^T x^{(i)} + \epsilon^{(i)}] = \theta^T x^{(i)} + E[\epsilon^{(i)}], \text{ pero:}$$

$$\epsilon^{(i)} \sim N(0, \sigma^2) \text{ Así que: } E[\epsilon^{(i)}] = 0$$

$$\text{Así que: } E[y^{(i)} | x = x^{(i)}] = \theta^T x^{(i)}$$

*) podemos calcular la varianza:

$$\text{Var}(y^{(i)} | x = x^{(i)}) = \text{Var}(\theta^T x^{(i)} + \epsilon^{(i)}) = \text{Var}(\epsilon^{(i)} + \theta^T x^{(i)}) = \text{Var}(\epsilon^{(i)}) = \sigma^2$$

Demostremos:

$$\text{Var}(\epsilon^{(i)} + \theta^T x^{(i)}) = \text{Var}(\theta^T x^{(i)} + \epsilon^{(i)}) = E[(\theta^T x^{(i)} + \epsilon^{(i)} - E[\theta^T x^{(i)} + \epsilon^{(i)}])^2]$$

$$\text{Var}(\epsilon^{(i)} + \theta^T x^{(i)}) = E[(\theta^T x^{(i)} + \epsilon^{(i)} - E[\epsilon^{(i)}] - \theta^T x^{(i)})^2]$$

$$\text{Var}(\epsilon^{(i)} + \theta^T x^{(i)}) = E[(\epsilon^{(i)} - E[\epsilon^{(i)}])^2] = \text{Var}(\epsilon^{(i)}) = \sigma^2$$

Interpretación:

$$y^{(i)} | x = x^{(i)} \sim N(\theta^T x^{(i)}, \sigma^2)$$

El modelo dice que los valores de y se distribuyen alrededor de la predicción lineal

$h_\theta(x^{(i)}) = \theta^T x^{(i)}$ y σ^2 mide que tanto se dispersan los datos alrededor de esa predicción

(3)

2) de este punto 1 obtenemos:

$$y^{(i)} | x = x^{(i)} \sim N(\theta^T x^{(i)}, \sigma^2)$$

* La densidad de probabilidad general de una distribución normal con media μ y varianza σ^2 es

$$p(y) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y-\mu)^2}{2\sigma^2}}$$

En nuestro problema

$$\mu = \theta^T x^{(i)}$$

Además estamos evaluando la densidad en el valor $y^{(i)}$ entonces sustituimos:

$$y \rightarrow y^{(i)}$$

$$y$$

$$\mu \rightarrow \theta^T x^{(i)}$$

Así obtenemos:

$$p(y^{(i)} | x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}}$$

también podemos escribirlo como:

$$p(y^{(i)} | x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}}$$

¿Qué significa esta expresión?

Esta fórmula nos dice qué tan compatible es el dato observado $y^{(i)}$ con una determinada elección de los parámetros

• Nuestro modelo predice $\hat{y}^{(i)} = \theta^T x^{(i)}$

El dato real es $y^{(i)}$

(4)

por lo tanto:

$$y^{(i)} - \hat{y}^{(i)} = y^{(i)} - \theta^T x^{(i)}$$

es el residuo, es decir, la diferencia entre lo que realmente observamos y lo que predice el modelo.

$$\text{Si } y^{(i)} \approx \theta^T x^{(i)}$$

El exponente está cerca de cero y la densidad es grande. El dato es bastante compatible con el modelo.

Ahora si

$$(y^{(i)} - \theta^T x^{(i)})^2 \gg 0$$

Entonces: $e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}}$ se hace pequeño. El dato es menos compatible. La

densidad es menor.

3) Suponiendo independencia entre observaciones construya

$$L(\theta)$$

x) construya la función de verosimilitud.

La tenemos para una sola observación x

$$p(y^{(i)} | x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}}$$

Ahora el conjunto de datos tiene M observaciones

$$D = \{(x^{(i)}, y^{(i)})\}_{i=1}^M$$

El ejercicio dice que las observaciones son independientes, la probabilidad conjunta de observar todas las variables $y^{(1)} \dots y^{(M)}$ es el producto de las probabilidades individuales.

(5)

La función de verosimilitud se define:

$$L(\theta) = P(D, \theta) = P(y^{(1)}, y^{(2)}, \dots, y^{(n)} | x^{(1)}, \dots, x^{(n)}; \theta)$$

Si suponemos independencia entre las observaciones entonces:

$$P(y^{(1)}, y^{(2)}, \dots, y^{(n)} | x^{(1)}, \dots, x^{(n-1)}, x^{(n)}) = P(y^{(1)} | x^{(1)}) \dots P(y^{(n-1)} | x^{(n-1)}) P(y^{(n)} | x^{(n)})$$

$$P(y^{(1)}, y^{(2)}, \dots, y^{(n)} | x^{(1)}, \dots, x^{(n)}) = \prod_{i=1}^n P(y^{(i)} | x^{(i)}; \theta)$$

Entonces:

$$L(\theta) = \prod_{i=1}^n P(y^{(i)} | x^{(i)}; \theta)$$

Sustituimos la expresión del ítem 2 y obtenemos:

$$L(\theta) = \prod_{i=1}^n \left[\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}} \right]$$

Separamos el producto de factores:

$$\prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n = \left(\frac{1}{\sqrt{2n\sigma^2}} \right)^n$$

Además el producto de exponenciales se convierte en una exponencial de la suma:

$$\prod_{i=1}^n e^{a_i} = e^{\sum_{i=1}^n a_i}$$

por lo tanto:

$$L(\theta) = \left(\frac{1}{\sqrt{2n\sigma^2}} \right)^n e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y^{(i)} - \theta^T x^{(i)})^2}$$

$$L(\theta) = \left(\frac{1}{\sqrt{2n\sigma^2}} \right)^n e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y^{(i)} - \theta^T x^{(i)})^2}$$

$$l(\theta) = \frac{1}{(2\pi\sigma^2)^{M/2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^M (y^{(i)} - \theta^T x^{(i)})^2} \quad (6)$$

Esta es la función de verosimilitud

La idea física y matemática es la siguiente: $l(\theta)$ mide que tan compatibles son todos los datos observados con una elección de θ

Si θ produce predicciones muy cercanas a los datos

$$\theta^T x^{(i)} \approx y^{(i)}$$

Entonces los residuos son pequeños y la verosimilitud es grande. De otro modo la función disminuye.

4) Obtenga

$$\ell(\theta) = \log l(\theta)$$

partiendo de:

$$l(\theta) = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^M e^{-\frac{1}{2\sigma^2} \sum_{i=1}^M (y^{(i)} - \theta^T x^{(i)})^2}$$

Definimos:

$$\ell(\theta) = \log l(\theta)$$

$$\ell(\theta) = \log \left[\left(\frac{1}{\sqrt{2\pi}\sigma} \right)^M e^{-\frac{1}{2\sigma^2} \sum_{i=1}^M (y^{(i)} - \theta^T x^{(i)})^2} \right]$$

$$\ell(\theta) = \log \left[\left(\frac{1}{\sqrt{2\pi}\sigma} \right)^M \right] - \frac{1}{2\sigma^2} \sum_{i=1}^M (y^{(i)} - \theta^T x^{(i)})^2$$

$$\ell(\theta) = M \log \left(\frac{1}{\sqrt{2\pi}\sigma} \right) - \frac{1}{2\sigma^2} \sum_{i=1}^M (y^{(i)} - \theta^T x^{(i)})^2$$

$$\ell(\theta) = -M \log(\sqrt{2\pi}\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^M (y^{(i)} - \theta^T x^{(i)})^2$$

$$\ell(\theta) = -M \left[\frac{1}{2} \log(2\pi) + \log(\sigma) \right] - \frac{1}{2\sigma^2} \sum_{i=1}^M (y^{(i)} - \theta^T x^{(i)})^2$$

$$\ell(\theta) = -\frac{M}{2} \log(2\pi) - M \log(\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^M (y^{(i)} - \theta^T x^{(i)})^2$$

también es muy común escribir

7

$$\ell(\theta) = -\frac{M}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^M (y(i) - \theta^T x(i))^2$$

5) Identificar los términos que dependen de θ

Ahora analizamos cada término:

El primer es $-\frac{M}{2} \log(2\pi\sigma^2)$

Este término es una constante no depende de θ

Ahora observamos el segundo

$$-\frac{1}{2\sigma^2} \sum_{i=1}^M (y(i) - \theta^T x(i))^2$$

Este término contiene toda la parte de θ

6) Demostremos que maximizar la log-Verosimilitud equivale a minimizar la suma de los

Residuos Cuadrados

Partimos de la parte de la log-Verosimilitud que depende de θ

$$\ell(\theta) = \text{Constante} - \frac{1}{2\sigma^2} \sum_{i=1}^M (y(i) - \theta^T x(i))^2$$

Definamos la suma de Residuos Cuadrados

$$S(\theta) = \sum_{i=1}^M (y(i) - \theta^T x(i))^2$$

Entonces el log Verosimilitud puede escribirse como:

$$\ell(\theta) = \text{Constante} - \frac{1}{2\sigma^2} S(\theta)$$

Observamos directamente.

②

$$\sigma^2 > 0$$

Entonces

$$\frac{1}{2\sigma^2} > 0$$

delante este término hay un signo negativo.

$$-\frac{1}{2\sigma^2} S(\theta)$$

Significa que cuando $S(\theta)$ aumenta $J(\theta)$ disminuye y cuando $S(\theta)$ disminuye, $J(\theta)$ aumenta

por ejemplo si dos valores de θ producen $J(\theta) = \text{constante} - \frac{1}{2\sigma^2} S(\theta)$

$$S(\theta_1) = 2 \wedge S(\theta_2) = 10$$

$$-\frac{1}{2\sigma^2} S(\theta_1) > -\frac{1}{2\sigma^2} S(\theta_2)$$

por tanto θ_1 tendría una mayor verosimilitud

$\text{avg max}_{\theta} J(\theta) = \text{avg max}_{\theta} \left[-\frac{1}{2\sigma^2} S(\theta) \right]$ multiplicado por una constante negativa cambia
maximización por minimización

$$\text{avg max}_{\theta} \left[-\frac{1}{2\sigma^2} S(\theta) \right] = \text{avg min}_{\theta} S(\theta)$$

$$\text{avg max}_{\theta} J(\theta) = \text{avg min}_{\theta} \sum_{i=1}^M (y(i) - \theta^T x(i))^2$$

Entonces:

$$\text{avg max}_{\theta} J(\theta) = \text{avg min}_{\theta} \sum_{i=1}^M (\theta^T x(i) - y(i))^2$$

La conclusión conceptual:

bajo la hipótesis de errores gaussianos, buscar los parámetros más probables es más o menos

verosimilitud conduce exactamente a la misma cuestión que minimizar la suma de errores al cuadrado.

7) Obtenga una función de costo de la forma:

$$J(\theta) = \frac{1}{2M} \sum_{i=1}^M (h(\theta; x) - y(i))^2$$

Del punto 6 obtenimos que: Maximizar la verosimilitud equivale a minimizar

$$\sum_{i=1}^M (\theta^T x^{(i)} - y^{(i)})$$

Ahora definimos la hipótesis de regresión lineal:

$$h_{\theta}(x^{(i)}) = \theta^T x^{(i)}$$

Substituyendo en la suma de residuos cuadradas:

$$\sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Para construir una función de costo conveniente dividimos por $2M$

$$J(\theta) = \frac{1}{2M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

* 8) Explicación

El factor $1/M$ hacemos que otras trabajando con un valor cuadrático promedio en lugar de una suma que crece porque tenemos más datos. El factor $1/2$ se introduce por conveniencia matemática

Cuando derivamos un término cuadrático

$$\frac{d}{dz} z^2 = 2z$$

De 2 se cancela con el $1/2$ por eso los derivados quedan más limpios

Explicación detallada:

$$S(\theta) = \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$J(\theta) = \frac{1}{2M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

(10)

Si $\exists \theta_1, \theta_2$ tal que:

$$S(\theta_1) < S(\theta_2) \wedge \frac{1}{2m} > 0$$

$$\text{Entonces } \frac{1}{2m} S(\theta_1) < \frac{1}{2m} S(\theta_2) \Leftrightarrow J(\theta_1) < J(\theta_2)$$

por lo tanto:

$$\underset{\theta}{\operatorname{argmin}} S(\theta) = \underset{\theta}{\operatorname{argmin}} J(\theta)$$

Los factores $\frac{1}{2}$ y $\frac{1}{m}$ No cambian el minimizador puesto son constantes positivas con respecto a θ