

## 2) Gradiente y descenso por gradiente: (1)

Una vez construida  $J(\theta)$ , el aprendizaje puede verse como un problema de optimización.

El gradiente indica cómo cambia el coste cuando cambia cada parámetro, y permite construir una regla iterativa para encontrar valores de  $\theta$  que reduzcan el error.

X) tenemos la hipótesis de regresión lineal

$$h_{\theta}(x^{(i)}) = \theta^T x^{(i)}$$

$$h_{\theta}(x^{(i)}) = [\theta_0, \theta_1, \dots, \theta_n] \begin{bmatrix} x_0^{(i)} \\ x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$$

$$h_{\theta}(x^{(i)}) = x_0^{(i)} \theta_0 + \theta_1 x_1^{(i)} + \dots + \theta_n x_n^{(i)}$$

para  $j=0$   $x_0^{(i)} = 1$

$$\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_0} = 1$$

$$\frac{\partial \theta_0}{\partial \theta_0}$$

$$h_{\theta}(x^{(i)}) = 1 + \theta_1 x_1^{(i)} + \theta_2 x_2^{(i)} + \dots + \theta_n x_n^{(i)}$$

Ahora:

$$\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} = ? \quad h_{\theta}(x^{(i)}) = 1 + \theta_1 x_1^{(i)} + \theta_2 x_2^{(i)} + \dots + \theta_n x_n^{(i)}$$

$$\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} = x_j^{(i)} \quad \text{R/}$$

(2) Usar la regla de la cadena para hallar

$$\frac{\partial J}{\partial \theta_j} = \frac{\partial J}{\partial \theta_j} \left[ \frac{1}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)})^2 \right]$$

$$\frac{\partial J}{\partial \theta_j} = 2 \cdot \frac{1}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) \frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} = \frac{1}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) x_j = \frac{\partial J}{\partial \theta_j}$$

Paso 3: Escribiremos el resultado como una suma sobre los  $m$  datos

Resultado general:

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

De forma explícita tenemos:

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} [(h_{\theta}(x^{(1)}) - y^{(1)}) x_j^{(1)} + (h_{\theta}(x^{(2)}) - y^{(2)}) x_j^{(2)} + \dots + (h_{\theta}(x^{(m)}) - y^{(m)}) x_j^{(m)}]$$

Podemos tenerlo a terminos:

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) (1)$$

$$\frac{\partial J}{\partial \theta_1} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_1^{(i)}$$

$$\frac{\partial J}{\partial \theta_2} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_2^{(i)}$$

⋮

$$\frac{\partial J}{\partial \theta_n} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_n^{(i)}$$

En forma vectorial

$$\nabla J(\theta) = \begin{bmatrix} \frac{\partial J}{\partial \theta_0} \\ \frac{\partial J}{\partial \theta_1} \\ \vdots \\ \frac{\partial J}{\partial \theta_n} \end{bmatrix} = \frac{1}{m} \begin{bmatrix} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) (1) \\ \vdots \\ \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_n^{(i)} \end{bmatrix}$$

(3)

4) Construya:

$$\theta_j = \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$$

Del punto 3 obtenemos

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

Ahora simplemente sustituimos esta derivada en la regla general.

$$\theta_j := \theta_j - \alpha \left[ \frac{1}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} \right]$$

$$\theta_j := \theta_j - \frac{\alpha}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

En forma vectorial

$$\theta := \theta - \frac{\alpha}{M} X^T (X\theta - y)$$

La expresión significa que cada parámetro  $\theta_j$  se corrige en la dirección opuesta al gradiente porque el gradiente señala la dirección de mayor aumento  $J(\theta)$  y nosotros queremos disminuir el costo, por eso aparece el signo negativo  $-\alpha \frac{\partial J}{\partial \theta_j}$ . Si  $\alpha$  es muy grande, la actualización puede

pasarse del mínimo. Si es muy pequeña, el aprendizaje puede ser muy lento.

5) Escribiremos la actualización para:

$$\theta_0 := \theta_0 - \frac{\alpha}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)}$$

$$\theta_0 := \theta_0 - \frac{\alpha}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) (1) \quad \checkmark$$

(4)

$$\theta_1 := \theta_1 - \frac{\alpha}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) x_{1,i} \quad j=1$$

$$\theta_2 := \theta_2 - \frac{\alpha}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) x_{2,i} \quad j=2$$

$$\theta_n := \theta_n - \frac{\alpha}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) x_{n,i}$$

¿Qué estamos haciendo en cada iteración?

tenemos unos parámetros

$\theta_0, \theta_1, \dots, \theta_n$  actuales

con ellos calculamos

$$h_{\theta}(x^{(i)})$$

calculamos los errores

$$h_{\theta}(x^{(i)}) - y^{(i)}$$

a) con esos errores calculamos el gradiente

$\frac{\partial J}{\partial \theta_j}$  y finalmente modificamos cada parámetro en dirección opuesta al gradiente.

$$\theta_j^{\text{nuevo}} = \theta_j^{\text{viejo}} - \alpha \frac{\partial J}{\partial \theta_j}$$

Esto se repite iterativamente buscando reducir  $J(\theta)$ .

b) por que los parámetros deben actualizarse simultáneamente

$$\theta_j^{\text{nuevo}} = \theta_j^{\text{viejo}} - \alpha \frac{\partial J(\theta^{\text{viejo}})}{\partial \theta_j}$$

porque todas las componentes del gradiente deben calcularse en el mismo punto del espacio

de parámetros

5

Supongamos por simplicidad:

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \end{bmatrix}$$

$$\theta^{(k)} = \begin{bmatrix} \theta_0^{(k)} \\ \theta_1^{(k)} \end{bmatrix}$$

Calculamos el gradiente en ese punto:

$$\nabla J(\theta^{(k)}) = \begin{bmatrix} \frac{\partial J}{\partial \theta_0} \\ \frac{\partial J}{\partial \theta_1} \end{bmatrix}_{\theta = \theta^{(k)}}$$

Entonces la actualización correcta es:

$$\theta_0^{(k+1)} = \theta_0^{(k)} - \alpha \frac{\partial J(\theta^{(k)})}{\partial \theta_0}$$

$$\theta_1^{(k+1)} = \theta_1^{(k)} - \alpha \frac{\partial J(\theta^{(k)})}{\partial \theta_1}$$

} se actualizan por el mismo punto del espacio de parámetros.