

①

x) punto 5:

Likelihood y función de costo logística:

Una vez obtenida $h_{\theta}(x)$, cada observación puede interpretarse probabilísticamente.Para $y=1$ el modelo asigna una probabilidad $h_{\theta}(x)$; para $y=0$ asigna $1-h_{\theta}(x)$.

A partir de ambas probabilidades se construye una única expresión para la verosimilitud

1) Escriba una expresión única para

$$p(y^{(i)} | x^{(i)}; \theta) = ?$$

partiendo de la hipótesis logística:

$$h_{\theta}(x) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

Además

$$p_{\theta}(Y=1 | X=x) = h_{\theta}(x)$$

$$p_{\theta}(Y=0 | X=x) = 1 - h_{\theta}(x)$$

Queremos una sola fórmula que funcione para $y^{(i)}=1$ como para $y^{(i)}=0$

La expresión es:

$$p(y^{(i)} | x^{(i)}; \theta) = [h_{\theta}(x^{(i)})]^{y^{(i)}} [1 - h_{\theta}(x^{(i)})]^{1-y^{(i)}}$$

Veremos si funciona

$$\text{Si } y^{(i)}=1 \quad p(y^{(i)} | x^{(i)}; \theta) = h_{\theta}(x^{(i)})$$

$$\text{Si } y^{(i)}=0 \quad p(y^{(i)} | x^{(i)}; \theta) = 1 - h_{\theta}(x^{(i)})$$

para ambas clases la fórmula funciona

*)

⑦

2) Construye la Verosimilitud para m observaciones

*) Suponiendo que las observaciones son independientes, la Verosimilitud es el producto de las probabilidades individuales

$$L(\theta) = \prod_{i=1}^m p(y_i | x_i; \theta)$$

Sustituyendo la expresión anterior presentada

$$L(\theta) = \prod_{i=1}^m [h_{\theta}(x_i)]^{y_i} [1 - h_{\theta}(x_i)]^{1-y_i}$$

*) Esta función mide que tan probable es observar todos los datos para un valor de θ

2) Calcular la Log-Verosimilitud

Definimos:

$$\ell(\theta) = \log L(\theta)$$

$$\ell(\theta) = \log \left[\prod_{i=1}^m [h_{\theta}(x_i)]^{y_i} [1 - h_{\theta}(x_i)]^{1-y_i} \right] \quad \text{Usamos} \quad \log \left(\prod_{i=1}^m a_i \right) = \sum_{i=1}^m \log(a_i)$$

$$\ell(\theta) = \sum_{i=1}^m \log [h_{\theta}(x_i)^{y_i} (1 - h_{\theta}(x_i))^{1-y_i}]$$

$$\ell(\theta) = y_i \log(h_{\theta}(x_i)) + (1 - y_i) \log(1 - h_{\theta}(x_i))$$

4) Cambiar el signo y normalizar por m para obtener $J(\theta)$

En máxima Verosimilitud queremos maximizar $\ell(\theta)$

Para normalizar los algoritmos de optimización se escriben como problemas de minimización

$$J(\theta) = -\frac{1}{m} \ell(\theta)$$

3

• Sustituyendo:

$$J(\theta) = \frac{1}{M} \sum_{i=1}^M \left[y^{(i)} \log h_{\theta}(x^{(i)}) + (1-y^{(i)}) \log (1-h_{\theta}(x^{(i)})) \right]$$

podemos escribir el coste para una sola observación como

$$\text{Cost}(h_{\theta}(x^{(i)}), y^{(i)}) = - \left[y^{(i)} \log h_{\theta}(x^{(i)}) + (1-y^{(i)}) \log (1-h_{\theta}(x^{(i)})) \right]$$

y entonces:

$$J(\theta) = \frac{1}{M} \sum_{i=1}^M \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)})$$

5) Identificar la entropía cruzada binaria.

• La expresión $-[y \log(p) + (1-y) \log(1-p)]$ es precisamente la entropía cruzada binaria. En nuestro modelo $p = h_{\theta}(x)$

por tanto

$$\text{BCE} = -[y \log h_{\theta}(x) + (1-y) \log (1-h_{\theta}(x))]$$

y la función total es el promedio

$$J(\theta) = \frac{1}{M} \sum_{i=1}^M \text{BCE}^{(i)}$$

La idea:

6) calcular $\frac{\partial J}{\partial \theta}$

$$J(\theta) = \frac{1}{M} \sum_{i=1}^M \left[y^{(i)} \log h_{\theta}(x^{(i)}) + (1-y^{(i)}) \log (1-h_{\theta}(x^{(i)})) \right]$$

para simplificar $h_i = h_{\theta}(x^{(i)})$

(4)

Entropy:

$$J(\theta) = -\frac{1}{n} \sum_{i=1}^n [y^{(i)} \log h_i + (1-y^{(i)}) \log (1-h_i)]$$

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{n} \sum_{i=1}^n \frac{\partial}{\partial \theta_j} [y^{(i)} \log h_i + (1-y^{(i)}) \log (1-h_i)]$$

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{n} \sum_{i=1}^n \left[y^{(i)} \frac{1}{h_i} \frac{\partial h_i}{\partial \theta_j} + (1-y^{(i)}) \frac{1}{1-h_i} (-1) \frac{\partial h_i}{\partial \theta_j} \right]$$

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{n} \sum_{i=1}^n \left[\frac{y^{(i)}}{h_i} - \frac{(1-y^{(i)})}{1-h_i} \right] \frac{\partial h_i}{\partial \theta_j}$$

Above Numpy Calculus

$$\frac{\partial h_i}{\partial \theta_j} \quad h_i = \sigma(\theta^T x^{(i)})$$

$$1 - \frac{1}{1+e^{-z}} = \frac{1+e^{-z}}{1+e^{-z}} = \frac{e^{-z}}{1+e^{-z}} = \frac{1}{e^z+1}$$

$$z_i = \theta^T x^{(i)}, \quad h_i = \sigma(z_i)$$

$$\frac{\partial h_i}{\partial \theta_j} = \frac{\partial h_i}{\partial z} \cdot \frac{\partial z_i}{\partial \theta_j} = \sigma'(z_i) \frac{\partial z_i}{\partial \theta_j}$$

$$\sigma(z) = \frac{1}{1+e^{-z}}, \quad \sigma'(z) = \frac{-(-1)e^{-z}}{(1+e^{-z})^2} = \frac{e^{-z}}{(1+e^{-z})^2} = \frac{e^{-z}}{(1+e^{-z})} \cdot \frac{1}{(1+e^{-z})}$$

$$= \frac{1}{(1+e^{-z})} \left[\frac{1}{e^z(1+e^{-z})} \right] = \frac{1}{(1+e^{-z})} \left[\frac{1}{1+e^z} \right] = \frac{1}{(1+e^{-z})} \left[1 - \frac{1}{1+e^{-z}} \right]$$

$$= \sigma(z)(1-\sigma(z))$$

$$\sigma'(z_i) = h_i(1-h_i)$$

x) Admés,

①

$$\bullet \quad z_i = \theta^T X^{(i)} = \sum_{k=0}^n \theta_k X_k^{(i)}$$

$$\frac{\partial z_i}{\partial \theta_j} = \sum_{k=0}^n \frac{\partial \theta_k}{\partial \theta_j} X_k^{(i)} = \sum_{k=0}^n \delta_{kj} X_k^{(i)} = X_j^{(i)}$$

Así

$$\frac{\partial h_i}{\partial \theta_j} = h_i(1-h_i) X_j^{(i)}$$

Substituyendo

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{n} \sum_{i=1}^n \left[\frac{y^{(i)}}{h_i} - \frac{1-y^{(i)}}{1-h_i} \right] h_i(1-h_i) X_j^{(i)}$$

$$\bullet = -\frac{1}{n} \sum_{i=1}^n \left[y^{(i)} [1-h_i] - (1-y^{(i)}) h_i \right] X_j^{(i)}$$

$$y^{(i)} - y^{(i)} h_i - h_i + y^{(i)} h_i = y^{(i)} - h_i$$

por lo tanto:

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{n} \sum_{i=1}^n (y^{(i)} - h_i) X_j^{(i)}$$

$$\frac{\partial J}{\partial \theta} = -\frac{1}{n} \sum_{i=1}^n (h_i - y^{(i)}) X_j^{(i)}$$

⑦ Regla de descenso por gradiente:

$$\bullet \quad \theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$$

Substituyendo el gradiente

$$\frac{1}{n} X^T (\theta - y) = 0$$

(6)

Substituyendo el gradiente:

$$\theta_j := \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_{j,i}$$

para $j = 0, 1, 2, \dots, n$

Las actualizaciones deben hacerse simultaneamente

En forma Vectorial

$$\theta^{(k+1)} = \theta^{(k)} - \frac{\alpha}{m} X^T (h_{\theta}(X) - y)$$

Donde $h_{\theta}(X)$ representa el vector de probabilidades predichas.

X) Comparar el gradiente con convergencia lineal

En Regresión lineal hechas las siguientes:

$$\frac{\partial J_{lin}}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_{j,i}$$

En regresión logística necesitamos de obtener

$$\frac{\partial J_{log}}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_{j,i}$$

La forma Algebraica es la misma pero no significa que ambos modelos sean iguales

La diferencia esta en:

para regresión lineal $h_{\theta}(x) = \theta^T x$

mientras para regresión logística

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

generando el 3 parametro

4)

Además las funciones de costo son distintas

$$J_{\text{lin}}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 \quad \rightarrow \text{Regresión lineal}$$

Regresión logística

$$J_{\text{log}}(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)}))]$$

Así que tenemos la coincidencia:

$\nabla J_{\text{lineal}} \quad \nabla J_{\text{logística}}$ tienen la misma estructura

$$\frac{1}{m} \sum_i (\text{predicción} - \text{valor real}) X_j(i)$$

En regresión lineal

$$\boxed{\text{predicción} = \theta^T x}$$

Regresión logística

$$\boxed{\text{predicción} = \sigma(\theta^T x)}$$