

6)

①

Regularización

Un buen Ajuste sobre los datos de entrenamiento no garantiza necesariamente una buena generalización. Una buena forma de controlar modelos con parámetros grandes es añadir una penalización a la función de costo. para regularización L_2 ,

$$\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

El parámetro λ controla cuánto pesa esta penalización frente al ajuste de los datos

1) Costo Regularizado para regresión lineal.

En regresión lineal tenemos:

$$J_{\text{datos}}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Con $h_{\theta}(x) = \theta^T x$

Ahora añadimos la penalización L_2 :

$$\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

por lo tanto la nueva función de costo es

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

podemos pensar de como:

$$J(\theta) = J_{\text{datos}}(\theta) + J_{\text{reg}}(\theta)$$

$$\text{donde } J_{\text{reg}}(\theta) = \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

! El primer término intenta ajustar bien los datos y

el segundo evita que los parámetros θ_j se hagan

excesivamente grandes.

(2)

2) calculăm $\frac{\partial J}{\partial \theta_j}$ pentru $j \geq 1$

primul de:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{k=1}^n \theta_k^2$$

Derivăm:

$$\frac{\partial J}{\partial \theta_j} = \frac{\partial J_{\text{data}}}{\partial \theta_j} + \frac{\partial J_{\text{reg}}}{\partial \theta_j}$$

De la exercitiu anterior se bazează urm:

$$\frac{\partial J_{\text{data}}}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

Ahora derivăm de la termen de regularizare:

$$\frac{\partial}{\partial \theta_j} \left[\frac{\lambda}{2m} \sum_{k=1}^n \theta_k^2 \right]$$

Succesul la constantă:

$$= \frac{\lambda}{2m} \frac{\partial}{\partial \theta_j} [\theta_1^2 + \theta_1^2 + \theta_1^2 + \theta_n^2] = \frac{\lambda}{2m} \frac{\partial \theta_j^2}{\partial \theta_j} = \frac{\lambda}{2m} \cdot 2\theta_j = \frac{\lambda}{m} \theta_j$$

pentru $j \geq 1$ se ține seama:

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j$$

Este ci el gradienta regularizată de regresia liniară.

3) caso $\lambda = 0$

3)

La penalización es:

$$\frac{\lambda}{2m} \sum_{i=1}^n \theta_i^2$$

No contiene θ_0 por tanto, $\frac{\partial J_{reg}}{\partial \theta_0} = 0$

Así que:

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_0^{(i)}$$

$$x_0^{(i)} = 1$$

Obtenemos

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) \quad \text{No aparece } \frac{\lambda \theta_0}{m}$$

4) Actualización para $j \geq 1$

La regla del descenso por gradiente es:

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$$

Sustituimos el gradiente que acabamos de obtener:

$$\theta_j := \theta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \right]$$

$$\theta_j := \theta_j - \alpha \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda \alpha}{m} \theta_j$$

$$\theta_j := \theta_j - \frac{\alpha \lambda}{m} \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)} \quad j = 1, \dots, n$$

4

Reorganizar la actualización

tenemos:

$$\theta_j = \theta_j - \frac{\alpha \lambda}{m} \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

Los dos primeros términos contienen θ_j

$$\theta_j - \frac{\alpha \lambda}{m} \theta_j$$

Factorizamos

$$\theta_j \left(1 - \frac{\alpha \lambda}{m}\right) \theta_j$$

Así:

$$\theta_j = \theta_j \left(1 - \frac{\alpha \lambda}{m}\right) - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

$j \geq 1$

El término de datos exactamente:

$$\frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

El intérprete el factor

$$1 - \frac{\alpha \lambda}{m}$$

Este factor tiene una interpretación aún más importante:

$$\boxed{1 - \frac{\alpha \lambda}{m}}$$

(5)

multiplica por el parámetro θ_i

Si queremos momentaneamente los datos tendríamos

$$\theta_i^{\text{nuevo}} = \left(1 - \frac{\alpha \lambda}{m}\right) \theta_i^{\text{viejo}}$$

Normalmente se escogen valores:

$$0 < 1 - \frac{\alpha \lambda}{m} < 1$$

Entonces el valor absoluto θ_i disminuye en cada actualización

por ejemplo si

$$1 - \frac{\alpha \lambda}{m} = 0.9 \quad \text{Entonces:}$$

$$\theta_i^{\text{nuevo}} = 0.9 \theta_i^{\text{viejo}}$$

$$\text{Si } \theta_i = 10$$

Se convierte, entre de considerar el término de datos, en 9.5

$$\text{Si } \theta_i = -10 \text{ obtenemos } -9.5$$

En ambos casos el parámetro se acerca a cero.

Este efecto se llama Weight decay.

Podemos pensar de la actualización como dos fuentes.

$$\theta_i \left(1 - \frac{\alpha \lambda}{m}\right) - \frac{\alpha}{m} \sum_i (h_\theta(x^{(i)}) - y^{(i)}) x_{j,i}$$

datos: busca mejorar el ajuste

↳ Regularización evita sobreajuste

Si $\lambda = 0$ no hay regularización

Si λ aumenta, se penaliza más se vuelve más fuerte.

Si λ es muy grande puede aparecer sobreajuste.

(6)

7) Coste Regularizado para Regresión Logística

En regresión logística sin regularización

$$J_{\text{log}}(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1-y^{(i)}) \log (1-h_{\theta}(x^{(i)}))]$$

Añadimos exactamente la misma penalización L_2

$$\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

Entonces:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1-y^{(i)}) \log (1-h_{\theta}(x^{(i)}))] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

Donde ahora:

$$h_{\theta}(x) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

Es decir

$J_{\text{log, reg}} =$ Entropía cruzada + penalización L_2

8) Gradiente para Regresión Logística Regularizada

$$\frac{\partial J_{\text{data}}}{\partial \theta_1} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_{i1}$$

La parte de regularización es:

$$J_{\text{reg}}(\theta) = \frac{\lambda}{2m} \sum_{k=1}^n \theta_k^2$$

④

por tanto: para $j \geq 1$

$$\frac{\partial J_{reg}}{\partial \theta_j} = \frac{\lambda}{n} \theta_j$$

Sumando ambas contribuciones

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)}) x_{j,i} + \frac{\lambda}{n} \theta_j$$

para $j=0$

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})$$

para $j \geq 1$

$$\theta_j := \theta_j \left(1 - \frac{2\lambda}{n} \right) - \frac{\lambda}{n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)}) x_{j,i}$$

y para el intercepto

$$\theta_0 := \theta_0 - \frac{\lambda}{n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})$$

q) ¿por qué normalmente no se regulariza θ_0

* Regularizar θ_0 penaliza innecesariamente el nivel bias del modelo y además,

habría que tener en cuenta que la solución dependería de donde estemos el origen o centro de las variables

θ no se regulariza porque representa el intercepto, no el efecto de una covariable.