

1. Regresión lineal multivariada desde máxima verosimilitud

En regresión lineal se busca modelar una variable continua Y a partir de variables de entrada X . Una forma natural de hacerlo es suponer que la salida observada está formada por una parte determinista, $\theta^T x$, más una fluctuación aleatoria.

Considere

$$\mathcal{D} = \{(x^{(i)}, y^{(i)})\}_{i=1}^m,$$

con

$$x^{(i)} = \begin{bmatrix} 1 \\ x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix}, \quad \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}.$$

Suponga que

$$y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)}, \quad \varepsilon^{(i)} \sim \mathcal{N}(0, \sigma^2).$$

La hipótesis gaussiana permite construir una distribución para Y y, a partir de ella, una función de verosimilitud para los datos observados.

1. Determine la distribución de

$$Y^{(i)} \mid X = x^{(i)}.$$

2. Escriba

$$p(y^{(i)} \mid x^{(i)}; \theta).$$

3. Suponiendo independencia entre observaciones, construya

$$L(\theta).$$

4. Obtenga

$$\ell(\theta) = \log L(\theta).$$

5. Identifique los términos que dependen de θ .

6. Muestre que maximizar $\ell(\theta)$ equivale a minimizar la suma de residuos cuadrados.

7. Obtenga una función de coste de la forma

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2.$$

8. Explique por qué $1/2$ y $1/m$ no cambian el minimizador.

2. Gradiente y descenso por gradiente

Una vez construida $J(\theta)$, el aprendizaje puede verse como un problema de optimización. El gradiente indica cómo cambia el coste cuando cambia cada parámetro, y permite construir una regla iterativa para encontrar valores de θ que reduzcan el error.

Parta de

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2.$$

1. Calcule

$$\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j}.$$

2. Use la regla de la cadena para hallar

$$\frac{\partial J}{\partial \theta_j}.$$

3. Escriba el resultado como suma sobre los m datos.

4. Construya

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}.$$

5. Escriba la actualización para

$$j = 0, 1, \dots, n.$$

6. Explique por qué los parámetros deben actualizarse simultáneamente.

3. Ecuación normal

Para regresión lineal también existe una solución analítica. La idea es escribir el coste en forma matricial e imponer directamente la condición de mínimo.

Defina

$$X = \begin{bmatrix} 1 & x_1^{(1)} & \cdots & x_n^{(1)} \\ 1 & x_1^{(2)} & \cdots & x_n^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & \cdots & x_n^{(m)} \end{bmatrix},$$

$$y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix}, \quad J(\theta) = \frac{1}{2m} (X\theta - y)^T (X\theta - y).$$

1. Expanda

$$(X\theta - y)^T (X\theta - y).$$

2. Calcule

$$\nabla_{\theta} J(\theta).$$

3. Imponga

$$\nabla_{\theta} J(\theta) = 0.$$

4. Obtenga

$$X^T X \theta = X^T y.$$

5. Si $X^T X$ es invertible, despeje θ .

6. Compare esta solución con descenso por gradiente:

- ¿cuál es iterativa?
- ¿cuál es analítica?
- ¿cuándo puede fallar la inversión?

4. Regresión logística desde la familia exponencial

En clasificación binaria, Y toma dos valores posibles. Por ello, la distribución Bernoulli proporciona un punto de partida natural. Al escribirla como miembro de la familia exponencial se obtiene una relación entre su parámetro natural y una función lineal de x .

Considere

$$p(y; \eta) = b(y) \exp [\eta T(y) - a(\eta)],$$

y para $Y \in \{0, 1\}$,

$$p(y; \phi) = \phi^y (1 - \phi)^{1-y}.$$

1. Reescriba Bernoulli usando una exponencial.
2. Identifique el parámetro natural η .
3. Muestre que

$$\eta = \log \frac{\phi}{1 - \phi}.$$

4. Despeje ϕ en función de η .

5. Si

$$\eta = \theta^T x,$$

obtenga

$$P_{\theta}(Y = 1 \mid X = x).$$

6. Defina esta cantidad como

$$h_{\theta}(x).$$

7. Obtenga

$$P_{\theta}(Y = 0 \mid X = x).$$

5. Likelihood y función de coste logística

Una vez obtenida $h_{\theta}(x)$, cada observación puede interpretarse probabilísticamente. Para $y = 1$, el modelo asigna probabilidad $h_{\theta}(x)$; para $y = 0$, asigna $1 - h_{\theta}(x)$. A partir de ambas posibilidades se construye una única expresión para la verosimilitud.

1. Escriba una expresión única para

$$p(y^{(i)} \mid x^{(i)}; \theta)$$

válida para $y^{(i)} = 0$ y $y^{(i)} = 1$.

2. Construya la verosimilitud para m observaciones.

3. Calcule la log-verosimilitud.

4. Cambie el signo y normalice por m para obtener $J(\theta)$.

5. Identifique la entropía cruzada binaria.

6. Calcule

$$\frac{\partial J}{\partial \theta_j}.$$

7. Escriba la regla de descenso por gradiente.

8. Compare este gradiente con el de regresión lineal.

Puede ser útil recordar que

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad \sigma'(z) = \sigma(z) (1 - \sigma(z)).$$

6. Regularización

Un buen ajuste sobre los datos de entrenamiento no garantiza necesariamente una buena generalización. Una forma de controlar modelos con parámetros grandes es añadir una penalización a la función de coste. Para regularización L_2 ,

$$\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2.$$

El parámetro λ controla cuánto pesa esta penalización frente al ajuste a los datos.

1. Escriba el coste regularizado para regresión lineal.

2. Calcule

$$\frac{\partial J}{\partial \theta_j}, \quad j \geq 1.$$

3. Escriba por separado el caso $j = 0$.

4. Construya la actualización para $j \geq 1$.

5. Reorganice hasta obtener

$$\theta_j := \theta_j \left(1 - \frac{\alpha \lambda}{m} \right) - \text{término de datos.}$$

6. Interprete el factor

$$1 - \frac{\alpha \lambda}{m}.$$

7. Escriba el coste regularizado para regresión logística.

8. Obtenga el gradiente correspondiente.

9. Explique por qué normalmente no se regulariza θ_0 .

Referencias

Ng, A. Y. *CS229 Lecture Notes: Supervised Learning*. Stanford University.

Murphy, K. P. (2022). *Probabilistic Machine Learning: An Introduction*. MIT Press.

Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.

*) T[al] pr.

(1)

1) Regresión lineal multivariada desde máxima verosimilitud

x) En Regresión lineal se busca modelar una variable continua Y a partir de variables de entrada X . Una forma natural de hacerlo es suponer que la salida observada es la formada por una parte determinista, $\theta^T X$, más una fluctuación aleatoria.

Considerar:

$$D = \{ (X^{(i)}, y^{(i)}) \}_{i=1}^M$$

con:

$$X^{(i)} = \begin{bmatrix} 1 \\ x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix}, \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}$$

Suponga que:

$$y^{(i)} = \theta^T X^{(i)} + \epsilon^{(i)} \quad \epsilon^{(i)} \sim \mathcal{N}(0, \sigma^2)$$

La hipótesis gaussiana permite construir una distribución para Y a partir de ella, una función de verosimilitud para los datos observados.

1) Determinar la distribución de $y^{(i)} | X = X^{(i)}$

Solución primer numeral:

Partimos de: $y^{(i)} = \theta^T X^{(i)} + \epsilon^{(i)}$

donde: $\epsilon^{(i)} \sim \mathcal{N}(0, \sigma^2)$

(2)

Como $x^{(i)}$ es conocido y θ se considera fijo, el término

$\theta^T x^{(i)}$ se considera una constante. Entonces $y^{(i)}$ es una variable normal desplazada por esa constante

La propiedad que se usa es:

$$\epsilon \sim N(0, \sigma^2) \Rightarrow a + \epsilon \sim N(a, \sigma^2)$$

Por lo tanto:

$$y^{(i)} | x = x^{(i)} \sim N(\theta^T x^{(i)}, \sigma^2)$$

Identifiquemos la media:

$$E[y^{(i)} | x = x^{(i)}] = \theta^T x^{(i)}$$

Por lo que se tiene que:

$$E[y^{(i)} | x = x^{(i)}] = E[\theta^T x^{(i)} + \epsilon^{(i)}] = \theta^T x^{(i)} + E[\epsilon^{(i)}], \text{ pero:}$$

$$\epsilon^{(i)} \sim N(0, \sigma^2) \text{ Así que: } E[\epsilon^{(i)}] = 0$$

$$\text{Así que: } E[y^{(i)} | x = x^{(i)}] = \theta^T x^{(i)}$$

*) podemos calcular la varianza:

$$\text{Var}(y^{(i)} | x = x^{(i)}) = \text{Var}(\theta^T x^{(i)} + \epsilon^{(i)}) = \text{Var}(\epsilon^{(i)} + \theta^T x^{(i)}) = \text{Var}(\epsilon^{(i)}) = \sigma^2$$

Demostremos:

$$\text{Var}(\epsilon^{(i)} + \theta^T x^{(i)}) = \text{Var}(\theta^T x^{(i)} + \epsilon^{(i)}) = E[(\theta^T x^{(i)} + \epsilon^{(i)} - E[\theta^T x^{(i)} + \epsilon^{(i)}])^2]$$

$$\text{Var}(\epsilon^{(i)} + \theta^T x^{(i)}) = E[(\theta^T x^{(i)} + \epsilon^{(i)} - E[\epsilon^{(i)}] - \theta^T x^{(i)})^2]$$

$$\text{Var}(\epsilon^{(i)} + \theta^T x^{(i)}) = E[(\epsilon^{(i)} - E[\epsilon^{(i)}])^2] = \text{Var}(\epsilon^{(i)}) = \sigma^2$$

Interpretación:

$$y^{(i)} | x = x^{(i)} \sim N(\theta^T x^{(i)}, \sigma^2)$$

El modelo dice que los valores de y se distribuyen alrededor de la predicción lineal

$h_\theta(x^{(i)}) = \theta^T x^{(i)}$ y σ^2 mide que tanto se dispersan los datos alrededor de esa predicción

(3)

2) de este punto 1 obtenemos:

$$y^{(i)} | x = x^{(i)} \sim N(\theta^T x^{(i)}, \sigma^2)$$

* La densidad de probabilidad general de una distribución normal con media μ y varianza σ^2 es

$$p(y) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y-\mu)^2}{2\sigma^2}}$$

En nuestro problema

$$\mu = \theta^T x^{(i)}$$

Además estamos evaluando la densidad en el valor $y^{(i)}$ entonces sustituimos:

$$y \rightarrow y^{(i)}$$

$$y$$

$$\mu \rightarrow \theta^T x^{(i)}$$

Así obtenemos:

$$p(y^{(i)} | x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}}$$

también podemos escribirlo como:

$$p(y^{(i)} | x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}}$$

¿Qué significa esta expresión?

Esta fórmula nos dice que tan compatible es el dato observado $y^{(i)}$ con una determinada elección de los parámetros

• Nuestro modelo predice $\hat{y}^{(i)} = \theta^T x^{(i)}$

El dato real es $y^{(i)}$

(4)

por lo tanto:

$$y^{(i)} - \hat{y}^{(i)} = y^{(i)} - \theta^T x^{(i)}$$

es el residuo, es decir, la diferencia entre lo que realmente observamos y lo que predice el modelo.

$$\text{Si } y^{(i)} \approx \theta^T x^{(i)}$$

El exponente está cerca de cero y la densidad es grande. El dato es bastante compatible con el modelo.

Ahora si

$$(y^{(i)} - \theta^T x^{(i)})^2 \gg 0$$

Entonces: $e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}}$ se hace pequeño. El dato es menos compatible. La

densidad es menor.

3) Suponiendo independencia entre observaciones construya

$$L(\theta)$$

x) construya la función de verosimilitud.

La tenemos para una sola observación x

$$p(y^{(i)} | x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}}$$

Ahora el conjunto de datos tiene M observaciones

$$D = \{(x^{(i)}, y^{(i)})\}_{i=1}^M$$

El ejercicio dice que las observaciones son independientes, la probabilidad conjunta de observar todas las variables $y^{(1)} \dots y^{(M)}$ es el producto de las probabilidades individuales.

(5)

La función de verosimilitud se define:

$$L(\theta) = P(D, \theta) = P(y^{(1)}, y^{(2)}, \dots, y^{(n)} | x^{(1)}, \dots, x^{(n)}; \theta)$$

Si suponemos independencia entre las observaciones entonces:

$$P(y^{(1)}, y^{(2)}, \dots, y^{(n)} | x^{(1)}, \dots, x^{(n-1)}, x^{(n)}) = P(y^{(1)} | x^{(1)}) \dots P(y^{(n-1)} | x^{(n-1)}) P(y^{(n)} | x^{(n)})$$

$$P(y^{(1)}, y^{(2)}, \dots, y^{(n)} | x^{(1)}, \dots, x^{(n)}) = \prod_{i=1}^n P(y^{(i)} | x^{(i)}; \theta)$$

Entonces:

$$L(\theta) = \prod_{i=1}^n P(y^{(i)} | x^{(i)}; \theta)$$

Sustituimos la expresión del ítem 2 y obtenemos:

$$L(\theta) = \prod_{i=1}^n \left[\frac{1}{\sqrt{2\pi}\sigma} e^{\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right)} \right]$$

Separamos el producto de factores:

$$\prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n = \left(\frac{1}{\sqrt{2n\sigma^2}} \right)^n$$

Además el producto de exponenciales se convierte en una exponencial de la suma:

$$\prod_{i=1}^n e^{a_i} = e^{\sum_{i=1}^n a_i}$$

por lo tanto:

$$L(\theta) = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y^{(i)} - \theta^T x^{(i)})^2}$$
$$L(\theta) = \left(\frac{1}{\sqrt{2n\sigma^2}} \right)^n e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y^{(i)} - \theta^T x^{(i)})^2}$$

$$l(\theta) = \frac{1}{(2\pi\sigma^2)^{M/2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^M (y^{(i)} - \theta^T x^{(i)})^2} \quad (6)$$

Esta es la función de verosimilitud

La idea física y matemática es la siguiente: $l(\theta)$ mide que tan compatibles son todos los datos observados con una elección de θ

Si θ produce predicciones muy cercanas a los datos

$$\theta^T x^{(i)} \approx y^{(i)}$$

Entonces los residuos son pequeños y la verosimilitud es grande. De otro modo la función disminuye.

4) Obtenga

$$\ell(\theta) = \log l(\theta)$$

partiendo de:

$$l(\theta) = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^M e^{-\frac{1}{2\sigma^2} \sum_{i=1}^M (y^{(i)} - \theta^T x^{(i)})^2}$$

$$\text{Definimos: } \ell(\theta) = \log l(\theta)$$

$$\ell(\theta) = \log \left[\left(\frac{1}{\sqrt{2\pi}\sigma} \right)^M e^{-\frac{1}{2\sigma^2} \sum_{i=1}^M (y^{(i)} - \theta^T x^{(i)})^2} \right]$$

$$\ell(\theta) = \log \left[\left(\frac{1}{\sqrt{2\pi}\sigma} \right)^M \right] - \frac{1}{2\sigma^2} \sum_{i=1}^M (y^{(i)} - \theta^T x^{(i)})^2$$

$$\ell(\theta) = M \log \left(\frac{1}{\sqrt{2\pi}\sigma} \right) - \frac{1}{2\sigma^2} \sum_{i=1}^M (y^{(i)} - \theta^T x^{(i)})^2$$

$$\ell(\theta) = -M \log(\sqrt{2\pi}\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^M (y^{(i)} - \theta^T x^{(i)})^2$$

$$\ell(\theta) = -M \left[\frac{1}{2} \log(2\pi) + \log(\sigma) \right] - \frac{1}{2\sigma^2} \sum_{i=1}^M (y^{(i)} - \theta^T x^{(i)})^2$$

$$\ell(\theta) = -\frac{M}{2} \log(2\pi) - M \log(\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^M (y^{(i)} - \theta^T x^{(i)})^2$$

también es muy común escribir

7

$$\ell(\theta) = -\frac{M}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^M (y(i) - \theta^T x(i))^2$$

5) Identificar los términos que dependen de θ

Ahora analizamos cada término:

El primer es $-\frac{M}{2} \log(2\pi\sigma^2)$

Este término es una constante no depende de θ

Ahora observamos el segundo

$$-\frac{1}{2\sigma^2} \sum_{i=1}^M (y(i) - \theta^T x(i))^2$$

Este término contiene toda la parte de θ

6) Demostremos que maximizar la log-Verosimilitud equivale a minimizar la suma de los

Residuos Cuadrados

Partimos de la parte de la log-Verosimilitud que depende de θ

$$\ell(\theta) = \text{Constante} - \frac{1}{2\sigma^2} \sum_{i=1}^M (y(i) - \theta^T x(i))^2$$

Definamos la suma de Residuos Cuadrados

$$S(\theta) = \sum_{i=1}^M (y(i) - \theta^T x(i))^2$$

Entonces el log Verosimilitud puede escribirse como:

$$\ell(\theta) = \text{Constante} - \frac{1}{2\sigma^2} S(\theta)$$

Observamos directamente.

②

$$\sigma^2 > 0$$

Entonces

$$\frac{1}{2\sigma^2} > 0$$

delante este término hay un signo negativo.

$$-\frac{1}{2\sigma^2} S(\theta)$$

Significa que cuando $S(\theta)$ aumenta $J(\theta)$ disminuye y cuando $S(\theta)$ disminuye, $J(\theta)$ aumenta

por ejemplo si dos valores de θ producen $J(\theta) = \text{constante} - \frac{1}{2\sigma^2} S(\theta)$

$$S(\theta_1) = 2 \wedge S(\theta_2) = 10$$

$$-\frac{1}{2\sigma^2} S(\theta_1) > -\frac{1}{2\sigma^2} S(\theta_2)$$

por tanto θ_1 tendría una mayor verosimilitud

$\text{avg max}_{\theta} J(\theta) = \text{avg max}_{\theta} \left[-\frac{1}{2\sigma^2} S(\theta) \right]$ multiplicar por una constante negativa cambia
maximización por minimización

$$\text{avg max}_{\theta} \left[-\frac{1}{2\sigma^2} S(\theta) \right] = \text{avg min}_{\theta} S(\theta)$$

$$\text{avg max}_{\theta} J(\theta) = \text{avg min}_{\theta} \sum_{i=1}^M (y(i) - \theta^T x(i))^2$$

Entonces:

$$\text{avg max}_{\theta} J(\theta) = \text{avg min}_{\theta} \sum_{i=1}^M (\theta^T x(i) - y(i))^2$$

La conclusión conceptual:

bajo la hipótesis de errores gaussianos, buscar los parámetros más probables es más o menos

verosimilitud conduce exactamente a la misma cuestión que minimizar la suma de errores al cuadrado.

7) Obtenga una función de costo de la forma:

$$J(\theta) = \frac{1}{2M} \sum_{i=1}^M (h_{\theta}(x) - y(i))^2$$

Del punto 6 obtenimos que: Maximizar la verosimilitud equivale a minimizar

$$\sum_{i=1}^M (\theta^T x^{(i)} - y^{(i)})$$

Ahora definimos la hipótesis de regresión lineal:

$$h_{\theta}(x^{(i)}) = \theta^T x^{(i)}$$

Substituyendo en la suma de residuos cuadradas:

$$\sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Para construir una función de costo conveniente dividimos por $2M$

$$J(\theta) = \frac{1}{2M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

* 8) Explicación

El factor $1/M$ hacemos que otras trabajando con un valor cuadrático promedio en lugar de una suma que crece porque tenemos más datos. El factor $1/2$ se introduce por conveniencia matemática

Cuando derivamos un término cuadrático

$$\frac{d}{dz} z^2 = 2z$$

El 2 se cancela con el $1/2$ por eso los derivados quedan más limpios

Explicación detallada:

$$S(\theta) = \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$J(\theta) = \frac{1}{2M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

(10)

Si $\exists \theta_1, \theta_2$ tal que:

$$S(\theta_1) < S(\theta_2) \wedge \frac{1}{2m} > 0$$

$$\text{Entonces } \frac{1}{2m} S(\theta_1) < \frac{1}{2m} S(\theta_2) \Leftrightarrow J(\theta_1) < J(\theta_2)$$

por lo tanto:

$$\underset{\theta}{\operatorname{argmin}} S(\theta) = \underset{\theta}{\operatorname{argmin}} J(\theta)$$

Los factores $\frac{1}{2}$ y $\frac{1}{m}$ No cambian el minimizador puesto son constantes positivas con respecto a θ

2) Gradiente y descenso por gradiente: (1)

Una vez construida $J(\theta)$, el aprendizaje puede verse como un problema de optimización.

El gradiente indica cómo cambia el coste cuando cambia cada parámetro, y permite construir una regla iterativa para encontrar valores de θ que reduzcan el error.

X) tenemos la hipótesis de regresión lineal

$$h_{\theta}(x^{(i)}) = \theta^T x^{(i)}$$

$$h_{\theta}(x^{(i)}) = [\theta_0, \theta_1, \dots, \theta_n] \begin{bmatrix} x_0^{(i)} \\ x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$$

$$h_{\theta}(x^{(i)}) = x_0^{(i)} \theta_0 + \theta_1 x_1^{(i)} + \dots + \theta_n x_n^{(i)}$$

para $j=0$ $x_0^{(i)} = 1$

$$\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_0} = 1$$

$$\frac{\partial \theta_0}{\partial \theta_0}$$

$$h_{\theta}(x^{(i)}) = 1 + \theta_1 x_1^{(i)} + \theta_2 x_2^{(i)} + \dots + \theta_n x_n^{(i)}$$

Ahora:

$$\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} = ? \quad h_{\theta}(x^{(i)}) = 1 + \theta_1 x_1^{(i)} + \theta_2 x_2^{(i)} + \dots + \theta_n x_n^{(i)}$$

$$\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} = x_j^{(i)}$$

(2) Usar la regla de la cadena para hallar

$$\frac{\partial J}{\partial \theta_j} = \frac{\partial J}{\partial \theta_j} \left[\frac{1}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)})^2 \right]$$

$$\frac{\partial J}{\partial \theta_j} = 2 \cdot \frac{1}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) \frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} = \frac{1}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) x_j = \frac{\partial J}{\partial \theta_j}$$

Paso 3: Escribiremos el resultado como una suma sobre los m datos

Resultado general:

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

De forma explícita tenemos:

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} [(h_{\theta}(x^{(1)}) - y^{(1)}) x_j^{(1)} + (h_{\theta}(x^{(2)}) - y^{(2)}) x_j^{(2)} + \dots + (h_{\theta}(x^{(m)}) - y^{(m)}) x_j^{(m)}]$$

Podemos tenerlo a terminos:

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) (1)$$

$$\frac{\partial J}{\partial \theta_1} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_1^{(i)}$$

$$\frac{\partial J}{\partial \theta_2} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_2^{(i)}$$

$$\frac{\partial J}{\partial \theta_n} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_n^{(i)}$$

En forma vectorial

$$\nabla J(\theta) = \begin{bmatrix} \frac{\partial J}{\partial \theta_0} \\ \frac{\partial J}{\partial \theta_1} \\ \vdots \\ \frac{\partial J}{\partial \theta_n} \end{bmatrix} = \frac{1}{m} \begin{bmatrix} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) (1) \\ \vdots \\ \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_n^{(i)} \end{bmatrix}$$

(3)

4) Construya:

$$\theta_j = \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$$

Del punto 3 obtenemos

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

Ahora simplemente sustituimos esta derivada en la regla general.

$$\theta_j := \theta_j - \alpha \left[\frac{1}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} \right]$$

$$\theta_j := \theta_j - \frac{\alpha}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

En forma vectorial

$$\theta := \theta - \frac{\alpha}{M} X^T (X\theta - y)$$

La expresión significa que cada parámetro θ_j se corrige en la dirección opuesta al gradiente porque el gradiente señala la dirección de mayor aumento $J(\theta)$ y nosotros queremos disminuir el costo, por eso aparece el signo negativo $-\alpha \frac{\partial J}{\partial \theta_j}$. Si α es muy grande, la actualización puede

pasarse del mínimo. Si es muy pequeña, el aprendizaje puede ser muy lento.

5) Escribiremos la actualización para:

$$\theta_0 := \theta_0 - \frac{\alpha}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)}$$

$$\theta_0 := \theta_0 - \frac{\alpha}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) (1) \quad \checkmark$$

(4)

$$\theta_1 := \theta_1 - \frac{\alpha}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) x_{i1} \quad j=1$$

$$\theta_2 := \theta_2 - \frac{\alpha}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) x_{i2} \quad j=2$$

$$\theta_n := \theta_n - \frac{\alpha}{M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)}) x_{in} \quad j=n$$

¿Qué estamos haciendo en cada iteración?

tenemos unos parámetros

$\theta_0, \theta_1, \dots, \theta_n$ actuales

con ellos calculamos

$$h_{\theta}(x^{(i)})$$

calculamos los errores

$$h_{\theta}(x^{(i)}) - y^{(i)}$$

a) con esos errores calculamos el gradiente

$\frac{\partial J}{\partial \theta_j}$ y finalmente modificamos cada parámetro en dirección opuesta al gradiente.

$$\theta_j^{\text{nuevo}} = \theta_j^{\text{viejo}} - \alpha \frac{\partial J}{\partial \theta_j}$$

Esto se repite iterativamente buscando reducir $J(\theta)$.

b) por que los parámetros deben actualizarse simultáneamente

$$\theta_j^{\text{nuevo}} = \theta_j^{\text{viejo}} - \alpha \frac{\partial J(\theta^{\text{viejo}})}{\partial \theta_j}$$

porque todas las componentes del gradiente deben calcularse en el mismo punto del espacio

de parámetros

5

Supongamos por simplicidad:

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \end{bmatrix}$$

$$\theta^{(k)} = \begin{bmatrix} \theta_0^{(k)} \\ \theta_1^{(k)} \end{bmatrix}$$

Calculamos el gradiente en ese punto:

$$\nabla J(\theta^{(k)}) = \begin{bmatrix} \frac{\partial J}{\partial \theta_0} \\ \frac{\partial J}{\partial \theta_1} \end{bmatrix}_{\theta = \theta^{(k)}}$$

Entonces la actualización correcta es:

$$\theta_0^{(k+1)} = \theta_0^{(k)} - \alpha \frac{\partial J(\theta^{(k)})}{\partial \theta_0}$$

$$\theta_1^{(k+1)} = \theta_1^{(k)} - \alpha \frac{\partial J(\theta^{(k)})}{\partial \theta_1}$$

} se actualizan por el mismo punto del espacio de parámetros.

x) puntos:

(1)

Ecuación Normal:

Para la regresión lineal también existe una solución analítica. La idea es escribir el coste en forma Matricial e imponer directamente la condición de mínimo

Definir:

$$X = \begin{bmatrix} 1 & x_1^{(1)} & \dots & x_n^{(1)} \\ \vdots & \vdots & & \vdots \\ 1 & x_1^{(m)} & \dots & x_n^{(m)} \end{bmatrix}$$

$$y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix}$$

$$J(\theta) = \frac{1}{2m} (X\theta - y)^T (X\theta - y)$$

$$X\theta = \begin{bmatrix} \theta_0 + \theta_1 x_1^{(1)} + \dots + \theta_n x_n^{(1)} \\ \vdots \\ \theta_0 + \theta_1 x_1^{(m)} + \dots + \theta_n x_n^{(m)} \end{bmatrix}$$

para cada componente es justamente:

$$h_\theta(x^{(i)}) = \theta^T x^{(i)}$$

Así que

$$X\theta = \begin{bmatrix} h_\theta(x^{(1)}) \\ h_\theta(x^{(2)}) \\ \vdots \\ h_\theta(x^{(m)}) \end{bmatrix}$$

Ahora vemos y

$$X\theta - y = \begin{bmatrix} h_\theta(x^{(1)}) - y^{(1)} \\ h_\theta(x^{(2)}) - y^{(2)} \\ \vdots \\ h_\theta(x^{(m)}) - y^{(m)} \end{bmatrix}$$

su transpuesta es:

$$(X\theta - y)^T = [h_\theta(x^{(1)}) - y^{(1)}, h_\theta(x^{(2)}) - y^{(2)} \dots h_\theta(x^{(m)}) - y^{(m)}]$$

por lo tanto

i) Expandir $(X\theta - y)^T (X\theta - y)$

Solución:

partiendo de:

$$J(\theta) = \frac{1}{2m} (X\theta - y)^T (X\theta - y)$$

$$\text{con } X = \begin{bmatrix} 1 & x_1^{(1)} & \dots & x_n^{(1)} \\ \vdots & \vdots & & \vdots \\ 1 & x_1^{(m)} & \dots & x_n^{(m)} \end{bmatrix}$$

$$\theta = \begin{bmatrix} \theta_0 \\ \vdots \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix} \quad y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix}$$

$$(x\theta - y)^T (x\theta - y)$$

(2)

Es el producto

$$\begin{bmatrix} h\theta(x^{(1)}) - y^{(1)} & \dots & h\theta(x^{(n)}) - y^{(n)} \end{bmatrix} \begin{bmatrix} h\theta(x^{(1)}) - y^{(1)} \\ \vdots \\ h\theta(x^{(n)}) - y^{(n)} \end{bmatrix}$$

El resultado es:

$$(x\theta - y)^T (x\theta - y) = \sum_{i=1}^n (h\theta(x^{(i)}) - y^{(i)})^2$$

Ahora hagamos la expansión algebraica matricial

Usamos:

$$(A-B)^T = A^T - B^T$$

Entonces:

$$(x\theta - y)^T = (x\theta)^T - y^T$$

$$\text{y como } (x\theta)^T = \theta^T x^T$$

tenemos

$$(x\theta - y)^T = \theta^T x^T - y^T$$

Por lo tanto:

$$(x\theta - y)^T (x\theta - y) = (\theta^T x^T - y^T) (x\theta - y)$$

$$= \theta^T x^T x \theta - \underbrace{\theta^T x^T y}_{\text{escalar}} - \underbrace{y^T x \theta}_{\text{escalar}} + y^T y$$

Ahora observamos que:

$$\theta^T x^T y \text{ es un escalar}$$

$$\text{y } y^T x \theta \text{ también es un escalar}$$

además:

$$(\theta^T x^T y)^T = y^T x \theta$$

Como el transpuesto de un mismo escalar es el mismo escalar,

$$\theta^T x^T y = y^T x \theta$$

Los términos entre corchetes se pueden combinar

$$-\theta^T x^T y - y^T x \theta = -2\theta^T x^T y$$

Finalmente:

$$(x\theta - y)^T (x\theta - y) = \theta^T x^T x \theta - 2\theta^T x^T y + y^T y$$

y por lo tanto:

$$J(\theta) = \frac{1}{2n} [\theta^T x^T x \theta - 2\theta^T x^T y + y^T y]$$

② Paso 2:

calcular $\nabla_{\theta} J(\theta)$

partiendo de la forma expresada

$$J(\theta) = \frac{1}{2m} (\theta^T X^T X \theta - 2\theta^T X^T y + y^T y)$$

Ahora derivamos con respecto al vector θ .

$$\nabla_{\theta} (\theta^T A \theta) = (A + A^T) \theta$$

y si A es simétrica

$$\nabla_{\theta} (\theta^T A \theta) = 2A\theta$$

En nuestro caso:

$$A = X^T X$$

y $X^T X$ es simétrica porque:

$$(X^T X)^T = X^T X$$

Entonces:

$$\nabla_{\theta} (\theta^T X^T X \theta) = 2X^T X \theta$$

Ahora el segundo término

$$-2\theta^T X^T y$$

Como $X^T y$ no depende de θ

$$\nabla_{\theta} (\theta^T X^T y) = X^T y$$

por lo tanto:

$$\nabla_{\theta} (-2\theta^T X^T y) = -2X^T y$$

Finalmente $y^T y$ no depende de θ

Así que:

$$\nabla_{\theta} J(\theta) = 0$$

③

Entonces

$$\nabla_{\theta} J(\theta) = \frac{1}{2m} (2X^T X \theta - 2X^T y)$$

$$\nabla_{\theta} J(\theta) = \frac{1}{m} (X^T X \theta - X^T y)$$

también puede escribirse como:

$$\nabla_{\theta} J(\theta) = \frac{1}{m} X^T (X\theta - y)$$

Paso 3)

del paso anterior obtenimos

$$\nabla_{\theta} J(\theta) = \frac{1}{m} (X^T X \theta - X^T y)$$

Para encontrar un mínimo, imponemos que el gradiente sea cero.

$$\nabla_{\theta} J(\theta) = 0$$

Entonces:

$$\frac{1}{m} (X^T X \theta - X^T y) = 0$$

Como $m \neq 0$

$$X^T X \theta - X^T y = 0$$

$$X^T X \theta = X^T y$$

Esta ecuación se conoce como la ecuación normal de la regresión lineal

$X^T X$ es una Matriz de $(n+1) \times (n+1)$

Mientras $X^T y$

es un vector $(n+1) \times 1$

Entonces la ecuación

$X^T X \theta = X^T y$ es un sistema de $n+1$ ecuaciones con $n+1$ incógnitas.

4

Despejamos θ suponiendo que: $X^T X$ es invertible.

Partimos de la ecuación normal

$$X^T X \theta = X^T y$$

$$(X^T X)^{-1} X^T X \theta = (X^T X)^{-1} X^T y$$

Como:

$$(X^T X)^{-1} (X^T X) = I$$

obtenemos

$$\theta = (X^T X)^{-1} X^T y$$

Finalmente:

$$\theta = (X^T X)^{-1} X^T y$$

Esta es la solución analítica de la regresión lineal mediante la ecuación normal

Ⓢ) ~~tempos~~ de los Métodos diferentes para encontrar los parámetros θ que minimizan $J(\theta)$

Descenso por gradiente.

$$\theta_j^{(k+1)} = \theta_j^{(k)} - \alpha \frac{\partial J(\theta^{(k)})}{\partial \theta_j}$$

En forma Matricial:

$$\theta^{(k+1)} = \theta^{(k)} - \frac{\alpha}{n} X^T (X \theta^{(k)} - y)$$

Ala iniciamos con un Valor inicial

$$\theta^{(0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Luego repetimos sucesivas actualizaciones

$$\theta^{(0)} \rightarrow \theta^{(1)} \rightarrow \theta^{(2)} \rightarrow \dots$$

hasta que $J(\theta)$ deje de cambiar significativamente o

se alcance algún criterio de convergencia

porque el descenso de gradiente es un método iterativo

5

Ecuación normal

En este espacio obtenimos

$$X^T X \theta = X^T y$$

Si $X^T X$ es invertible

$$\hat{\theta} = (X^T X)^{-1} X^T y$$

La ecuación normal proporciona una solución analítica

¿Cuándo falla la inversión?

Para usar directamente $(X^T X)^{-1}$ es necesario que $X^T X$ sea invertible

La inversión falla cuando:

$$\det(X^T X) = 0$$

(1)

Punto 4

Regresión logística del de la familia exponencial.

En clasificación binaria Y toma dos valores posibles. por ello, la distribución binomial proporcional a un par de parámetros naturales. Al escribirla como miembro de la familia exponencial se obtiene una expresión en términos de parámetros naturales y una función lineal de X

Considera $p(y; \eta) = b(y) \exp[\eta^T(y) - a(\eta)]$ y para $y \in \{0, 1\}$

$$p(y; \theta) = \theta^y (1-\theta)^{1-y}$$

1) Reescriba binomial usando una exponencial

Empezamos con:

$$p(y; \theta) = \theta^y (1-\theta)^{1-y}$$

Usamos la propiedad

$$a^b = e^{b \log a} = [e^{\log a}]^b$$

$$\theta^y = e^{y \log \theta} = [e^{\log \theta}]^y$$

$$y (1-\theta)^{1-y} = e^{(1-y) \log(1-\theta)} = [e^{\log(1-\theta)}]^{1-y}$$

por lo tanto:

$$p(y; \theta) = e^{y \log \theta} e^{(1-y) \log(1-\theta)}$$

$$p(y; \theta) = \exp(y \log \theta + (1-y) \log(1-\theta))$$

Expandimos

$$(1-y) \log(1-y) = \log(1-\theta) - y \log(1-\theta)$$

$$p(y; \theta) = \exp[y \log \theta - y \log(1-\theta) + \log(1-\theta)]$$

Agrupamos términos.

$$p(y; \theta) = \exp(y \log \theta - \log(1-\theta) + \log(1-\theta))$$

$$p(y; \theta) = \exp\left[y \log\left(\frac{\theta}{1-\theta}\right) + \log(1-\theta)\right]$$

(2)

identifican el parámetro natural λ

$$p(y; \lambda) = b(y) \exp[\lambda T(y) - a(\lambda)]$$

Con

$$p(y; \theta) = \exp\left[y \log\left(\frac{\theta}{1-\theta}\right) + \log(1-\theta)\right]$$

podemos identificar

$$y = T(y)$$

y es coeficiente que multiplica a y es el parámetro natural

$$\lambda = \log\left(\frac{\theta}{1-\theta}\right)$$

$$b(y) = 1$$

3) Mostron que:

$$\lambda = \log\left(\frac{\theta}{1-\theta}\right)$$

Esto saca directamente de comparar la expresión anterior con la forma exponencial

tenemos:

$$p(y; \theta) = \exp\left[y \log\left(\frac{\theta}{1-\theta}\right) + \log(1-\theta)\right]$$

La función generadora es:

$$p(y; \lambda) = b(y) \exp[\lambda T(y) - a(\lambda)]$$

Como $T(y) = y$

$$\lambda = \log\left(\frac{\theta}{1-\theta}\right)$$

Esta transformación recibe el nombre de logit

$$\text{logit}(\theta) = \log\left(\frac{\theta}{1-\theta}\right)$$

3

Por lo tanto ϕ en función de h

Partiendo de:

$$h = \log\left(\frac{\phi}{1-\phi}\right)$$

$$e^h = \frac{\phi}{1-\phi}$$

$$\phi(1-\phi) = \phi$$

$$e^h \cdot e^{\phi} = \phi$$

$$e^h = \phi + e^{\phi} \phi$$

$$e^h = \phi(1 + e^{\phi})$$

$$\phi = \frac{e^h}{1 + e^h}$$

$$\phi = \frac{1}{1 + e^{-h}}$$

función sigmoide
o logística

* Si $h = \theta^T X$, obtener $p_{\theta}(Y=1 | X=x)$

tenemos

$$h = \theta^T X$$

y a carbamos de encontrar:

$$\phi = \frac{1}{1 + e^{-h}}$$

$$\phi = \frac{1}{1 + e^{-\theta^T X}}$$

En una variable de bernoulli

$$p(Y=1) = \phi$$

por lo tanto:

$$p_{\theta}(Y=1 | X=x) = \frac{1}{1 + e^{-\theta^T X}}$$

6) Definiremos como $h_{\theta}(x)$

Definimos la hipotesis logística

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T X}}$$

por lo tanto:

$$p_{\theta}(Y=1 | X=x) = h_{\theta}(x)$$

En Regresión Logística tenemos

$$h_{\theta}(x) = \sigma(\theta^T x)$$

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad z = \theta^T x$$

Obtener $p_{\theta}(Y=0 | X=x)$

$$p(Y=0 | X=x) + p(Y=1 | X=x) = 1$$

Entonces

$$p_{\theta}(Y=1 | X=x) = 1 - p_{\theta}(Y=0 | X=x)$$

$$\text{Como: } p_{\theta}(Y=1 | X=x) = h_{\theta}(x)$$

$$p_{\theta}(Y=0 | X=x) = 1 - h_{\theta}(x)$$

$$p_{\theta}(Y=0 | X=x) = 1 - \frac{1}{1 + e^{-\theta^T X}} = \frac{e^{-\theta^T X}}{1 + e^{-\theta^T X}}$$

④

$$p_{\theta}(y=0 | X=x) = \frac{1}{1 + e^{\theta^T x}}$$

Als es das probabilistische Grundan:

$$\left. \begin{aligned} p_{\theta}(y=1 | X=x) &= h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}} \\ p_{\theta}(y=0 | X=x) &= 1 - h_{\theta}(x) = \frac{1}{1 + e^{\theta^T x}} \end{aligned} \right\}$$

①

x) punto 5:

Likelihood y función de costo logística:

Una vez obtenida $h_{\theta}(x)$, cada observación puede interpretarse probabilísticamente.Para $y=1$ el modelo asigna una probabilidad $h_{\theta}(x)$; para $y=0$ asigna $1-h_{\theta}(x)$.

A partir de ambas probabilidades se construye una única expresión para la verosimilitud

1) Escriba una expresión única para

$$p(y^{(i)} | x^{(i)}; \theta) = ?$$

partiendo de la hipótesis logística:

$$h_{\theta}(x) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

Además

$$p_{\theta}(Y=1 | X=x) = h_{\theta}(x)$$

$$p_{\theta}(Y=0 | X=x) = 1 - h_{\theta}(x)$$

Queremos una sola fórmula que funcione para $y^{(i)}=1$ como para $y^{(i)}=0$

La expresión es:

$$p(y^{(i)} | x^{(i)}; \theta) = [h_{\theta}(x^{(i)})]^{y^{(i)}} [1 - h_{\theta}(x^{(i)})]^{1-y^{(i)}}$$

Veremos si funciona

$$\text{Si } y^{(i)}=1 \quad p(y^{(i)} | x^{(i)}; \theta) = h_{\theta}(x^{(i)})$$

$$\text{Si } y^{(i)}=0 \quad p(y^{(i)} | x^{(i)}; \theta) = 1 - h_{\theta}(x^{(i)})$$

para ambas clases la fórmula funciona

*)

⑦

2) Construye la Verosimilitud para m observaciones

*) Suponiendo que las observaciones son independientes, la Verosimilitud es el producto de las probabilidades individuales

$$L(\theta) = \prod_{i=1}^m p(y_i | x_i; \theta)$$

Sustituyendo la expresión anterior presentada

$$L(\theta) = \prod_{i=1}^m [h_{\theta}(x_i)]^{y_i} [1 - h_{\theta}(x_i)]^{1-y_i}$$

*) Esta función mide que tan probable es observar todos los datos para un valor de θ

2) Calcular la Log-Verosimilitud

Definimos:

$$\ell(\theta) = \log L(\theta)$$

$$\ell(\theta) = \log \left[\prod_{i=1}^m [h_{\theta}(x_i)]^{y_i} [1 - h_{\theta}(x_i)]^{1-y_i} \right] \quad \text{Usamos} \quad \log \left(\prod_{i=1}^m a_i \right) = \sum_{i=1}^m \log(a_i)$$

$$\ell(\theta) = \sum_{i=1}^m \log [h_{\theta}(x_i)^{y_i} (1 - h_{\theta}(x_i))^{1-y_i}]$$

$$\ell(\theta) = y_i \log(h_{\theta}(x_i)) + (1-y_i) \log(1-h_{\theta}(x_i))$$

4) Cambiar el signo y normalizar por m para obtener $J(\theta)$

En máxima Verosimilitud queremos maximizar $\ell(\theta)$

Para normalizar los algoritmos de optimización se escriben como problemas de minimización

$$J(\theta) = -\frac{1}{m} \ell(\theta)$$

3

• Sustituyendo:

$$J(\theta) = -\frac{1}{M} \sum_{i=1}^M \left[y^{(i)} \log h_{\theta}(x^{(i)}) + (1-y^{(i)}) \log (1-h_{\theta}(x^{(i)})) \right]$$

podemos escribir el coste para una sola observación como

$$\text{Cost}(h_{\theta}(x^{(i)}), y^{(i)}) = -[y^{(i)} \log h_{\theta}(x^{(i)}) + (1-y^{(i)}) \log (1-h_{\theta}(x^{(i)}))]$$

y entonces:

$$J(\theta) = \frac{1}{M} \sum_{i=1}^M \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)})$$

5) Identificar la entropía cruzada binaria.

• La expresión $-[y \log(p) + (1-y) \log(1-p)]$ es precisamente la entropía cruzada binaria. En nuestro modelo $p = h_{\theta}(x)$

por tanto

$$\text{BCE} = -[y \log h_{\theta}(x) + (1-y) \log (1-h_{\theta}(x))]$$

y la función total es el promedio

$$J(\theta) = \frac{1}{M} \sum_{i=1}^M \text{BCE}^{(i)}$$

La idea:

6) Calcular $\frac{\partial J}{\partial \theta}$

$$J(\theta) = -\frac{1}{M} \sum_{i=1}^M \left[y^{(i)} \log h_{\theta}(x^{(i)}) + (1-y^{(i)}) \log (1-h_{\theta}(x^{(i)})) \right]$$

para simplificar $h_i = h_{\theta}(x^{(i)})$

(4)

Entropy:

$$J(\theta) = -\frac{1}{n} \sum_{i=1}^n [y^{(i)} \log h_i + (1-y^{(i)}) \log (1-h_i)]$$

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{n} \sum_{i=1}^n \frac{\partial}{\partial \theta_j} [y^{(i)} \log h_i + (1-y^{(i)}) \log (1-h_i)]$$

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{n} \sum_{i=1}^n \left[y^{(i)} \frac{1}{h_i} \frac{\partial h_i}{\partial \theta_j} + (1-y^{(i)}) \frac{1}{1-h_i} (-1) \frac{\partial h_i}{\partial \theta_j} \right]$$

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{n} \sum_{i=1}^n \left[\frac{y^{(i)}}{h_i} - \frac{(1-y^{(i)})}{1-h_i} \right] \frac{\partial h_i}{\partial \theta_j}$$

Above Numpy Calculus

$$\frac{\partial h_i}{\partial \theta_j} \quad h_i = \sigma(\theta^T x^{(i)})$$

$$1 - \frac{1}{1+e^{-z}} = \frac{1+e^{-z}}{1+e^{-z}} = \frac{e^{-z}}{1+e^{-z}} = \frac{1}{e^z+1}$$

$$z_i = \theta^T x^{(i)}, \quad h_i = \sigma(z_i)$$

$$\frac{\partial h_i}{\partial \theta_j} = \frac{\partial h_i}{\partial z} \cdot \frac{\partial z_i}{\partial \theta_j} = \sigma'(z_i) \frac{\partial z_i}{\partial \theta_j}$$

$$\sigma(z) = \frac{1}{1+e^{-z}}, \quad \sigma'(z) = \frac{-(-1)e^{-z}}{(1+e^{-z})^2} = \frac{e^{-z}}{(1+e^{-z})^2} = \frac{e^{-z}}{(1+e^{-z})} \cdot \frac{1}{(1+e^{-z})}$$

$$= \frac{1}{(1+e^{-z})} \left[\frac{1}{e^z(1+e^{-z})} \right] = \frac{1}{(1+e^{-z})} \left[\frac{1}{1+e^z} \right] = \frac{1}{(1+e^{-z})} \left[1 - \frac{1}{1+e^{-z}} \right]$$

$$= \sigma(z)(1-\sigma(z))$$

$$\sigma'(z_i) = h_i(1-h_i)$$

x) Admés,

①

$$\bullet \quad z_i = \theta^T X^{(i)} = \sum_{k=0}^n \theta_k X_k^{(i)}$$

$$\frac{\partial z_i}{\partial \theta_j} = \sum_{k=0}^n \frac{\partial \theta_k}{\partial \theta_j} X_k^{(i)} = \sum_{k=0}^n \delta_{kj} X_k^{(i)} = X_j^{(i)}$$

Así

$$\frac{\partial h_i}{\partial \theta_j} = h_i(1-h_i) X_j^{(i)}$$

Substituyendo

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{n} \sum_{i=1}^n \left[\frac{y^{(i)}}{h_i} - \frac{1-y^{(i)}}{1-h_i} \right] h_i(1-h_i) X_j^{(i)}$$

$$\bullet = -\frac{1}{n} \sum_{i=1}^n \left[y^{(i)} [1-h_i] - (1-y^{(i)}) h_i \right] X_j^{(i)}$$

$$y^{(i)} - y^{(i)} h_i - h_i + y^{(i)} h_i = y^{(i)} - h_i$$

por lo tanto:

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{n} \sum_{i=1}^n (y^{(i)} - h_i) X_j^{(i)}$$

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{n} \sum_{i=1}^n (h_i - y^{(i)}) X_j^{(i)}$$

⑦ Regla de descenso por gradiente:

$$\bullet \quad \theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$$

Substituyendo el gradiente

$$\theta_j := \theta_j + \frac{1}{n} \sum_{i=1}^n (y^{(i)} - h_i) X_j^{(i)}$$

⑥

Substituyendo el gradiente:

$$\theta_j := \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_{j,i}$$

para $j = 0, 1, 2, \dots, n$

Las actualizaciones deben hacerse simultaneamente

En forma Vectorial

$$\theta^{(k+1)} = \theta^{(k)} - \frac{\alpha}{m} X^T (h_{\theta}(X) - y)$$

Donde $h_{\theta}(X)$ representa el vector de probabilidades predichas.

X) Comparar el gradiente con convergencia lineal

En Regresión lineal habíamos llegado:

$$\frac{\partial J_{lin}}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_{j,i}$$

En regresión logística necesitamos obtener

$$\frac{\partial J_{log}}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_{j,i}$$

La forma Algebraica es la misma pero no significa que ambos modelos sean iguales

La diferencia esta en:

para regresión lineal $h_{\theta}(x) = \theta^T x$

mientras para regresión logística

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

generando el 3 parametro

4)

Además las funciones de costo son distintas

$$J_{\text{lin}}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 \quad \rightarrow \text{Regresión lineal}$$

Regresión logística

$$J_{\text{log}}(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)}))]$$

Así que tenemos la coincidencia:

$\nabla J_{\text{lineal}} \quad \nabla J_{\text{logística}}$ tienen la misma estructura

$$\frac{1}{m} \sum_i (\text{predicción} - \text{valor real}) X_j(i)$$

En regresión lineal

$$\boxed{\text{predicción} = \theta^T x}$$

Regresión logística

$$\boxed{\text{predicción} = \sigma(\theta^T x)}$$

6)

①

Regularización

Un buen Ajuste sobre los datos de entrenamiento no garantiza necesariamente una buena generalización. Una buena forma de controlar modelos con parámetros grandes es añadir una penalización a la función de costo. para regularización L_2 ,

$$\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

El parámetro λ controla cuánto pesa esta penalización frente al ajuste de los datos

1) Costo Regularizado para regresión lineal.

En regresión lineal tenemos:

$$J_{\text{datos}}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Con $h_{\theta}(x) = \theta^T x$

Ahora añadimos la penalización L_2 :

$$\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

por lo tanto la nueva función de costo es

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

podemos pensar de como:

$$J(\theta) = J_{\text{datos}}(\theta) + J_{\text{reg}}(\theta)$$

$$\text{donde } J_{\text{reg}}(\theta) = \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

! El primer término intenta ajustar bien los datos y

el segundo evita que los parámetros θ_j se hagan

excesivamente grandes.

(2)

2) calculăm $\frac{\partial J}{\partial \theta_j}$ pentru $j \geq 1$

primul de:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{k=1}^n \theta_k^2$$

Derivăm:

$$\frac{\partial J}{\partial \theta_j} = \frac{\partial J_{data}}{\partial \theta_j} + \frac{\partial J_{reg}}{\partial \theta_j}$$

De la exercitiu anterior se poate scrie:

$$\frac{\partial J_{data}}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

Ahora derivăm de la termenul de regularizare:

$$\frac{\partial}{\partial \theta_j} \left[\frac{\lambda}{2m} \sum_{k=1}^n \theta_k^2 \right]$$

Scriem λ ca constantă:

$$= \frac{\lambda}{2m} \frac{\partial}{\partial \theta_j} [\theta_1^2 + \theta_2^2 + \theta_3^2 + \dots + \theta_n^2] = \frac{\lambda}{2m} \frac{\partial \theta_j^2}{\partial \theta_j} = \frac{\lambda}{2m} \cdot 2\theta_j = \frac{\lambda}{m} \theta_j$$

pentru $j \geq 1$ se poate scrie:

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j$$

Este deci el gradientul regularizate de regresie liniară.

3) caso $\lambda = 0$

3)

La penalización es:

$$\frac{\lambda}{2m} \sum_{i=1}^n \theta_i^2$$

No contiene θ_0 por tanto, $\frac{\partial J_{reg}}{\partial \theta_0} = 0$

Así que:

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_0^{(i)}$$

$$x_0^{(i)} = 1$$

Obtenemos

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) \quad \text{No aparece } \frac{\lambda \theta_0}{m}$$

4) Actualización para $j \geq 1$

La regla del descenso por gradiente es:

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$$

Sustituimos el gradiente que acabamos de obtener:

$$\theta_j := \theta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \right]$$

$$\theta_j := \theta_j - \alpha \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda \alpha}{m} \theta_j$$

$$\theta_j := \theta_j - \frac{\alpha \lambda}{m} \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)} \quad j=1, \dots, n$$

4)

Reorganizar la actualización

tenemos:

$$\theta_j = \theta_j - \frac{\alpha \lambda}{m} \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

Los dos primeros términos contienen θ_j

$$\theta_j - \frac{\alpha \lambda}{m} \theta_j$$

Factorizamos

$$\theta_j \left(1 - \frac{\alpha \lambda}{m}\right) \theta_j$$

Así:

$$\theta_j = \theta_j \left(1 - \frac{\alpha \lambda}{m}\right) - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

$j \geq 1$

El término de datos exactamente:

$$\frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

El intérprete es factor

$$1 - \frac{\alpha \lambda}{m}$$

Este factor tiene una interpretación aún más importante:

$$\boxed{1 - \frac{\alpha \lambda}{m}}$$

(5)

multiplica por el parámetro θ_i

Si queremos momentaneamente los datos tendríamos

$$\theta_i^{\text{nuevo}} = \left(1 - \frac{\alpha \lambda}{m}\right) \theta_i^{\text{viejo}}$$

Normalmente se escogen valores:

$$0 < 1 - \frac{\alpha \lambda}{m} < 1$$

Entonces el valor absoluto θ_i disminuye en cada actualización

por ejemplo si

$$1 - \frac{\alpha \lambda}{m} = 0.9 \quad \text{Entonces:}$$

$$\theta_i^{\text{nuevo}} = 0.9 \theta_i^{\text{viejo}}$$

$$\text{Si } \theta_i = 10$$

Se convierte, antes de considerar el término de datos, en 9.5

$$\text{Si } \theta_i = -10 \text{ obtenemos } -9.5$$

En ambos casos el parámetro se acerca a cero.

Este efecto se llama **Weight decay**.

Podemos pensar de la actualización como dos fuentes.

$$\theta_i \left(1 - \frac{\alpha \lambda}{m}\right) - \frac{\alpha}{m} \sum_i (h_\theta(x^{(i)}) - y^{(i)}) x_{j,i}$$

datos: busca mejorar el ajuste

↳ Regularización empírica hacia cero

Si $\lambda = 0$ no hay regularización

Si λ aumenta, se penaliza más se vuelve más fuerte.

Si λ es muy grande puede aparecer sobreajuste.

(6)

7) Coste Regularizado para Regresión Logística

En regresión logística sin regularización

$$J_{\text{log}}(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1-y^{(i)}) \log (1-h_{\theta}(x^{(i)}))]$$

Añadimos exactamente la misma penalización L_2 :

$$\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

Entonces:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1-y^{(i)}) \log (1-h_{\theta}(x^{(i)}))] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

Donde ahora:

$$h_{\theta}(x) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

Es decir

$J_{\text{log, reg}} =$ Entropía cruzada + penalización L_2

8) Gradiente para Regresión Logística Regularizada

$$\frac{\partial J_{\text{data}}}{\partial \theta_1} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_{i1}$$

La parte de regularización es:

$$J_{\text{reg}}(\theta) = \frac{\lambda}{2m} \sum_{k=1}^n \theta_k^2$$

④

por tanto: para $j \geq 1$

$$\frac{\partial J_{reg}}{\partial \theta_j} = \frac{\lambda}{n} \theta_j$$

Sumando ambas contribuciones

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)}) x_{j,i} + \frac{\lambda}{n} \theta_j$$

para $j=0$

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})$$

para $j \geq 1$

$$\theta_j := \theta_j \left(1 - \frac{2\lambda}{n} \right) - \frac{\lambda}{n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)}) x_{j,i}$$

y para el intercepto

$$\theta_0 := \theta_0 - \frac{\lambda}{n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})$$

q) ¿por qué normalmente no se regulariza θ_0

* Regularizar θ_0 penaliza innecesariamente el nivel bias del modelo y además,

habría que tener en cuenta que la solución dependería de donde estemos el origen o centro de las variables

θ_0 no se regulariza porque representa el intercepto, no el efecto de una característica.

Taller: Regresión Lineal y Regresión Logística

Desarrollo matemático paso a paso

Índice

1. Regresión lineal multivariada desde máxima verosimilitud	4
1.1. Distribución condicional	4
1.2. Densidad condicional	5
1.3. Función de verosimilitud	5
1.4. Log-verosimilitud	6
1.5. Función de costo	6
2. Gradiente y descenso por gradiente	6
2.1. Derivada de la hipótesis	7
2.2. Gradiente de la función de costo	7
2.3. Descenso por gradiente	7
2.4. Actualización simultánea	8
3. Ecuación normal	8
3.1. Expansión de la función de costo	9
3.2. Gradiente	10
3.3. Condición de mínimo	11
3.4. Solución analítica	11
3.5. Comparación con descenso por gradiente	11
4. Regresión logística desde la familia exponencial	12
4.1. Bernoulli en forma exponencial	12
4.2. Parámetro natural	12
4.3. Despeje de ϕ	13
4.4. Forma canónica de Bernoulli	14
4.5. Introducción del modelo lineal	14
4.6. Hipótesis logística	14
4.7. Probabilidad de $Y = 0$	15
5. Likelihood y función de costo logística	15
5.1. Expresión probabilística única	15
5.2. Verosimilitud	16
5.3. Log-verosimilitud	16
5.4. Función de costo logística	17
5.5. Entropía cruzada binaria	17
5.6. Gradiente de la función de costo	17
5.7. Descenso por gradiente	19

5.8. Comparación con regresión lineal	19
6. Regularización	19
6.1. Costo regularizado para regresión lineal	20
6.2. Gradiente para $j \geq 1$	20
6.3. Caso $j = 0$	21
6.4. Actualización para $j \geq 1$	22
6.5. Interpretación del factor de decaimiento	22
6.6. Costo regularizado para regresión logística	23
6.7. Gradiente logístico regularizado	24
6.8. ¿Por qué no se regulariza θ_0 ?	24
7. Resumen de resultados	25
7.1. Regresión lineal	25
7.2. Regresión logística	25
7.3. Regularización L_2	26

1. Regresión lineal multivariada desde máxima verosimilitud

Considérese el conjunto de datos

$$D = \{(x^{(i)}, y^{(i)})\}_{i=1}^m,$$

donde cada vector de características se escribe como

$$x^{(i)} = \begin{bmatrix} 1 \\ x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix},$$

y el vector de parámetros es

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}.$$

El modelo de regresión lineal se define mediante

$$Y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)},$$

donde

$$\varepsilon^{(i)} \sim \mathcal{N}(0, \sigma^2).$$

Definimos la hipótesis

$$h_\theta(x^{(i)}) = \theta^T x^{(i)}.$$

Explícitamente,

$$h_\theta(x^{(i)}) = \theta_0 + \theta_1 x_1^{(i)} + \cdots + \theta_n x_n^{(i)}.$$

1.1. Distribución condicional

Partimos de

$$Y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)}.$$

La esperanza condicional es

$$\mathbb{E}[Y^{(i)} \mid X = x^{(i)}] = \mathbb{E}[\theta^T x^{(i)} + \varepsilon^{(i)}] \tag{1}$$

$$= \theta^T x^{(i)} + \mathbb{E}[\varepsilon^{(i)}]. \tag{2}$$

Como

$$\mathbb{E}[\varepsilon^{(i)}] = 0,$$

se obtiene

$$\mathbb{E} [Y^{(i)} \mid X = x^{(i)}] = \theta^T x^{(i)}$$

Por otra parte,

$$\text{Var} (Y^{(i)} \mid X = x^{(i)}) = \text{Var} (\theta^T x^{(i)} + \varepsilon^{(i)}) \quad (3)$$

$$= \text{Var} (\varepsilon^{(i)}) \quad (4)$$

$$= \sigma^2. \quad (5)$$

Por tanto,

$$Y^{(i)} \mid X = x^{(i)} \sim \mathcal{N} (\theta^T x^{(i)}, \sigma^2)$$

1.2. Densidad condicional

La densidad de una variable aleatoria normal es

$$p(y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y - \mu)^2}{2\sigma^2} \right].$$

En nuestro caso,

$$\mu = \theta^T x^{(i)}.$$

Por consiguiente,

$$p(y^{(i)} \mid x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right]$$

1.3. Función de verosimilitud

Suponiendo que las observaciones son independientes,

$$L(\theta) = \prod_{i=1}^m p(y^{(i)} \mid x^{(i)}; \theta).$$

Sustituyendo la distribución normal,

$$L(\theta) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right].$$

Entonces,

$$L(\theta) = \left(\frac{1}{\sqrt{2\pi\sigma}} \right)^m \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2 \right]$$

1.4. Log-verosimilitud

Definimos

$$\ell(\theta) = \log L(\theta).$$

Por tanto,

$$\ell(\theta) = -\frac{m}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2$$

El primer término no depende de θ .

Además,

$$-\frac{1}{2\sigma^2} < 0.$$

Por consiguiente, maximizar $\ell(\theta)$ equivale a minimizar

$$\sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2.$$

Así,

$$\arg \max_{\theta} \ell(\theta) = \arg \min_{\theta} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

1.5. Función de costo

Definimos

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

El factor $1/m$ convierte la suma en un error promedio, mientras que el factor $1/2$ simplifica las derivadas debido a que

$$\frac{d}{dz} \left(\frac{1}{2} z^2 \right) = z.$$

Además,

$$\frac{1}{2m} > 0,$$

de modo que multiplicar por esta constante no modifica la posición del mínimo.

2. Gradiente y descenso por gradiente

Partimos de

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2.$$

2.1. Derivada de la hipótesis

La hipótesis puede escribirse como

$$h_{\theta}(x^{(i)}) = \sum_{k=0}^n \theta_k x_k^{(i)}.$$

Por tanto,

$$\boxed{\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} = x_j^{(i)}}$$

para

$$j = 0, \dots, n.$$

2.2. Gradiente de la función de costo

Derivamos respecto a θ_j :

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{2m} \sum_{i=1}^m \frac{\partial}{\partial \theta_j} \left[(h_{\theta}(x^{(i)}) - y^{(i)})^2 \right].$$

Aplicando la regla de la cadena,

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{2m} \sum_{i=1}^m 2 (h_{\theta}(x^{(i)}) - y^{(i)}) \frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j}.$$

Como

$$\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} = x_j^{(i)},$$

obtenemos

$$\boxed{\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}}$$

2.3. Descenso por gradiente

La regla general de descenso por gradiente es

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j},$$

donde α es la tasa de aprendizaje.

Sustituyendo el gradiente,

$$\boxed{\theta_j := \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}}$$

para

$$j = 0, \dots, n.$$

Para el intercepto, como

$$x_0^{(i)} = 1,$$

tenemos

$$\theta_0 := \theta_0 - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

2.4. Actualización simultánea

Todas las componentes del gradiente deben calcularse utilizando el mismo vector de parámetros $\theta^{(k)}$.

En forma vectorial,

$$\theta^{(k+1)} = \theta^{(k)} - \alpha \nabla J(\theta^{(k)})$$

Por tanto, primero se calculan todas las componentes del gradiente y posteriormente se actualizan simultáneamente los parámetros.

3. Ecuación normal

Definimos la matriz de diseño

$$X = \begin{bmatrix} 1 & x_1^{(1)} & \cdots & x_n^{(1)} \\ 1 & x_1^{(2)} & \cdots & x_n^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & \cdots & x_n^{(m)} \end{bmatrix},$$

el vector de observaciones

$$y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix},$$

y

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}.$$

Equivalentemente,

$$X = \begin{bmatrix} (x^{(1)})^T \\ (x^{(2)})^T \\ \vdots \\ (x^{(m)})^T \end{bmatrix}.$$

Las dimensiones son

$$X \in \mathbb{R}^{m \times (n+1)},$$

$$\theta \in \mathbb{R}^{(n+1) \times 1},$$

$$y \in \mathbb{R}^{m \times 1}.$$

Además,

$$X\theta = \begin{bmatrix} h_{\theta}(x^{(1)}) \\ h_{\theta}(x^{(2)}) \\ \vdots \\ h_{\theta}(x^{(m)}) \end{bmatrix}.$$

La función de costo puede escribirse como

$$J(\theta) = \frac{1}{2m} (X\theta - y)^T (X\theta - y)$$

3.1. Expansión de la función de costo

Tenemos

$$(X\theta - y)^T = \theta^T X^T - y^T.$$

Entonces,

$$(X\theta - y)^T (X\theta - y) = (\theta^T X^T - y^T)(X\theta - y) \quad (6)$$

$$= \theta^T X^T X\theta - \theta^T X^T y - y^T X\theta + y^T y. \quad (7)$$

El término

$$y^T X\theta$$

es un escalar, ya que sus dimensiones son

$$(1 \times m)(m \times (n+1))((n+1) \times 1) = 1 \times 1.$$

Como es un escalar,

$$y^T X\theta = (y^T X\theta)^T.$$

Por tanto,

$$y^T X \theta = \theta^T X^T y.$$

Así,

$$(X\theta - y)^T (X\theta - y) = \theta^T X^T X \theta - 2\theta^T X^T y + y^T y$$

y

$$J(\theta) = \frac{1}{2m} [\theta^T X^T X \theta - 2\theta^T X^T y + y^T y]$$

3.2. Gradiente

Utilizamos la identidad

$$\nabla_{\theta}(\theta^T A \theta) = (A + A^T)\theta.$$

Tomamos

$$A = X^T X.$$

Como

$$(X^T X)^T = X^T X,$$

la matriz es simétrica y por tanto

$$\nabla_{\theta}(\theta^T X^T X \theta) = 2X^T X \theta.$$

También,

$$\nabla_{\theta}(-2\theta^T X^T y) = -2X^T y,$$

mientras que

$$\nabla_{\theta}(y^T y) = 0.$$

Por consiguiente,

$$\nabla_{\theta} J(\theta) = \frac{1}{2m} (2X^T X \theta - 2X^T y).$$

Finalmente,

$$\nabla_{\theta} J(\theta) = \frac{1}{m} (X^T X \theta - X^T y)$$

o equivalentemente,

$$\nabla_{\theta} J(\theta) = \frac{1}{m} X^T (X\theta - y)$$

3.3. Condición de mínimo

En el mínimo,

$$\nabla_{\theta} J(\theta) = 0.$$

Entonces,

$$\frac{1}{m} (X^T X \theta - X^T y) = 0.$$

Multiplicando por m ,

$$X^T X \theta - X^T y = 0.$$

Por tanto,

$$\boxed{X^T X \theta = X^T y}$$

Esta expresión recibe el nombre de **ecuación normal**.

3.4. Solución analítica

Si $X^T X$ es invertible,

$$(X^T X)^{-1} X^T X \theta = (X^T X)^{-1} X^T y.$$

Como

$$(X^T X)^{-1} X^T X = I,$$

obtenemos

$$\boxed{\hat{\theta} = (X^T X)^{-1} X^T y}$$

3.5. Comparación con descenso por gradiente

El descenso por gradiente es un método iterativo:

$$\boxed{\theta^{(k+1)} = \theta^{(k)} - \frac{\alpha}{m} X^T (X \theta^{(k)} - y)}$$

Necesita una condición inicial, una tasa de aprendizaje y múltiples iteraciones. La ecuación normal proporciona una solución analítica:

$$\boxed{\hat{\theta} = (X^T X)^{-1} X^T y}$$

cuando $X^T X$ es invertible.

La inversión falla cuando

$$\det(X^T X) = 0.$$

Esto ocurre cuando X no tiene rango columna completo:

$$\boxed{\text{rank}(X) < n + 1}$$

Por tanto, la condición de invertibilidad es

$$\boxed{\text{rank}(X) = n + 1}$$

4. Regresión logística desde la familia exponencial

Para clasificación binaria,

$$Y \in \{0, 1\}.$$

La distribución Bernoulli está dada por

$$p(y; \phi) = \phi^y (1 - \phi)^{1-y}.$$

La forma general de una distribución perteneciente a la familia exponencial es

$$p(y; \eta) = b(y) \exp [\eta T(y) - a(\eta)].$$

4.1. Bernoulli en forma exponencial

Partimos de

$$p(y; \phi) = \phi^y (1 - \phi)^{1-y}.$$

Utilizando

$$a^b = e^{b \log a},$$

tenemos

$$p(y; \phi) = \exp [y \log \phi + (1 - y) \log(1 - \phi)].$$

Expandimos:

$$p(y; \phi) = \exp [y \log \phi + \log(1 - \phi) - y \log(1 - \phi)].$$

Agrupando los términos que contienen y ,

$$\boxed{p(y; \phi) = \exp \left[y \log \left(\frac{\phi}{1 - \phi} \right) + \log(1 - \phi) \right]}$$

4.2. Parámetro natural

Comparando con

$$p(y; \eta) = b(y) \exp [\eta T(y) - a(\eta)],$$

identificamos

$$T(y) = y, \quad b(y) = 1,$$

y

$$\boxed{\eta = \log \left(\frac{\phi}{1 - \phi} \right)}$$

La transformación

$$\log \left(\frac{\phi}{1 - \phi} \right)$$

se denomina **logit**.

4.3. Despeje de ϕ

Partimos de

$$\eta = \log \left(\frac{\phi}{1 - \phi} \right).$$

Aplicamos la exponencial:

$$e^\eta = \frac{\phi}{1 - \phi}.$$

Multiplicamos por $1 - \phi$:

$$e^\eta(1 - \phi) = \phi.$$

Distribuyendo,

$$e^\eta - e^\eta\phi = \phi.$$

Agrupamos los términos que contienen ϕ :

$$e^\eta = \phi + e^\eta\phi.$$

Factorizando,

$$e^\eta = \phi(1 + e^\eta).$$

Por tanto,

$$\phi = \frac{e^\eta}{1 + e^\eta}.$$

Dividiendo numerador y denominador por e^η ,

$$\boxed{\phi = \frac{1}{1 + e^{-\eta}}}$$

4.4. Forma canónica de Bernoulli

Como

$$\phi = \frac{e^\eta}{1 + e^\eta},$$

entonces

$$1 - \phi = \frac{1}{1 + e^\eta}.$$

Por tanto,

$$\log(1 - \phi) = -\log(1 + e^\eta).$$

Sustituyendo,

$$p(y; \eta) = \exp[y\eta - \log(1 + e^\eta)].$$

Así,

$$\boxed{b(y) = y, \quad T(y) = y, \quad a(\eta) = \log(1 + e^\eta)}$$

4.5. Introducción del modelo lineal

Tomamos

$$\eta = \theta^T x.$$

Entonces,

$$\phi = \frac{1}{1 + e^{-\theta^T x}}.$$

Como para una distribución Bernoulli

$$P(Y = 1) = \phi,$$

obtenemos

$$\boxed{P_\theta(Y = 1 \mid X = x) = \frac{1}{1 + e^{-\theta^T x}}}$$

4.6. Hipótesis logística

Definimos

$$\boxed{h_\theta(x) = \frac{1}{1 + e^{-\theta^T x}}}$$

o equivalentemente,

$$\boxed{h_\theta(x) = \sigma(\theta^T x)}$$

donde la función sigmoide es

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Por tanto,

$$P_{\theta}(Y = 1 \mid X = x) = h_{\theta}(x)$$

4.7. Probabilidad de $Y = 0$

Como

$$P(Y = 0 \mid X = x) + P(Y = 1 \mid X = x) = 1,$$

tenemos

$$P_{\theta}(Y = 0 \mid X = x) = 1 - h_{\theta}(x).$$

Explícitamente,

$$1 - h_{\theta}(x) = 1 - \frac{1}{1 + e^{-\theta^T x}}.$$

Entonces,

$$P_{\theta}(Y = 0 \mid X = x) = \frac{1}{1 + e^{\theta^T x}}$$

5. Likelihood y función de costo logística

Partimos de

$$P_{\theta}(Y = 1 \mid X = x) = h_{\theta}(x),$$

$$P_{\theta}(Y = 0 \mid X = x) = 1 - h_{\theta}(x),$$

con

$$h_{\theta}(x) = \sigma(\theta^T x).$$

5.1. Expresión probabilística única

Para una observación i , ambas posibilidades pueden escribirse como

$$p(y^{(i)} \mid x^{(i)}; \theta) = [h_{\theta}(x^{(i)})]^{y^{(i)}} [1 - h_{\theta}(x^{(i)})]^{1-y^{(i)}}$$

Si $y^{(i)} = 1$,

$$p = h_{\theta}(x^{(i)})^1 [1 - h_{\theta}(x^{(i)})]^0 = h_{\theta}(x^{(i)}).$$

Si $y^{(i)} = 0$,

$$p = h_{\theta}(x^{(i)})^0 [1 - h_{\theta}(x^{(i)})]^1 = 1 - h_{\theta}(x^{(i)}).$$

5.2. Verosimilitud

Suponiendo independencia entre las m observaciones,

$$L(\theta) = \prod_{i=1}^m p(y^{(i)} | x^{(i)}; \theta).$$

Por tanto,

$$L(\theta) = \prod_{i=1}^m [h_{\theta}(x^{(i)})]^{y^{(i)}} [1 - h_{\theta}(x^{(i)})]^{1-y^{(i)}}$$

5.3. Log-verosimilitud

Definimos

$$\ell(\theta) = \log L(\theta).$$

Entonces,

$$\ell(\theta) = \log \left[\prod_{i=1}^m h_{\theta}(x^{(i)})^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{1-y^{(i)}} \right]. \quad (8)$$

Utilizando

$$\log \left(\prod_i a_i \right) = \sum_i \log(a_i),$$

obtenemos

$$\ell(\theta) = \sum_{i=1}^m \log \left[h_{\theta}(x^{(i)})^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{1-y^{(i)}} \right].$$

Aplicando

$$\log(ab) = \log a + \log b$$

y

$$\log(a^b) = b \log a,$$

llegamos a

$$\ell(\theta) = \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)}))]$$

5.4. Función de costo logística

Máxima verosimilitud busca maximizar

$$\ell(\theta).$$

Equivalentemente, podemos minimizar la log-verosimilitud negativa.

Definimos

$$J(\theta) = -\frac{1}{m}\ell(\theta).$$

Por tanto,

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)}))]$$

5.5. Entropía cruzada binaria

Para una sola observación,

$$\text{BCE}(y, h) = -[y \log h + (1 - y) \log(1 - h)]$$

Esta función recibe el nombre de **entropía cruzada binaria** (*Binary Cross-Entropy*).

En regresión logística,

$$h = h_{\theta}(x).$$

Por tanto,

$$\text{BCE} = -[y \log h_{\theta}(x) + (1 - y) \log (1 - h_{\theta}(x))]$$

y

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{BCE}^{(i)}$$

5.6. Gradiente de la función de costo

Definimos, para simplificar,

$$h_i = h_{\theta}(x^{(i)}).$$

Entonces,

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_i + (1 - y^{(i)}) \log(1 - h_i)].$$

Derivando respecto a θ_j ,

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{m} \sum_{i=1}^m \left[\frac{y^{(i)}}{h_i} - \frac{1 - y^{(i)}}{1 - h_i} \right] \frac{\partial h_i}{\partial \theta_j}.$$

Ahora,

$$h_i = \sigma(z_i),$$

con

$$z_i = \theta^T x^{(i)}.$$

Aplicando regla de la cadena,

$$\frac{\partial h_i}{\partial \theta_j} = \sigma'(z_i) \frac{\partial z_i}{\partial \theta_j}.$$

Sabemos que

$$\sigma'(z) = \sigma(z)(1 - \sigma(z)).$$

Por tanto,

$$\sigma'(z_i) = h_i(1 - h_i).$$

Además,

$$\frac{\partial z_i}{\partial \theta_j} = x_j^{(i)}.$$

Así,

$$\boxed{\frac{\partial h_i}{\partial \theta_j} = h_i(1 - h_i)x_j^{(i)}}$$

Sustituyendo,

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{m} \sum_{i=1}^m \left[\frac{y^{(i)}}{h_i} - \frac{1 - y^{(i)}}{1 - h_i} \right] h_i(1 - h_i)x_j^{(i)}.$$

Simplificando,

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{m} \sum_{i=1}^m [y^{(i)}(1 - h_i) - (1 - y^{(i)})h_i] x_j^{(i)}.$$

Ahora,

$$y^{(i)}(1 - h_i) - (1 - y^{(i)})h_i = y^{(i)} - y^{(i)}h_i - h_i + y^{(i)}h_i \quad (9)$$

$$= y^{(i)} - h_i. \quad (10)$$

Por tanto,

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} - h_i)x_j^{(i)}.$$

Finalmente,

$$\boxed{\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}}$$

5.7. Descenso por gradiente

La regla es

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}.$$

Por tanto,

$$\theta_j := \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

para

$$j = 0, \dots, n.$$

5.8. Comparación con regresión lineal

Para regresión lineal,

$$\frac{\partial J_{\text{lin}}}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}.$$

Para regresión logística,

$$\frac{\partial J_{\text{log}}}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}.$$

Por tanto, ambos tienen la misma estructura:

$$\frac{1}{m} \sum_{i=1}^m (\text{predicción} - \text{valor real}) x_j^{(i)}$$

Sin embargo, las hipótesis son diferentes.

En regresión lineal,

$$h_{\theta}(x) = \theta^T x$$

mientras que en regresión logística,

$$h_{\theta}(x) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

6. Regularización

Un buen ajuste sobre los datos de entrenamiento no garantiza necesariamente una buena generalización.

Para controlar la complejidad del modelo introducimos una penalización sobre la magnitud de sus parámetros.

Para regularización L_2 , utilizamos

$$\boxed{\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2}$$

donde $\lambda \geq 0$ controla la intensidad de la regularización.

Es importante observar que la suma comienza en $j = 1$. Por tanto, θ_0 no se incluye en la penalización.

6.1. Costo regularizado para regresión lineal

El costo sin regularización es

$$J_{\text{datos}}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2.$$

Añadiendo la regularización L_2 ,

$$\boxed{J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2}$$

Podemos escribir

$$J(\theta) = J_{\text{datos}}(\theta) + J_{\text{reg}}(\theta),$$

donde

$$J_{\text{reg}}(\theta) = \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2.$$

6.2. Gradiente para $j \geq 1$

Para evitar confusión entre el índice de la suma y el parámetro respecto al cual derivamos, escribimos

$$J_{\text{reg}}(\theta) = \frac{\lambda}{2m} \sum_{k=1}^n \theta_k^2.$$

Entonces,

$$\frac{\partial J}{\partial \theta_j} = \frac{\partial J_{\text{datos}}}{\partial \theta_j} + \frac{\partial J_{\text{reg}}}{\partial \theta_j}.$$

Del resultado de regresión lineal,

$$\frac{\partial J_{\text{datos}}}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}.$$

Ahora,

$$\frac{\partial J_{\text{reg}}}{\partial \theta_j} = \frac{\lambda}{2m} \frac{\partial}{\partial \theta_j} \sum_{k=1}^n \theta_k^2.$$

Todos los términos con $k \neq j$ tienen derivada cero. Por tanto,

$$\frac{\partial J_{\text{reg}}}{\partial \theta_j} = \frac{\lambda}{2m} \frac{\partial}{\partial \theta_j} \theta_j^2.$$

Como

$$\frac{\partial}{\partial \theta_j} \theta_j^2 = 2\theta_j,$$

se obtiene

$$\frac{\partial J_{\text{reg}}}{\partial \theta_j} = \frac{\lambda}{2m} (2\theta_j).$$

Por consiguiente,

$$\boxed{\frac{\partial J_{\text{reg}}}{\partial \theta_j} = \frac{\lambda}{m} \theta_j}$$

y el gradiente total es

$$\boxed{\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j, \quad j \geq 1}$$

6.3. Caso $j = 0$

La penalización

$$\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

no contiene a θ_0 .

Por tanto,

$$\frac{\partial J_{\text{reg}}}{\partial \theta_0} = 0.$$

Entonces,

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)}.$$

Como

$$x_0^{(i)} = 1,$$

obtenemos

$$\boxed{\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})}$$

6.4. Actualización para $j \geq 1$

La regla general de descenso por gradiente es

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}.$$

Sustituyendo el gradiente regularizado,

$$\theta_j := \theta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \right].$$

Distribuyendo α ,

$$\theta_j := \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)} - \frac{\alpha \lambda}{m} \theta_j.$$

Reordenando,

$$\theta_j := \theta_j - \frac{\alpha \lambda}{m} \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}.$$

Factorizamos θ_j :

$$\theta_j := \left(1 - \frac{\alpha \lambda}{m}\right) \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}, \quad j \geq 1$$

El término asociado a los datos es

$$\frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

6.5. Interpretación del factor de decaimiento

El factor

$$1 - \frac{\alpha \lambda}{m}$$

multiplica al valor anterior del parámetro.

Si ignoramos momentáneamente el término asociado a los datos,

$$\theta_j^{\text{nuevo}} = \left(1 - \frac{\alpha \lambda}{m}\right) \theta_j^{\text{anterior}}.$$

Cuando

$$0 < 1 - \frac{\alpha \lambda}{m} < 1,$$

el valor absoluto de θ_j disminuye.

Por ejemplo, si

$$1 - \frac{\alpha\lambda}{m} = 0,95,$$

entonces

$$\theta_j^{\text{nuevo}} = 0,95\theta_j^{\text{anterior}}.$$

Este comportamiento recibe el nombre de **weight decay** o decaimiento de los pesos. La actualización puede interpretarse como

$$\underbrace{\left(1 - \frac{\alpha\lambda}{m}\right) \theta_j}_{\text{regularización}} - \underbrace{\frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}}_{\text{término de datos}}$$

La regularización empuja los parámetros hacia valores de menor magnitud, mientras que el término de datos busca mejorar el ajuste.

Si

$$\lambda = 0,$$

recuperamos el modelo sin regularización.

Un valor mayor de λ produce una penalización más fuerte. Sin embargo, un valor excesivamente grande puede producir subajuste.

6.6. Costo regularizado para regresión logística

El costo logístico sin regularización es

$$J_{\text{datos}}(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)}))].$$

Añadiendo regularización L_2 ,

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)}))] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

donde

$$h_{\theta}(x) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}.$$

Por tanto,

$$J_{\text{log,reg}} = \text{entropía cruzada} + \text{penalización } L_2$$

6.7. Gradiente logístico regularizado

Sin regularización habíamos obtenido

$$\frac{\partial J_{\text{datos}}}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}.$$

La derivada de la regularización para $j \geq 1$ es

$$\frac{\partial J_{\text{reg}}}{\partial \theta_j} = \frac{\lambda}{m} \theta_j.$$

Por tanto,

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j, \quad j \geq 1$$

Para $j = 0$,

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

La actualización para $j \geq 1$ es

$$\theta_j := \left(1 - \frac{\alpha \lambda}{m}\right) \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

mientras que para el intercepto,

$$\theta_0 := \theta_0 - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

6.8. ¿Por qué no se regulariza θ_0 ?

En regresión lineal,

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \cdots + \theta_n x_n.$$

El parámetro θ_0 representa el **intercepto** o término de sesgo.

Los parámetros

$$\theta_1, \dots, \theta_n$$

determinan la sensibilidad de la predicción frente a las características de entrada.

La regularización busca controlar precisamente la magnitud de estos coeficientes.

Por otro lado, θ_0 determina principalmente el nivel base o desplazamiento global del modelo.

Por esta razón, normalmente se utiliza

$$\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

en lugar de

$$\frac{\lambda}{2m} \sum_{j=0}^n \theta_j^2.$$

Así,

θ_0 normalmente no se regulariza porque representa el intercepto, no el efecto asociado a una característica.

7. Resumen de resultados

Los ejercicios anteriores permiten relacionar regresión lineal, regresión logística, máxima verosimilitud, descenso por gradiente y regularización.

7.1. Regresión lineal

La hipótesis es

$$h_{\theta}(x) = \theta^T x$$

y la función de costo es

$$J_{\text{lin}}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

El gradiente es

$$\frac{\partial J_{\text{lin}}}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

y la ecuación normal proporciona, cuando $X^T X$ es invertible,

$$\hat{\theta} = (X^T X)^{-1} X^T y$$

7.2. Regresión logística

La hipótesis logística es

$$h_{\theta}(x) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

con

$$P_{\theta}(Y = 1 \mid X = x) = h_{\theta}(x)$$

y

$$P_{\theta}(Y = 0 \mid X = x) = 1 - h_{\theta}(x)$$

La función de costo es la entropía cruzada binaria:

$$J_{\log}(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)}))]$$

y su gradiente es

$$\frac{\partial J_{\log}}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

7.3. Regularización L_2

La penalización es

$$J_{\text{reg}}(\theta) = \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

Para $j \geq 1$, el gradiente regularizado tiene la estructura

$$\frac{\partial J}{\partial \theta_j} = \frac{\partial J_{\text{datos}}}{\partial \theta_j} + \frac{\lambda}{m} \theta_j$$

y la actualización puede escribirse como

$$\theta_j := \left(1 - \frac{\alpha \lambda}{m}\right) \theta_j - \text{término de datos}$$

El factor

$$1 - \frac{\alpha \lambda}{m}$$

produce un decaimiento de la magnitud de los parámetros y ayuda a controlar la complejidad del modelo.

Finalmente, θ_0 normalmente no se regulariza debido a que representa el intercepto.