

Taller: Regresión Lineal y Regresión Logística

Desarrollo matemático paso a paso

Índice

1. Regresión lineal multivariada desde máxima verosimilitud	4
1.1. Distribución condicional	4
1.2. Densidad condicional	5
1.3. Función de verosimilitud	5
1.4. Log-verosimilitud	6
1.5. Función de costo	6
2. Gradiente y descenso por gradiente	6
2.1. Derivada de la hipótesis	7
2.2. Gradiente de la función de costo	7
2.3. Descenso por gradiente	7
2.4. Actualización simultánea	8
3. Ecuación normal	8
3.1. Expansión de la función de costo	9
3.2. Gradiente	10
3.3. Condición de mínimo	11
3.4. Solución analítica	11
3.5. Comparación con descenso por gradiente	11
4. Regresión logística desde la familia exponencial	12
4.1. Bernoulli en forma exponencial	12
4.2. Parámetro natural	12
4.3. Despeje de ϕ	13
4.4. Forma canónica de Bernoulli	14
4.5. Introducción del modelo lineal	14
4.6. Hipótesis logística	14
4.7. Probabilidad de $Y = 0$	15
5. Likelihood y función de costo logística	15
5.1. Expresión probabilística única	15
5.2. Verosimilitud	16
5.3. Log-verosimilitud	16
5.4. Función de costo logística	17
5.5. Entropía cruzada binaria	17
5.6. Gradiente de la función de costo	17
5.7. Descenso por gradiente	19

5.8. Comparación con regresión lineal	19
6. Regularización	19
6.1. Costo regularizado para regresión lineal	20
6.2. Gradiente para $j \geq 1$	20
6.3. Caso $j = 0$	21
6.4. Actualización para $j \geq 1$	22
6.5. Interpretación del factor de decaimiento	22
6.6. Costo regularizado para regresión logística	23
6.7. Gradiente logístico regularizado	24
6.8. ¿Por qué no se regulariza θ_0 ?	24
7. Resumen de resultados	25
7.1. Regresión lineal	25
7.2. Regresión logística	25
7.3. Regularización L_2	26

1. Regresión lineal multivariada desde máxima verosimilitud

Considérese el conjunto de datos

$$D = \{(x^{(i)}, y^{(i)})\}_{i=1}^m,$$

donde cada vector de características se escribe como

$$x^{(i)} = \begin{bmatrix} 1 \\ x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix},$$

y el vector de parámetros es

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}.$$

El modelo de regresión lineal se define mediante

$$Y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)},$$

donde

$$\varepsilon^{(i)} \sim \mathcal{N}(0, \sigma^2).$$

Definimos la hipótesis

$$h_\theta(x^{(i)}) = \theta^T x^{(i)}.$$

Explícitamente,

$$h_\theta(x^{(i)}) = \theta_0 + \theta_1 x_1^{(i)} + \cdots + \theta_n x_n^{(i)}.$$

1.1. Distribución condicional

Partimos de

$$Y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)}.$$

La esperanza condicional es

$$\mathbb{E}[Y^{(i)} \mid X = x^{(i)}] = \mathbb{E}[\theta^T x^{(i)} + \varepsilon^{(i)}] \tag{1}$$

$$= \theta^T x^{(i)} + \mathbb{E}[\varepsilon^{(i)}]. \tag{2}$$

Como

$$\mathbb{E}[\varepsilon^{(i)}] = 0,$$

se obtiene

$$\mathbb{E} [Y^{(i)} \mid X = x^{(i)}] = \theta^T x^{(i)}$$

Por otra parte,

$$\text{Var} (Y^{(i)} \mid X = x^{(i)}) = \text{Var} (\theta^T x^{(i)} + \varepsilon^{(i)}) \quad (3)$$

$$= \text{Var} (\varepsilon^{(i)}) \quad (4)$$

$$= \sigma^2. \quad (5)$$

Por tanto,

$$Y^{(i)} \mid X = x^{(i)} \sim \mathcal{N} (\theta^T x^{(i)}, \sigma^2)$$

1.2. Densidad condicional

La densidad de una variable aleatoria normal es

$$p(y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y - \mu)^2}{2\sigma^2} \right].$$

En nuestro caso,

$$\mu = \theta^T x^{(i)}.$$

Por consiguiente,

$$p(y^{(i)} \mid x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right]$$

1.3. Función de verosimilitud

Suponiendo que las observaciones son independientes,

$$L(\theta) = \prod_{i=1}^m p(y^{(i)} \mid x^{(i)}; \theta).$$

Sustituyendo la distribución normal,

$$L(\theta) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right].$$

Entonces,

$$L(\theta) = \left(\frac{1}{\sqrt{2\pi\sigma}} \right)^m \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2 \right]$$

1.4. Log-verosimilitud

Definimos

$$\ell(\theta) = \log L(\theta).$$

Por tanto,

$$\ell(\theta) = -\frac{m}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2$$

El primer término no depende de θ .

Además,

$$-\frac{1}{2\sigma^2} < 0.$$

Por consiguiente, maximizar $\ell(\theta)$ equivale a minimizar

$$\sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2.$$

Así,

$$\arg \max_{\theta} \ell(\theta) = \arg \min_{\theta} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

1.5. Función de costo

Definimos

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

El factor $1/m$ convierte la suma en un error promedio, mientras que el factor $1/2$ simplifica las derivadas debido a que

$$\frac{d}{dz} \left(\frac{1}{2} z^2 \right) = z.$$

Además,

$$\frac{1}{2m} > 0,$$

de modo que multiplicar por esta constante no modifica la posición del mínimo.

2. Gradiente y descenso por gradiente

Partimos de

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2.$$

2.1. Derivada de la hipótesis

La hipótesis puede escribirse como

$$h_{\theta}(x^{(i)}) = \sum_{k=0}^n \theta_k x_k^{(i)}.$$

Por tanto,

$$\boxed{\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} = x_j^{(i)}}$$

para

$$j = 0, \dots, n.$$

2.2. Gradiente de la función de costo

Derivamos respecto a θ_j :

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{2m} \sum_{i=1}^m \frac{\partial}{\partial \theta_j} \left[(h_{\theta}(x^{(i)}) - y^{(i)})^2 \right].$$

Aplicando la regla de la cadena,

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{2m} \sum_{i=1}^m 2 (h_{\theta}(x^{(i)}) - y^{(i)}) \frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j}.$$

Como

$$\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j} = x_j^{(i)},$$

obtenemos

$$\boxed{\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}}$$

2.3. Descenso por gradiente

La regla general de descenso por gradiente es

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j},$$

donde α es la tasa de aprendizaje.

Sustituyendo el gradiente,

$$\boxed{\theta_j := \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}}$$

para

$$j = 0, \dots, n.$$

Para el intercepto, como

$$x_0^{(i)} = 1,$$

tenemos

$$\theta_0 := \theta_0 - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

2.4. Actualización simultánea

Todas las componentes del gradiente deben calcularse utilizando el mismo vector de parámetros $\theta^{(k)}$.

En forma vectorial,

$$\theta^{(k+1)} = \theta^{(k)} - \alpha \nabla J(\theta^{(k)})$$

Por tanto, primero se calculan todas las componentes del gradiente y posteriormente se actualizan simultáneamente los parámetros.

3. Ecuación normal

Definimos la matriz de diseño

$$X = \begin{bmatrix} 1 & x_1^{(1)} & \cdots & x_n^{(1)} \\ 1 & x_1^{(2)} & \cdots & x_n^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & \cdots & x_n^{(m)} \end{bmatrix},$$

el vector de observaciones

$$y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix},$$

y

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}.$$

Equivalentemente,

$$X = \begin{bmatrix} (x^{(1)})^T \\ (x^{(2)})^T \\ \vdots \\ (x^{(m)})^T \end{bmatrix}.$$

Las dimensiones son

$$X \in \mathbb{R}^{m \times (n+1)},$$

$$\theta \in \mathbb{R}^{(n+1) \times 1},$$

$$y \in \mathbb{R}^{m \times 1}.$$

Además,

$$X\theta = \begin{bmatrix} h_{\theta}(x^{(1)}) \\ h_{\theta}(x^{(2)}) \\ \vdots \\ h_{\theta}(x^{(m)}) \end{bmatrix}.$$

La función de costo puede escribirse como

$$J(\theta) = \frac{1}{2m} (X\theta - y)^T (X\theta - y)$$

3.1. Expansión de la función de costo

Tenemos

$$(X\theta - y)^T = \theta^T X^T - y^T.$$

Entonces,

$$(X\theta - y)^T (X\theta - y) = (\theta^T X^T - y^T)(X\theta - y) \quad (6)$$

$$= \theta^T X^T X\theta - \theta^T X^T y - y^T X\theta + y^T y. \quad (7)$$

El término

$$y^T X\theta$$

es un escalar, ya que sus dimensiones son

$$(1 \times m)(m \times (n+1))((n+1) \times 1) = 1 \times 1.$$

Como es un escalar,

$$y^T X\theta = (y^T X\theta)^T.$$

Por tanto,

$$y^T X \theta = \theta^T X^T y.$$

Así,

$$(X\theta - y)^T (X\theta - y) = \theta^T X^T X \theta - 2\theta^T X^T y + y^T y$$

y

$$J(\theta) = \frac{1}{2m} [\theta^T X^T X \theta - 2\theta^T X^T y + y^T y]$$

3.2. Gradiente

Utilizamos la identidad

$$\nabla_{\theta}(\theta^T A \theta) = (A + A^T)\theta.$$

Tomamos

$$A = X^T X.$$

Como

$$(X^T X)^T = X^T X,$$

la matriz es simétrica y por tanto

$$\nabla_{\theta}(\theta^T X^T X \theta) = 2X^T X \theta.$$

También,

$$\nabla_{\theta}(-2\theta^T X^T y) = -2X^T y,$$

mientras que

$$\nabla_{\theta}(y^T y) = 0.$$

Por consiguiente,

$$\nabla_{\theta} J(\theta) = \frac{1}{2m} (2X^T X \theta - 2X^T y).$$

Finalmente,

$$\nabla_{\theta} J(\theta) = \frac{1}{m} (X^T X \theta - X^T y)$$

o equivalentemente,

$$\nabla_{\theta} J(\theta) = \frac{1}{m} X^T (X\theta - y)$$

3.3. Condición de mínimo

En el mínimo,

$$\nabla_{\theta} J(\theta) = 0.$$

Entonces,

$$\frac{1}{m} (X^T X \theta - X^T y) = 0.$$

Multiplicando por m ,

$$X^T X \theta - X^T y = 0.$$

Por tanto,

$$\boxed{X^T X \theta = X^T y}$$

Esta expresión recibe el nombre de **ecuación normal**.

3.4. Solución analítica

Si $X^T X$ es invertible,

$$(X^T X)^{-1} X^T X \theta = (X^T X)^{-1} X^T y.$$

Como

$$(X^T X)^{-1} X^T X = I,$$

obtenemos

$$\boxed{\hat{\theta} = (X^T X)^{-1} X^T y}$$

3.5. Comparación con descenso por gradiente

El descenso por gradiente es un método iterativo:

$$\boxed{\theta^{(k+1)} = \theta^{(k)} - \frac{\alpha}{m} X^T (X \theta^{(k)} - y)}$$

Necesita una condición inicial, una tasa de aprendizaje y múltiples iteraciones. La ecuación normal proporciona una solución analítica:

$$\boxed{\hat{\theta} = (X^T X)^{-1} X^T y}$$

cuando $X^T X$ es invertible.

La inversión falla cuando

$$\det(X^T X) = 0.$$

Esto ocurre cuando X no tiene rango columna completo:

$$\boxed{\text{rank}(X) < n + 1}$$

Por tanto, la condición de invertibilidad es

$$\boxed{\text{rank}(X) = n + 1}$$

4. Regresión logística desde la familia exponencial

Para clasificación binaria,

$$Y \in \{0, 1\}.$$

La distribución Bernoulli está dada por

$$p(y; \phi) = \phi^y (1 - \phi)^{1-y}.$$

La forma general de una distribución perteneciente a la familia exponencial es

$$p(y; \eta) = b(y) \exp [\eta T(y) - a(\eta)].$$

4.1. Bernoulli en forma exponencial

Partimos de

$$p(y; \phi) = \phi^y (1 - \phi)^{1-y}.$$

Utilizando

$$a^b = e^{b \log a},$$

tenemos

$$p(y; \phi) = \exp [y \log \phi + (1 - y) \log(1 - \phi)].$$

Expandimos:

$$p(y; \phi) = \exp [y \log \phi + \log(1 - \phi) - y \log(1 - \phi)].$$

Agrupando los términos que contienen y ,

$$\boxed{p(y; \phi) = \exp \left[y \log \left(\frac{\phi}{1 - \phi} \right) + \log(1 - \phi) \right]}$$

4.2. Parámetro natural

Comparando con

$$p(y; \eta) = b(y) \exp [\eta T(y) - a(\eta)],$$

identificamos

$$T(y) = y, \quad b(y) = 1,$$

y

$$\boxed{\eta = \log \left(\frac{\phi}{1 - \phi} \right)}$$

La transformación

$$\log \left(\frac{\phi}{1 - \phi} \right)$$

se denomina **logit**.

4.3. Despeje de ϕ

Partimos de

$$\eta = \log \left(\frac{\phi}{1 - \phi} \right).$$

Aplicamos la exponencial:

$$e^\eta = \frac{\phi}{1 - \phi}.$$

Multiplicamos por $1 - \phi$:

$$e^\eta(1 - \phi) = \phi.$$

Distribuyendo,

$$e^\eta - e^\eta\phi = \phi.$$

Agrupamos los términos que contienen ϕ :

$$e^\eta = \phi + e^\eta\phi.$$

Factorizando,

$$e^\eta = \phi(1 + e^\eta).$$

Por tanto,

$$\phi = \frac{e^\eta}{1 + e^\eta}.$$

Dividiendo numerador y denominador por e^η ,

$$\boxed{\phi = \frac{1}{1 + e^{-\eta}}}$$

4.4. Forma canónica de Bernoulli

Como

$$\phi = \frac{e^\eta}{1 + e^\eta},$$

entonces

$$1 - \phi = \frac{1}{1 + e^\eta}.$$

Por tanto,

$$\log(1 - \phi) = -\log(1 + e^\eta).$$

Sustituyendo,

$$p(y; \eta) = \exp[y\eta - \log(1 + e^\eta)].$$

Así,

$$\boxed{b(y) = y, \quad T(y) = y, \quad a(\eta) = \log(1 + e^\eta)}$$

4.5. Introducción del modelo lineal

Tomamos

$$\eta = \theta^T x.$$

Entonces,

$$\phi = \frac{1}{1 + e^{-\theta^T x}}.$$

Como para una distribución Bernoulli

$$P(Y = 1) = \phi,$$

obtenemos

$$\boxed{P_\theta(Y = 1 \mid X = x) = \frac{1}{1 + e^{-\theta^T x}}}$$

4.6. Hipótesis logística

Definimos

$$\boxed{h_\theta(x) = \frac{1}{1 + e^{-\theta^T x}}}$$

o equivalentemente,

$$\boxed{h_\theta(x) = \sigma(\theta^T x)}$$

donde la función sigmoide es

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Por tanto,

$$P_{\theta}(Y = 1 \mid X = x) = h_{\theta}(x)$$

4.7. Probabilidad de $Y = 0$

Como

$$P(Y = 0 \mid X = x) + P(Y = 1 \mid X = x) = 1,$$

tenemos

$$P_{\theta}(Y = 0 \mid X = x) = 1 - h_{\theta}(x).$$

Explícitamente,

$$1 - h_{\theta}(x) = 1 - \frac{1}{1 + e^{-\theta^T x}}.$$

Entonces,

$$P_{\theta}(Y = 0 \mid X = x) = \frac{1}{1 + e^{\theta^T x}}$$

5. Likelihood y función de costo logística

Partimos de

$$P_{\theta}(Y = 1 \mid X = x) = h_{\theta}(x),$$

$$P_{\theta}(Y = 0 \mid X = x) = 1 - h_{\theta}(x),$$

con

$$h_{\theta}(x) = \sigma(\theta^T x).$$

5.1. Expresión probabilística única

Para una observación i , ambas posibilidades pueden escribirse como

$$p(y^{(i)} \mid x^{(i)}; \theta) = [h_{\theta}(x^{(i)})]^{y^{(i)}} [1 - h_{\theta}(x^{(i)})]^{1-y^{(i)}}$$

Si $y^{(i)} = 1$,

$$p = h_{\theta}(x^{(i)})^1 [1 - h_{\theta}(x^{(i)})]^0 = h_{\theta}(x^{(i)}).$$

Si $y^{(i)} = 0$,

$$p = h_{\theta}(x^{(i)})^0 [1 - h_{\theta}(x^{(i)})]^1 = 1 - h_{\theta}(x^{(i)}).$$

5.2. Verosimilitud

Suponiendo independencia entre las m observaciones,

$$L(\theta) = \prod_{i=1}^m p(y^{(i)} | x^{(i)}; \theta).$$

Por tanto,

$$L(\theta) = \prod_{i=1}^m [h_{\theta}(x^{(i)})]^{y^{(i)}} [1 - h_{\theta}(x^{(i)})]^{1-y^{(i)}}$$

5.3. Log-verosimilitud

Definimos

$$\ell(\theta) = \log L(\theta).$$

Entonces,

$$\ell(\theta) = \log \left[\prod_{i=1}^m h_{\theta}(x^{(i)})^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{1-y^{(i)}} \right]. \quad (8)$$

Utilizando

$$\log \left(\prod_i a_i \right) = \sum_i \log(a_i),$$

obtenemos

$$\ell(\theta) = \sum_{i=1}^m \log \left[h_{\theta}(x^{(i)})^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{1-y^{(i)}} \right].$$

Aplicando

$$\log(ab) = \log a + \log b$$

y

$$\log(a^b) = b \log a,$$

llegamos a

$$\ell(\theta) = \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)}))]$$

5.4. Función de costo logística

Máxima verosimilitud busca maximizar

$$\ell(\theta).$$

Equivalentemente, podemos minimizar la log-verosimilitud negativa.

Definimos

$$J(\theta) = -\frac{1}{m}\ell(\theta).$$

Por tanto,

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)}))]$$

5.5. Entropía cruzada binaria

Para una sola observación,

$$\text{BCE}(y, h) = -[y \log h + (1 - y) \log(1 - h)]$$

Esta función recibe el nombre de **entropía cruzada binaria** (*Binary Cross-Entropy*).

En regresión logística,

$$h = h_{\theta}(x).$$

Por tanto,

$$\text{BCE} = -[y \log h_{\theta}(x) + (1 - y) \log (1 - h_{\theta}(x))]$$

y

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{BCE}^{(i)}$$

5.6. Gradiente de la función de costo

Definimos, para simplificar,

$$h_i = h_{\theta}(x^{(i)}).$$

Entonces,

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_i + (1 - y^{(i)}) \log(1 - h_i)].$$

Derivando respecto a θ_j ,

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{m} \sum_{i=1}^m \left[\frac{y^{(i)}}{h_i} - \frac{1 - y^{(i)}}{1 - h_i} \right] \frac{\partial h_i}{\partial \theta_j}.$$

Ahora,

$$h_i = \sigma(z_i),$$

con

$$z_i = \theta^T x^{(i)}.$$

Aplicando regla de la cadena,

$$\frac{\partial h_i}{\partial \theta_j} = \sigma'(z_i) \frac{\partial z_i}{\partial \theta_j}.$$

Sabemos que

$$\sigma'(z) = \sigma(z)(1 - \sigma(z)).$$

Por tanto,

$$\sigma'(z_i) = h_i(1 - h_i).$$

Además,

$$\frac{\partial z_i}{\partial \theta_j} = x_j^{(i)}.$$

Así,

$$\boxed{\frac{\partial h_i}{\partial \theta_j} = h_i(1 - h_i)x_j^{(i)}}$$

Sustituyendo,

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{m} \sum_{i=1}^m \left[\frac{y^{(i)}}{h_i} - \frac{1 - y^{(i)}}{1 - h_i} \right] h_i(1 - h_i)x_j^{(i)}.$$

Simplificando,

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{m} \sum_{i=1}^m [y^{(i)}(1 - h_i) - (1 - y^{(i)})h_i] x_j^{(i)}.$$

Ahora,

$$y^{(i)}(1 - h_i) - (1 - y^{(i)})h_i = y^{(i)} - y^{(i)}h_i - h_i + y^{(i)}h_i \quad (9)$$

$$= y^{(i)} - h_i. \quad (10)$$

Por tanto,

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} - h_i)x_j^{(i)}.$$

Finalmente,

$$\boxed{\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}}$$

5.7. Descenso por gradiente

La regla es

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}.$$

Por tanto,

$$\theta_j := \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

para

$$j = 0, \dots, n.$$

5.8. Comparación con regresión lineal

Para regresión lineal,

$$\frac{\partial J_{\text{lin}}}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}.$$

Para regresión logística,

$$\frac{\partial J_{\text{log}}}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}.$$

Por tanto, ambos tienen la misma estructura:

$$\frac{1}{m} \sum_{i=1}^m (\text{predicción} - \text{valor real}) x_j^{(i)}$$

Sin embargo, las hipótesis son diferentes.

En regresión lineal,

$$h_{\theta}(x) = \theta^T x$$

mientras que en regresión logística,

$$h_{\theta}(x) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

6. Regularización

Un buen ajuste sobre los datos de entrenamiento no garantiza necesariamente una buena generalización.

Para controlar la complejidad del modelo introducimos una penalización sobre la magnitud de sus parámetros.

Para regularización L_2 , utilizamos

$$\boxed{\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2}$$

donde $\lambda \geq 0$ controla la intensidad de la regularización.

Es importante observar que la suma comienza en $j = 1$. Por tanto, θ_0 no se incluye en la penalización.

6.1. Costo regularizado para regresión lineal

El costo sin regularización es

$$J_{\text{datos}}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2.$$

Añadiendo la regularización L_2 ,

$$\boxed{J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2}$$

Podemos escribir

$$J(\theta) = J_{\text{datos}}(\theta) + J_{\text{reg}}(\theta),$$

donde

$$J_{\text{reg}}(\theta) = \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2.$$

6.2. Gradiente para $j \geq 1$

Para evitar confusión entre el índice de la suma y el parámetro respecto al cual derivamos, escribimos

$$J_{\text{reg}}(\theta) = \frac{\lambda}{2m} \sum_{k=1}^n \theta_k^2.$$

Entonces,

$$\frac{\partial J}{\partial \theta_j} = \frac{\partial J_{\text{datos}}}{\partial \theta_j} + \frac{\partial J_{\text{reg}}}{\partial \theta_j}.$$

Del resultado de regresión lineal,

$$\frac{\partial J_{\text{datos}}}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}.$$

Ahora,

$$\frac{\partial J_{\text{reg}}}{\partial \theta_j} = \frac{\lambda}{2m} \frac{\partial}{\partial \theta_j} \sum_{k=1}^n \theta_k^2.$$

Todos los términos con $k \neq j$ tienen derivada cero. Por tanto,

$$\frac{\partial J_{\text{reg}}}{\partial \theta_j} = \frac{\lambda}{2m} \frac{\partial}{\partial \theta_j} \theta_j^2.$$

Como

$$\frac{\partial}{\partial \theta_j} \theta_j^2 = 2\theta_j,$$

se obtiene

$$\frac{\partial J_{\text{reg}}}{\partial \theta_j} = \frac{\lambda}{2m} (2\theta_j).$$

Por consiguiente,

$$\boxed{\frac{\partial J_{\text{reg}}}{\partial \theta_j} = \frac{\lambda}{m} \theta_j}$$

y el gradiente total es

$$\boxed{\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j, \quad j \geq 1}$$

6.3. Caso $j = 0$

La penalización

$$\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

no contiene a θ_0 .

Por tanto,

$$\frac{\partial J_{\text{reg}}}{\partial \theta_0} = 0.$$

Entonces,

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)}.$$

Como

$$x_0^{(i)} = 1,$$

obtenemos

$$\boxed{\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})}$$

6.4. Actualización para $j \geq 1$

La regla general de descenso por gradiente es

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}.$$

Sustituyendo el gradiente regularizado,

$$\theta_j := \theta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \right].$$

Distribuyendo α ,

$$\theta_j := \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)} - \frac{\alpha \lambda}{m} \theta_j.$$

Reordenando,

$$\theta_j := \theta_j - \frac{\alpha \lambda}{m} \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}.$$

Factorizamos θ_j :

$$\theta_j := \left(1 - \frac{\alpha \lambda}{m}\right) \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}, \quad j \geq 1$$

El término asociado a los datos es

$$\frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

6.5. Interpretación del factor de decaimiento

El factor

$$1 - \frac{\alpha \lambda}{m}$$

multiplica al valor anterior del parámetro.

Si ignoramos momentáneamente el término asociado a los datos,

$$\theta_j^{\text{nuevo}} = \left(1 - \frac{\alpha \lambda}{m}\right) \theta_j^{\text{anterior}}.$$

Cuando

$$0 < 1 - \frac{\alpha \lambda}{m} < 1,$$

el valor absoluto de θ_j disminuye.

Por ejemplo, si

$$1 - \frac{\alpha\lambda}{m} = 0,95,$$

entonces

$$\theta_j^{\text{nuevo}} = 0,95\theta_j^{\text{anterior}}.$$

Este comportamiento recibe el nombre de **weight decay** o decaimiento de los pesos. La actualización puede interpretarse como

$$\underbrace{\left(1 - \frac{\alpha\lambda}{m}\right) \theta_j}_{\text{regularización}} - \underbrace{\frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}}_{\text{término de datos}}$$

La regularización empuja los parámetros hacia valores de menor magnitud, mientras que el término de datos busca mejorar el ajuste.

Si

$$\lambda = 0,$$

recuperamos el modelo sin regularización.

Un valor mayor de λ produce una penalización más fuerte. Sin embargo, un valor excesivamente grande puede producir subajuste.

6.6. Costo regularizado para regresión logística

El costo logístico sin regularización es

$$J_{\text{datos}}(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)}))].$$

Añadiendo regularización L_2 ,

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)}))] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

donde

$$h_{\theta}(x) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}.$$

Por tanto,

$$J_{\text{log,reg}} = \text{entropía cruzada} + \text{penalización } L_2$$

6.7. Gradiente logístico regularizado

Sin regularización habíamos obtenido

$$\frac{\partial J_{\text{datos}}}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}.$$

La derivada de la regularización para $j \geq 1$ es

$$\frac{\partial J_{\text{reg}}}{\partial \theta_j} = \frac{\lambda}{m} \theta_j.$$

Por tanto,

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j, \quad j \geq 1$$

Para $j = 0$,

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

La actualización para $j \geq 1$ es

$$\theta_j := \left(1 - \frac{\alpha \lambda}{m}\right) \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

mientras que para el intercepto,

$$\theta_0 := \theta_0 - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

6.8. ¿Por qué no se regulariza θ_0 ?

En regresión lineal,

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \cdots + \theta_n x_n.$$

El parámetro θ_0 representa el **intercepto** o término de sesgo.

Los parámetros

$$\theta_1, \dots, \theta_n$$

determinan la sensibilidad de la predicción frente a las características de entrada.

La regularización busca controlar precisamente la magnitud de estos coeficientes.

Por otro lado, θ_0 determina principalmente el nivel base o desplazamiento global del modelo.

Por esta razón, normalmente se utiliza

$$\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

en lugar de

$$\frac{\lambda}{2m} \sum_{j=0}^n \theta_j^2.$$

Así,

θ_0 normalmente no se regulariza porque representa el intercepto, no el efecto asociado a una característica.

7. Resumen de resultados

Los ejercicios anteriores permiten relacionar regresión lineal, regresión logística, máxima verosimilitud, descenso por gradiente y regularización.

7.1. Regresión lineal

La hipótesis es

$$h_{\theta}(x) = \theta^T x$$

y la función de costo es

$$J_{\text{lin}}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

El gradiente es

$$\frac{\partial J_{\text{lin}}}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

y la ecuación normal proporciona, cuando $X^T X$ es invertible,

$$\hat{\theta} = (X^T X)^{-1} X^T y$$

7.2. Regresión logística

La hipótesis logística es

$$h_{\theta}(x) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

con

$$P_{\theta}(Y = 1 \mid X = x) = h_{\theta}(x)$$

y

$$P_{\theta}(Y = 0 \mid X = x) = 1 - h_{\theta}(x)$$

La función de costo es la entropía cruzada binaria:

$$J_{\log}(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)}))]$$

y su gradiente es

$$\frac{\partial J_{\log}}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

7.3. Regularización L_2

La penalización es

$$J_{\text{reg}}(\theta) = \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

Para $j \geq 1$, el gradiente regularizado tiene la estructura

$$\frac{\partial J}{\partial \theta_j} = \frac{\partial J_{\text{datos}}}{\partial \theta_j} + \frac{\lambda}{m} \theta_j$$

y la actualización puede escribirse como

$$\theta_j := \left(1 - \frac{\alpha \lambda}{m}\right) \theta_j - \text{término de datos}$$

El factor

$$1 - \frac{\alpha \lambda}{m}$$

produce un decaimiento de la magnitud de los parámetros y ayuda a controlar la complejidad del modelo.

Finalmente, θ_0 normalmente no se regulariza debido a que representa el intercepto.