

# Laboratorio 3 — Naive Bayes Bernoulli para detectar spam

Luis Seña Ávila, Universidad de Antioquia

Medellín - Antioquia

23 de septiembre de 2026

## Resumen

En este laboratorio se implementó desde cero un clasificador **Naive Bayes Bernoulli** para detectar correos spam. Se trabajó con un corpus pequeño de 11 correos y un vocabulario de 5 palabras. Se calcularon las probabilidades fundamentales del modelo: el prior  $P(Y)$ , la verosimilitud  $P(X_i | Y)$ , el likelihood  $P(X | Y)$  y el posterior  $P(Y | X)$ . Se evidenció el problema de la probabilidad cero y se resolvió mediante el suavizado de Laplace. Finalmente, se clasificó el correo “dinero gratis” obteniendo una probabilidad del 98.54 % de ser spam, validando así el funcionamiento del modelo y la importancia de la hipótesis de independencia condicional.

**Palabras Claves:** Naive Bayes, Bernoulli, clasificación, spam, suavizado de Laplace, independencia condicional.

## 1. Introducción

El clasificador Naive Bayes es uno de los modelos probabilísticos más utilizados en tareas de clasificación de texto, como la detección de spam. Su popularidad radica en su simplicidad y en su capacidad de funcionar bien incluso con conjuntos de datos pequeños, gracias a la hipótesis de independencia condicional, que asume que las palabras de un documento son independientes entre sí dado que se conoce la clase.

En este informe se presenta el desarrollo del laboratorio en el siguiente orden. En la Sección 2.1 se construye la representación vectorial de los correos mediante la función vectorizar, transformando cada mensaje en un vector binario de 0s y 1s. Luego, en la Sección 2.2, se calcula el prior  $P(Y)$ , es decir, la probabilidad base de cada clase. Después, en la Sección 2.3, se calcula la verosimilitud  $P(X_i | Y)$  sin suavizado, evidenciando el problema de las probabilidades iguales a cero. En la Sección 2.4 se aplica el suavizado de Laplace para resolver dicho problema. Más adelante, en la Sección 2.5, se clasifica un correo nuevo calculando el likelihood, el score conjunto y el posterior. Finalmente, en la Sección 3 se responden las preguntas de análisis y en la Sección 4 se cierra con las conclusiones.

## 2. Desarrollo

### 2.1. Construcción del vector $X$

Se implementó la función `vectorizar(texto, vocabulario)` que transforma un correo en un vector binario de dimensión 5, donde cada posición indica la presencia (1) o ausencia (0) de una palabra del vocabulario  $V = \{\text{dinero, gratis, premio, proyecto, reunion}\}$ . Por ejemplo, el correo “dinero gratis” se representa como (1, 1, 0, 0, 0). Posteriormente, se vectorizó todo el corpus de 11 correos, generando una lista de tuplas (`clasificación, vector`) que sirve como base para los cálculos posteriores.

### 2.2. Cálculo del prior $P(Y)$

Se calculó la probabilidad a priori de cada clase como la proporción de correos que pertenecen a ella:

$$P(Y = y) = \frac{\text{\#correos de clase } y}{\text{\#correos totales}}$$

Los resultados fueron  $P(\text{Spam}) = 0,4545$  y  $P(\text{Normal}) = 0,5455$ , reflejando un corpus ligeramente balanceado hacia los correos normales.

### 2.3. Cálculo de $P(X_i = 1 | Y)$ sin suavizado

Para cada palabra del vocabulario se calculó su frecuencia dentro de cada clase:

$$P(X_i = 1 | Y = y) = \frac{\text{\#correos de clase } y \text{ que contienen la palabra } i}{\text{\#correos de clase } y}$$

La tabla resultante mostró varias probabilidades iguales a cero. Por ejemplo,  $P(\text{proyecto} | \text{Spam}) = 0$  y  $P(\text{dinero} | \text{Normal}) = 0$ .

Problema identificado: Si una palabra nunca aparece en una clase, su probabilidad se vuelve exactamente 0. Como el likelihood se calcula como un producto, un solo cero anula todo el producto, haciendo que el modelo descarte por completo esa clase aunque el correo contenga muchas otras palabras típicas de ella. Esto se conoce como el problema de la probabilidad cero.

### 2.4. Suavizado de Laplace

Para resolver el problema anterior, se aplicó el suavizado de Laplace para variables Bernoulli:

$$\hat{P}(X_i = 1 | Y = y) = \frac{N_{iy} + 1}{N_y + 2}$$

donde  $N_{iy}$  es el número de correos de clase  $y$  que contienen la palabra  $i$ , y  $N_y$  es el total de correos de esa

clase. La nueva tabla ya no contiene ceros, garantizando que ningún término anule el producto completo.

## 2.5. Clasificación de un correo nuevo

Se clasificó el correo “dinero gratis”, cuyo vector es  $x = (1, 1, 0, 0, 0)$ . El procedimiento siguió los tres pasos del modelo:

1. **Likelihood:**  $P(x | Y) = \prod_i P(X_i = x_i | Y)$
2. **Score conjunto:**  $S_y = P(Y) \cdot P(x | Y)$
3. **Posterior:**  $P(Y | x) = \frac{S_y}{S_{spam} + S_{normal}}$

Los resultados fueron  $P(\text{Spam} | x) = 0,9854$  y  $P(\text{Normal} | x) = 0,0146$ , clasificando el correo como **SPAM** con un 98.54% de confianza.

A continuación se presenta una tabla resumen de los conceptos fundamentales utilizados en este laboratorio:

| Concepto              | Pregunta que responde                                              |
|-----------------------|--------------------------------------------------------------------|
| Clasificar            | ¿A qué categoría pertenece este correo nuevo?                      |
| Prior $P(Y)$          | ¿Qué tan común es cada clase en general?                           |
| Likelihood $P(X   Y)$ | Si fuera de esa clase, ¿qué tan probable sería ver estas palabras? |
| Posterior $P(Y   X)$  | Combinando todo, ¿qué tan probable es cada clase dado el correo?   |
| Decisión              | Elegir la clase con mayor posterior                                |

## 3. Respuestas a las preguntas de análisis

### 1. ¿Dónde se usa la hipótesis de independencia condicional?

Se usa al calcular el likelihood  $P(x | Y)$ . En lugar de calcular la probabilidad conjunta de todas las palabras al mismo tiempo (imposible con pocos datos), asumimos que cada palabra es independiente de las demás dado que conocemos la clase:

$$P(x | Y) = \prod_{i=1}^5 P(X_i | Y)$$

En el código, esto se ve en la función `likelihood`, donde multiplicamos `prob *= p_aparece` para cada palabra, sin considerar cómo interactúan entre ellas.

### 2. ¿Por qué no necesitamos almacenar una probabilidad para cada uno de los $2^5$ vectores posibles?

Porque la hipótesis de independencia condicional reduce el número de parámetros de exponencial a lineal. Sin independencia, necesitaríamos estimar  $2 \times 2^5 = 64$  parámetros (una probabilidad por cada combinación posible de palabras en cada clase). Con independencia, solo necesitamos 5 probabilidades  $P(X_i | \text{Spam})$ , 5

$P(X_i | \text{Normal})$  y 2 priors  $P(Y)$ : un total de **12 parámetros**. Además, cada uno se estima contando apariciones individuales, lo que requiere muchos menos datos.

### 3. ¿Por qué Naive Bayes se considera un modelo generativo aunque aquí lo usemos para clasificar?

Porque modela explícitamente la distribución conjunta  $P(X, Y)$  a través de dos componentes: el prior  $P(Y)$  y el likelihood  $P(X | Y)$ . Con ellos puede generar datos sintéticos muestreando  $Y \sim P(Y)$  y luego  $X_i \sim P(X_i | Y)$ . Para clasificar, aplicamos el Teorema de Bayes y derivamos el posterior, pero el modelo subyacente sigue siendo generativo porque **aprende y almacena**  $P(X | Y)$  y  $P(Y)$  por separado, en lugar de aprender directamente  $P(Y | X)$  o una frontera de decisión.

## 4. Conclusiones

- **La representación Bernoulli simplifica el modelo:** convertir cada correo en un vector binario permite calcular las probabilidades de forma directa y eficiente, sin ambigüedades sobre la frecuencia de las palabras.
- **El prior es fundamental:** la probabilidad base de cada clase ( $P(\text{Spam}) = 0,4545$  y  $P(\text{Normal}) = 0,5455$ ) influye en la decisión final, aunque en este caso el likelihood fue mucho más determinante.
- **El problema de la probabilidad cero es real:** sin suavizado, palabras como “proyecto” en spam tenían probabilidad 0, lo que anularía cualquier correo que las contuviera. El suavizado de Laplace resuelve esto de forma elegante.
- **La hipótesis de independencia condicional es clave:** reduce el número de parámetros de 64 a 12, haciendo viable el modelo incluso con corpus pequeños.
- **El clasificador funcionó correctamente:** el correo “dinero gratis” fue clasificado como SPAM con un 98.54% de confianza, lo cual es coherente con la naturaleza de las palabras “dinero” y “gratis” en el corpus.
- **Naive Bayes es generativo por construcción:** aunque lo usemos para clasificar, modela  $P(X | Y)$  y  $P(Y)$  por separado, lo que le permite generar datos sintéticos y le da una naturaleza distinta a los modelos discriminativos.

## 5. Bibliografía

### Referencias

- [1] A. Ng. *Machine Learning* (Coursera), semanas 1–3.
- [2] A. Géron. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, cap. 4. O'Reilly.

[3] Stanford CS229 — Machine Learning. <http://cs229.stanford.edu/syllabus.html>

El notebook completo con el desarrollo, los experimentos y los resultados puede consultarse en el siguiente enlace: [Laboratorio 03 - Naive Bayes Bernoulli para detectar spam](#)

## Declaración de uso de inteligencia artificial

Para la elaboración de este informe se utilizó la herramienta de inteligencia artificial DeepSeek (modelo de lenguaje) como apoyo en las siguientes tareas:

- Redacción y mejora de la claridad de las explicaciones en las secciones de desarrollo.
- Verificación de la coherencia entre los resultados del notebook y las conclusiones presentadas.
- Apoyo en la redacción de las respuestas a las preguntas de análisis.

El análisis de los datos, la implementación de los algoritmos, la ejecución del notebook y la interpretación de los resultados fueron realizados por el mí. Las sugerencias proporcionadas por la IA fueron revisadas, validadas y adaptadas antes de su inclusión en el documento. El uso de esta herramienta se declara en cumplimiento de los principios de transparencia y honestidad académica.