UNIVERSIDAD DE ANTIOQUIA
1803

Universidad de Antioquia
Facultad de Ciencias Exactas y Naturales
Instituto de Física
Examen, 30 Octubre, CCA

Nombre: Luis León Jiménez Cédula: 1063153947

1. (20%)Considere un detector que registra el número de partículas que llegan a su superficie durante intervalos de tiempo fijos. Se asume que las detecciones ocurren de manera independiente y que la tasa esperada de llegada depende de una condición experimental x_i, por ejemplo la intensidad de la fuente, la distancia al detector o el tiempo de exposición.

   Bajo estas hipótesis, el número de eventos observados y_i se modela como una variable aleatoria de Poisson:

$$p(y_i \mid x_i; \theta) = \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}, \qquad y_i = 0, 1, 2, \ldots \tag{1}$$

   donde $h_\theta(x_i)$ representa la tasa esperada de detecciones. En este primer modelo, suponga que la tasa depende linealmente de x_i:

$$h_\theta(x_i) = \theta_0 + \theta_1 x_i. \tag{2}$$

   Como $h_\theta(x_i)$ representa una tasa física, se debe cumplir que

$$h_\theta(x_i) > 0 \tag{3}$$

   para todos los datos observados.

   (a) Construya la función de verosimilitud $L(\theta)$ para un conjunto de datos independientes $\{(x_i, y_i)\}_{i=1}^n$.

   (b) Determine la log-verosimilitud $\ell(\theta)$ y obtenga la función de coste asociada al principio de máxima verosimilitud.

   (c) Muestre que, salvo constantes independientes de θ, la función de coste puede escribirse como

$$J(\theta) = \sum_{i=1}^{n} \left[h_\theta(x_i) - y_i \log h_\theta(x_i) \right]. \tag{4}$$

   (d) Usando $h_\theta(x_i) = \theta_0 + \theta_1 x_i$, calcule el gradiente de $J(\theta)$ respecto a θ_0 y θ_1.

   (e) Interprete físicamente $h_\theta(x)$, θ_0 y θ_1 en el contexto del detector.

Powered by CamScanner

Solución

a) $$L(\theta) = \prod_{i=1}^{n} P_i(y_i | x_i ; \theta)$$

→ $$\boxed{L(\theta) = \prod_{i=1}^{n} \frac{h_\theta(x_i)^{y_i} e^{-h(x_i)}}{y_i!}}$$

b) $$l(\theta) = \ln[L(\theta)]$$

→ $$l(\theta) = \ln\left[\prod_{i=1}^{n} \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!} \right]$$

$$= \sum_{i=1}^{n} \ln\left[\frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!} \right]$$

$$= \sum_{i=1}^{n} \left[y_i \ln[h_\theta(x_i)] - h_\theta(x_i) - \ln[y_i!] \right]$$

Powered by CamScanner

$$\ell(\theta) = \sum_{i=1}^{n} \left[y_i \ln[h_\theta(x_i)] - h_\theta(x_i) \right] - \sum_{i=1}^{n} \ln(y_i!)$$

$$J(\theta) = -\ell(\theta) = \sum_{i=1}^{n} \ln(y_i!) + \sum_{i=1}^{n} \left[h_\theta(x_i) - y_i \ln[h_\theta(x_i)] \right]$$

c) De la expresión anterior, el término

$$\sum_{i=1}^{n} \ln(y_i!) \text{ es una constante}$$

Por lo tanto, maximizar la verosimilitud, implica minimizar la función de costo, lo cual a su vez se reduce en minimizar la siguiente función de costo

$$J(\theta) = \sum_{i=1}^{n} \left[h_\theta(x_i) - y_i \ln[h_\theta(x_i)] \right]$$

Powered by CamScanner

d) $$\frac{\partial J}{\partial \theta_0} = \frac{\partial J}{\partial h_\theta(x_i)} \frac{\partial h_\theta(x_i)}{\partial \theta_0}$$ (1)

$$= \sum_{i=1}^{n} \left[1 - \frac{y_i}{h_\theta(x_i)} \right] = \sum_{i=1}^{n} 1 - \sum_{i=1}^{n} \frac{y_i}{h_\theta(x_i)}$$

$$\rightarrow \boxed{\frac{\partial J}{\partial \theta_0} = n - \sum_{i=1}^{n} \frac{y_i}{h_\theta(x_i)}}$$

Similarmente

$$\frac{\partial J}{\partial \theta_1} = \frac{\partial J}{\partial h_\theta(x_i)} \frac{\partial h_\theta(x_i)}{\partial \theta_1}$$ (x_i)

$$\rightarrow \boxed{\frac{\partial J}{\partial \theta_1} = \sum_{i=1}^{n} \left[1 - \frac{y_i}{h_\theta(x_i)} \right] \cdot x_i}$$

e) $h_\theta(x_i)$ es la tasa esperada de detecciones predicha por el modelo para la condición experimental x_i. Es el valor medio $\mathbb{E}[y_i | x_i]$ del proceso de Poisson.

Powered by CamScanner

Físicamente, es el flujo esperado que llega al detector bajo esa condición (intensidad de la fuente, distancia, tiempo de exposición, etc).

- θ_0 es la base o fondo. Representa las detecciones esperadas cuando $x_i = 0$. En otras palabras, es el ruido de fondo o offset del detector.

- θ_1 es la sensibilidad de la tasa de detección frente a x_i. Indica cuanto cambia la tasa esperada por cada unidad de aumento en x_i. Su signo dice si x_i aumenta o disminuye las detecciones.

Powered by CamScanner

2. (20%) Backward pass. Considere una red neuronal de una capa oculta que recibe una entrada escalar x_i y produce una tasa esperada de conteos mediante una salida positiva:

$$h_\theta(x_i) = \exp(f_\theta(x_i)). \tag{5}$$

La red está definida por:

$$Z_{i,1}^{[1]} = \theta_{1,1}^{[1]} x_i + b_1^{[1]}, \tag{6}$$
$$A_{i,1}^{[1]} = \sigma\left(Z_{i,1}^{[1]}\right), \tag{7}$$
$$Z_{i,1}^{[2]} = \theta_{1,1}^{[2]} A_{i,1}^{[1]} + b_1^{[2]}, \tag{8}$$
$$h_\theta(x_i) = \exp\left(Z_{i,1}^{[2]}\right). \tag{9}$$

donde σ es una función de activación diferenciable. Para un dato (x_i, y_i), la función de coste de Poisson, salvo constantes independientes de θ, es

$$J_i(\theta) = h_\theta(x_i) - y_i \log h_\theta(x_i). \tag{10}$$

Como $h_\theta(x_i) = \exp\left(Z_{i,1}^{[2]}\right)$, esta función puede escribirse como

$$J_i(\theta) = \exp\left(Z_{i,1}^{[2]}\right) - y_i Z_{i,1}^{[2]}. \tag{11}$$

(a) Calcule el error en la capa de salida:

$$\delta_{i,1}^{[2]} = \frac{\partial J_i}{\partial Z_{i,1}^{[2]}}. \tag{12}$$

(b) Calcule los gradientes respecto a los parámetros de la capa de salida:

$$\frac{\partial J_i}{\partial \theta_{1,1}^{[2]}}, \qquad \frac{\partial J_i}{\partial b_1^{[2]}}. \tag{13}$$

(c) Calcule el error que se propaga hacia la capa oculta:

$$\delta_{i,1}^{[1]} = \frac{\partial J_i}{\partial Z_{i,1}^{[1]}} = \frac{\partial J_i}{\partial Z_{i,1}^{[2]}} \frac{\partial Z_{i,1}^{[2]}}{\partial A_{i,1}^{[1]}} \frac{\partial A_{i,1}^{[1]}}{\partial Z_{i,1}^{[1]}}. \tag{14}$$

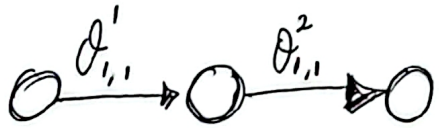
(d) Calcule los gradientes respecto a los parámetros de la primera capa:

$$\frac{\partial J_i}{\partial \theta_{1,1}^{[1]}}, \qquad \frac{\partial J_i}{\partial b_1^{[1]}}. \tag{15}$$

Powered by CamScanner

Solución

Nota: Cambié el orden de los subíndices para mantener la misma notación de las notas.



Propagación y activación en 1

$$z^{[1]}_{1,i} = \theta^{[1]}_{1,1} x_i + b^{[1]}_1$$

$$A^{[1]}_{1,i} = \sigma(z^1_{1,i})$$

Propagación y activación en 2

$$z^{[2]}_{1,i} = \theta^{[2]}_{1,1} A^{[1]}_{1,i} + b^{[2]}_1$$

$$h_\theta(x_i) = e^{z^{[2]}_{1,i}}$$

función de coste

$$J_i(\theta) = h_\theta(x_i) - y_i \ln h_\theta(x_i)$$

$$= e^{z^{[2]}_{1,i}} - y_i z^{[2]}_{1,i}$$

a)

$$\delta^{[2]}_{1,i} = \frac{\partial J_i}{\partial z^{[2]}_{1,i}} = e^{z^{[2]}_{1,i}} - y_i = \underbrace{h_\theta(x_i) - y_i}_{\text{Residuo}}$$

Powered by CamScanner

b) $$\frac{\partial J_i}{\partial \theta_{1,1}^{[2]}} = \frac{\partial J_i}{\partial z_{1,i}^{[2]}} \frac{\partial z_{1,i}^{[2]}}{\partial \theta_{1,1}^{[2]}}$$ $\rightarrow A_{1,i}^{[1]}$

$$= \left[h_\theta(x_i) - y_i \right] A_{1,i}^{[1]}$$

$$= \delta_{1,i}^{[2]} \; A_{1,i}^{[1]}$$

Para el sesgo

$$\frac{\partial J_i}{\partial b_1^{[2]}} = \frac{\partial J_i}{\partial z_{1,i}^{[2]}} \frac{\partial z_{1,i}^{[2]}}{\partial b_1^{[2]}}$$ $\rightarrow 1$

$$= \left[h_\theta(x_i) - y_i \right]$$

$$= \delta_{1,i}^{[2]}$$

$\rightarrow$ $$\boxed{\frac{\partial J_i}{\partial \theta_{1,1}^{[2]}} = \delta_{1,i}^{[2]} A_{1,i}^{[1]} \quad ; \quad \frac{\partial J_i}{\partial b_1^{[2]}} = \delta_{1,i}^{[2]}}$$

Powered by CamScanner

c) $J_i \rightarrow z_{1,i}^{[2]} \rightarrow A_{1,i}^{[1]} \rightarrow z_{1,i}^{[1]}$

$\rightarrow \frac{\partial J_i}{\partial z_{1,i}^{[1]}} = \frac{\partial J_i}{\partial z_{1,i}^{[2]}} \cdot \frac{\partial z_{1,i}^{[2]}}{\partial A_{1,i}^{[1]}} \cdot \frac{\partial A_{1,i}^{[1]}}{\partial z_{1,i}^{[1]}}$ ($\frac{\partial J_i}{\partial z_{1,i}^{[2]}} = \delta_{1,i}^{[2]}$)

- $\frac{\partial z_{1,i}^{[2]}}{\partial A_{1,i}^{[1]}} = \theta_{1,1}^{[2]}$
- $\frac{\partial A_{1,i}^{[1]}}{\partial z_{1,i}^{[1]}} = \sigma'(z_{1,i}^{[1]})$

$\rightarrow$ $$\boxed{\delta_{1,i}^{[1]} = \frac{\partial J_i}{\partial z_{1,i}^{[1]}} = \delta_{1,i}^{[2]} \cdot \theta_{1,1}^{[2]} \cdot \sigma'(z_{1,i}^{[1]})}$$

d) $\frac{\partial J_i}{\partial \theta_{1,1}^{[1]}} = \frac{\partial J_i}{\partial z_{1,i}^{[1]}} \frac{\partial z_{1,i}^{[1]}}{\partial \theta_{1,1}^{[1]}}$ ($\frac{\partial z_{1,i}^{[1]}}{\partial \theta_{1,1}^{[1]}} = x_i$)

$\rightarrow$ $$\boxed{\frac{\partial J_i}{\partial \theta_{1,1}^{[1]}} = x_i \, \delta_{1,i}^{[1]}}$$

$\frac{\partial J_i}{\partial b_1^{[1]}} = \frac{\partial J_i}{\partial z_{1,i}^{[1]}} \frac{\partial z_{1,i}^{[1]}}{\partial b_1^{[1]}}$ ($\frac{\partial z_{1,i}^{[1]}}{\partial b_1^{[1]}} = 1$)

$\rightarrow$ $$\boxed{\frac{\partial J_i}{\partial b_1^{[1]}} = \delta_{1,i}^{[1]}}$$

Powered by CamScanner

3. (30%) Considere una membrana cuadrada de lado unitario, con bordes fijos, cuyos desplazamientos transversales (U(x,y,t)), respecto a su posición de equilibrio, están descritos, en el régimen de pequeñas oscilaciones, por la ecuación de ondas adimensional:

$$\frac{\partial^2 U}{\partial t^2} = \frac{\partial^2 U}{\partial x^2} + \frac{\partial^2 U}{\partial y^2}$$

con $U = 0$ en los bordes y condiciones iniciales

$$U(x, y, 0) = \sin(\pi x)\sin(\pi y),$$

$$U_t(x, y, 0) = \sqrt{2}\pi \sin(\pi x)\sin(\pi y).$$

Aproxime el desplazamiento $U(x, y, t)$ mediante una PINN de la forma

$$U_\theta(x, y, t) = \sin(\pi x)\sin(\pi y)a_\theta(t).$$

donde $a_\theta(t)$ se representa mediante las siguientes arquitecturas:

Modelo A. Una capa con dos neuronas de activación sinusoidal:

$$a_\theta(t) = \sum_{j=1}^{2} A_j \sin(w_j t + b_j).$$

Modelo B. Dos capas consecutivas, con una neurona por capa:

$$h_1(t) = \sin(w_1 t + b_1),$$

$$a_\theta(t) = A \sin(w_2 h_1(t) + b_2).$$

Parte analítica. Para ambas arquitecturas, reducir la ecuación de ondas a una ecuación diferencial ordinaria, calcular analíticamente las derivadas de las neuronas y construir el residuo físico y la función de pérdida, incorporando las condiciones iniciales.

Parte computacional. Implementar en Python ambas arquitecturas y minimizar sus funciones de pérdida mediante un método de optimización. Comparar gráficamente las soluciones obtenidas con la solución analítica, cuantificar los errores de aproximación y analizar la conservación de la energía mecánica de la membrana. Analice todos los resultados.

Ayuda: La energía mecánica total se conserva:

$$E(t) = \frac{1}{2}\int_0^1 \int_0^1 \left[\left(\frac{\partial U}{\partial t}\right)^2 + \left(\frac{\partial U}{\partial x}\right)^2 + \left(\frac{\partial U}{\partial y}\right)^2\right] dx\, dy.$$

$$\frac{dE}{dt} = 0.$$

Powered by CamScanner

Solución

- Parte analítica

- Reducir la ecuación de ondas a una EDO

$$U_{tt} = U_{xx} + U_{yy} \rightarrow \text{Ecuación de ondas}$$

- La PINN propuesta es

$$U_\theta(x, y, t) = \operatorname{sen}(\pi x)\operatorname{sen}(\pi y)\, a_\theta(t)$$

$$\rightarrow U_x = \pi \operatorname{sen}(\pi x)\operatorname{sen}(\pi y)\, a_\theta(t)$$

$$\rightarrow U_{xx} = -\pi^2 \cos(\pi x)\operatorname{sen}(\pi y)\, a_\theta(t)$$

$$\rightarrow U_y = \pi \operatorname{sen}(\pi x)\cos(\pi y)\, a_\theta(t)$$

$$\rightarrow U_{yy} = -\pi^2 \operatorname{sen}(\pi x)\operatorname{sen}(\pi y)\, a_\theta(t)$$

$$\rightarrow U_{tt} = \operatorname{sen}(\pi x)\operatorname{sen}(\pi y)\, a''_\theta(t)$$

Powered by CamScanner

Remplazando en la EDP

$$\operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)\, a_\theta''(t) = -2\pi^2 \operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)\, a_\theta(t)$$

$$\rightarrow \boxed{a_\theta''(t) + 2\pi^2 a_\theta(t) = 0}$$

Esta ecuación es la de un oscilador armónico con frecuencia $\omega = \sqrt{2\pi^2} = \sqrt{2}\,\pi$

El polinomio característico de esa EDO es

$$\lambda^2 + 2\pi^2 = 0 \rightarrow \lambda = \pm \sqrt{2}\,\pi i$$

y la solución analítica es una combinación lineal de funciones armónicas, así

$$a_\theta(t) = C_1 \cos(\sqrt{2}\,\pi t) + C_2 \operatorname{Sen}(\sqrt{2}\,\pi t)$$

$$\rightarrow a'(t) = -\sqrt{2\pi^2}\, C_1 \operatorname{Sen}(\sqrt{2}\,\pi t) + \sqrt{2}\,\pi C_2 \cos(\sqrt{2}\,\pi t)$$

Powered by CamScanner

Condiciones iniciales

- $U(x,y,0) = \operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)\, a_\theta(0) = \operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)$

$\rightarrow a_\theta(0) = 1$

$\rightarrow \boxed{C_1 = 1}$

- $U_t(x,y,0) = \operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)\, a_\theta'(0) = \sqrt{2}\,\pi \operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)$

$\rightarrow a'(0) = \sqrt{2}\,\pi = \sqrt{2}\,\pi C_2$

$\rightarrow C_2 = 1$

$\rightarrow$ Solución exacta

$$a(t) = \cos(\sqrt{2}\,\pi t) + \operatorname{Sen}(\sqrt{2}\,\pi t)$$

Así entonces, la solución exacta de la membrana es

$$U(x,y,t) = \operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)\left[\cos(\sqrt{2}\,\pi t) + \operatorname{Sen}(\sqrt{2}\,\pi t)\right]$$

Powered by CamScanner

El residuo se define como

$$r_\theta = \mathcal{N} v_\theta - f(x,y,t)$$

donde

$$\mathcal{N} = \frac{\partial^2}{\partial t^2} - \frac{\partial^2}{\partial x^2} - \frac{\partial^2}{\partial y^2} \quad ; \quad f = 0$$

$$\rightarrow r_\theta = \operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)\, a_\theta''(t) + 2\pi^2 \operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)\, a_\theta(t)$$

$$= \operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)\left[a_\theta''(t) + 2\pi^2 a_\theta(t) \right]$$

Como el factor espacial no es nulo en el interior, evaluar $r_\theta = 0$ equivale a evaluar el residuo de la EDO

$$r_\theta(t) = a_\theta''(t) + 2\pi^2 a_\theta(t)$$

Para el modelo A

$$a_\theta(t) = \sum_{j=1}^{2} A_j \operatorname{Sen}(\omega_j t - b_j)$$

$$\theta = (A_1, A_2, \omega_1, \omega_2, b_1, b_2)$$

Powered by CamScanner

- $h_1'(t) = \omega_1 \cos[\omega_1 t + b_1]$

- $h_1''(t) = -\omega_1^2 \operatorname{Sen}[\omega_1 t + b_1] = -\omega_1^2 h_1(t)$

- $a_0'(t) = A \cos[\omega_2 h_1(t) + b_2] \cdot \omega_2 h_1'(t)$

- $a_0''(t) = A\omega_2 \left[h_1''(t) \cos[\omega_2 h_1(t) + b_2] + h_1'(t) \left(-\operatorname{Sen}[\omega_2 h_1(t) + b_2]\right) \omega_2 h_1'(t) \right]$

$$= A\omega_2 \left[-\omega_1^2 h_1(t) \cos[\omega_2 h_1(t) + b_2] - \omega_1^2 \cos^2(\omega_1 t + b_1) \cdot \omega_2 \operatorname{Sen}[\omega_2 h_1(t) + b_2] \right]$$

$$= -A\omega_1^2 \omega_2 \left[\operatorname{Sen}[\omega_1 t + b_1] \cos[\omega_2 h_1(t) + b_2] + \omega_2 \cos^2[\omega_1 t + b_1] \operatorname{Sen}[\omega_2 h_1 + b_2] \right]$$

haciendo $\phi(t) = \omega_1 t + b_1$ y $g(t) = \omega_2 h_1(t) + b_2$

$$= \omega_2 \operatorname{Sen}[\phi(t)] + b_2$$

$$\rightarrow a_0''(t) = -A\omega_1^2 \omega_2 \left[\operatorname{Sen}[\phi(t)] \cos[g(t)] + \omega_2 \cos^2[\phi(t)] \operatorname{Sen}[g(t)] \right]$$

Powered by CamScanner

$$\rightarrow \Gamma_\theta = \alpha''_{\theta_i}(t) + 2\pi^2 \alpha_\theta(t)$$

$$= A\Big[-\omega_1^2 \omega_2 \operatorname{Sen}[\phi(t)] \cos[g(t)]$$

$$- \omega_1^2 \omega_2^2 \cos^2[\phi(t)] \operatorname{Sen}[g(t)]$$

$$+ 2\pi^2 \operatorname{Sen}[g(t)]\Big]$$

Função de pérdida

$$J = w_{ec} J_{ec} + w_{ini} J_{ini} + w_f J_f$$

$$\cdot J_{ic} = \frac{1}{N_r} \sum_{k=1}^{N_r} |\Gamma_\theta(t_k)|^2 = \frac{1}{N_r} \sum_{k=1}^{N_r} |\alpha''_\theta(t_k) + 2\pi^2 \alpha_\theta(t_k)|^2$$

$$\cdot J_{ini} = [\alpha_\theta(0) - 1]^2 + [\alpha'_\theta(0) - \sqrt{2}\pi]^2$$

$$\cdot J_f = 0$$

$$\rightarrow J(\theta) = \frac{w_{ec}}{N_r} \sum_{k=1}^{N_r} |\Gamma_\theta(t_k)|^2 + w_{ini}\left[(\alpha_\theta(0) - 1)^2 + (\alpha'_\theta(0) - \sqrt{2}\pi)^2 \right]$$

Powered by CamScanner

4. (30%) Considere una red de memoria asociativa formada por N neuronas que almacena P patrones binarios. Cada patrón se representa mediante un vector de N componentes, cuyos valores son $+1$ o -1. Los patrones almacenados se organizan en una matriz X de tamaño $P \times N$, cuyos elementos son

$$x_{\mu i} \in \{-1, +1\},$$

donde $\mu = 1, \ldots, P$ identifica el patrón almacenado e $i = 1, \ldots, N$ identifica la neurona.

El estado de la red se describe mediante un vector $\mathbf{q} = (q_1, \ldots, q_N)$, donde $q_i \in \mathbb{R}$ representa el estado de la neurona i. Inicialmente, la red recibe un patrón binario $\mathbf{q}^{(0)}$, que puede contener errores respecto a uno de los patrones almacenados.

La recuperación de la memoria se realiza mediante la minimización de la función de energía

$$E(\mathbf{q}) = \frac{1}{2} \sum_{i=1}^{N} q_i^2 - \frac{1}{\beta} \ln \left(\sum_{\mu=1}^{P} \exp \left[\beta \sum_{i=1}^{N} x_{\mu i} q_i \right] \right)$$

donde $\beta > 0$ es un parámetro que controla la selectividad de la recuperación. Durante la evolución de la red, los valores q_i pueden ser continuos, aunque los patrones almacenados sean binarios.

Parte analítica

- Calcular las derivadas parciales de la energía respecto a cada componente q_i y obtener la expresión del gradiente.
- A partir del descenso de gradiente, deducir la regla de actualización:

$$q_i^{(t+1)} = q_i^{(t)} - \alpha \left. \frac{\partial E}{\partial q_i} \right|_{\mathbf{q}=\mathbf{q}^{(t)}}.$$

  donde $\alpha > 0$ es el tamaño del paso de actualización y $t = 0, 1, 2, \ldots$ representa el número de iteración.
- Considerar el caso $\alpha = 1$ y simplificar la regla de actualización. Analizar cómo influye el parámetro β en la contribución de los diferentes patrones almacenados, considerando valores pequeños y grandes.

Parte computacional

- Implementar en Python una red de memoria asociativa que almacene dos patrones binarios correspondientes a las letras J y H, representados mediante imágenes de 8×8 píxeles. Cada patrón contiene $N = 64$ componentes, donde $+1$ representa un píxel activo y -1 uno inactivo. Organizar los patrones en una matriz X de tamaño 2×64.
- Seleccionar uno de los patrones almacenados y generar un estado inicial perturbado mediante la inversión aleatoria de un porcentaje de sus píxeles. Implementar iterativamente la regla de actualización obtenida en la parte analítica, utilizando $\alpha = 1$, hasta alcanzar la convergencia o un número máximo de iteraciones.
- Desarrollar experimentos computacionales que permitan:
  (a) Visualizar el patrón original, el patrón perturbado y el estado final de la red, tanto en su representación continua como binaria.
  (b) Estudiar cómo cambia la recuperación al modificar el porcentaje de píxeles perturbados. Realizar varias perturbaciones aleatorias para cada porcentaje y evaluar la calidad de la recuperación.
  (c) Analizar cómo influye el parámetro β en la evolución de la energía y en los estados finales de la red. Interpretar los resultados obtenidos.

Ayuda: Para evaluar la recuperación, convertir el estado final en un patrón binario según el signo de cada componente y calcular el porcentaje de píxeles que coinciden con el patrón original.

Powered by CamScanner

Solución

a)

- $\frac{\partial}{\partial q_i}\left[\frac{1}{2}\sum_{j=1}^{N} q_j^2\right] = q_i$

- Sea $u = \sum_{\mu=1}^{P} e^{\beta \sum_{j=1}^{N} x_{\mu j} q_j}$

- $\frac{\partial}{\partial q_i} \ln[u] = \frac{1}{u}\frac{\partial u}{\partial q_i}$

- $\frac{\partial u}{\partial q_i} = \sum_{\mu=1}^{P}\left[e^{\beta \sum_{j=1}^{N} x_{\mu j} q_j} \cdot \beta x_{\mu i}\right]$

$$= \beta \sum_{\mu=1}^{P}\left[x_{\mu i}\, e^{\beta \sum_{j=1}^{N} x_{\mu j} q_j}\right]$$

$$\rightarrow \frac{\partial E}{\partial q_i} = q_i - \frac{1}{\beta}\frac{\beta \sum_{\mu=1}^{P} x_{\mu i}\, e^{\beta \sum_{j=1}^{N} x_{\mu j} q_j}}{\sum_{\mu=1}^{P} e^{\beta \sum_{j=1}^{N} x_{\mu j} q_j}}$$

Powered by CamScanner

$$\rightarrow \frac{\partial E}{\partial q_i} = q_i - \frac{\sum_{\mu=1}^{P} x_{\mu i} e^{\beta \sum_{j=1}^{N} x_{\mu j} q_j}}{\sum_{\mu=1}^{P} e^{\beta \sum_{j=1}^{N} x_{\mu j} q_j}}$$

b) $$q_i^{t+1} = q_i^t - \alpha \left[q_i^t - \frac{\sum_{\mu=1}^{P} x_{\mu i} e^{\beta \sum_{j=1}^{N} x_{\mu j} q_j}}{\sum_{\mu=1}^{P} e^{\beta \sum_{j=1}^{N} x_{\mu j} q_j}} \right]$$

c) para $\alpha = 1$

$$q_i^{t+1} = \frac{\sum_{\mu=1}^{P} x_{\mu i} e^{\beta \sum_{j=1}^{N} x_{\mu j} q_j}}{\sum_{\mu=1}^{P} e^{\beta \sum_{j=1}^{P} x_{\mu j} q_j}}$$

~~Para~~ Para valors pequeños de β, los exponents tienen valors similars por lo tanto los valors contribuyen de manera uniforme a la actualización.

Powered by CamScanner

- Para valores grandes de β, el patrón que tenga un mayor producto interno $\sum_j x_{uj} g_j$ tendrá una contribución dominante. Por lo tanto, la ruleta se vuelve más selectiva.

Powered by CamScanner