

1. Regresión lineal multivariada desde máxima verosimilitud

En regresión lineal se busca modelar una variable continua Y a partir de variables de entrada X . Una forma natural de hacerlo es suponer que la salida observada está formada por una parte determinista, $\theta^T x$, más una fluctuación aleatoria.

Considere

$$\mathcal{D} = \{(x^{(i)}, y^{(i)})\}_{i=1}^m,$$

con

$$x^{(i)} = \begin{bmatrix} 1 \\ x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix}, \quad \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}.$$

Suponga que

$$y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)}, \quad \varepsilon^{(i)} \sim \mathcal{N}(0, \sigma^2).$$

La hipótesis gaussiana permite construir una distribución para Y y, a partir de ella, una función de verosimilitud para los datos observados.

1. Determine la distribución de

$$Y^{(i)} \mid X = x^{(i)}.$$

2. Escriba

$$p(y^{(i)} \mid x^{(i)}; \theta).$$

3. Suponiendo independencia entre observaciones, construya

$$L(\theta).$$

4. Obtenga

$$\ell(\theta) = \log L(\theta).$$

5. Identifique los términos que dependen de θ .

6. Muestre que maximizar $\ell(\theta)$ equivale a minimizar la suma de residuos cuadrados.

7. Obtenga una función de coste de la forma

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2.$$

8. Explique por qué $1/2$ y $1/m$ no cambian el minimizador.

2. Gradiente y descenso por gradiente

Una vez construida $J(\theta)$, el aprendizaje puede verse como un problema de optimización. El gradiente indica cómo cambia el coste cuando cambia cada parámetro, y permite construir una regla iterativa para encontrar valores de θ que reduzcan el error.

Parta de

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2.$$

1. Calcule

$$\frac{\partial h_{\theta}(x^{(i)})}{\partial \theta_j}.$$

2. Use la regla de la cadena para hallar

$$\frac{\partial J}{\partial \theta_j}.$$

3. Escriba el resultado como suma sobre los m datos.

4. Construya

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}.$$

5. Escriba la actualización para

$$j = 0, 1, \dots, n.$$

6. Explique por qué los parámetros deben actualizarse simultáneamente.

3. Ecuación normal

Para regresión lineal también existe una solución analítica. La idea es escribir el coste en forma matricial e imponer directamente la condición de mínimo.

Defina

$$X = \begin{bmatrix} 1 & x_1^{(1)} & \cdots & x_n^{(1)} \\ 1 & x_1^{(2)} & \cdots & x_n^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & \cdots & x_n^{(m)} \end{bmatrix},$$

$$y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix}, \quad J(\theta) = \frac{1}{2m} (X\theta - y)^T (X\theta - y).$$

1. Expanda

$$(X\theta - y)^T (X\theta - y).$$

2. Calcule

$$\nabla_{\theta} J(\theta).$$

3. Imponga

$$\nabla_{\theta} J(\theta) = 0.$$

4. Obtenga

$$X^T X \theta = X^T y.$$

5. Si $X^T X$ es invertible, despeje θ .

6. Compare esta solución con descenso por gradiente:

- ¿cuál es iterativa?
- ¿cuál es analítica?
- ¿cuándo puede fallar la inversión?

4. Regresión logística desde la familia exponencial

En clasificación binaria, Y toma dos valores posibles. Por ello, la distribución Bernoulli proporciona un punto de partida natural. Al escribirla como miembro de la familia exponencial se obtiene una relación entre su parámetro natural y una función lineal de x .

Considere

$$p(y; \eta) = b(y) \exp [\eta T(y) - a(\eta)],$$

y para $Y \in \{0, 1\}$,

$$p(y; \phi) = \phi^y (1 - \phi)^{1-y}.$$

1. Reescriba Bernoulli usando una exponencial.
2. Identifique el parámetro natural η .
3. Muestre que

$$\eta = \log \frac{\phi}{1 - \phi}.$$

4. Despeje ϕ en función de η .

5. Si

$$\eta = \theta^T x,$$

obtenga

$$P_{\theta}(Y = 1 \mid X = x).$$

6. Defina esta cantidad como

$$h_{\theta}(x).$$

7. Obtenga

$$P_{\theta}(Y = 0 \mid X = x).$$

5. Likelihood y función de coste logística

Una vez obtenida $h_{\theta}(x)$, cada observación puede interpretarse probabilísticamente. Para $y = 1$, el modelo asigna probabilidad $h_{\theta}(x)$; para $y = 0$, asigna $1 - h_{\theta}(x)$. A partir de ambas posibilidades se construye una única expresión para la verosimilitud.

1. Escriba una expresión única para

$$p(y^{(i)} \mid x^{(i)}; \theta)$$

válida para $y^{(i)} = 0$ y $y^{(i)} = 1$.

2. Construya la verosimilitud para m observaciones.
3. Calcule la log-verosimilitud.
4. Cambie el signo y normalice por m para obtener $J(\theta)$.

5. Identifique la entropía cruzada binaria.

6. Calcule

$$\frac{\partial J}{\partial \theta_j}.$$

7. Escriba la regla de descenso por gradiente.

8. Compare este gradiente con el de regresión lineal.

Puede ser útil recordar que

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad \sigma'(z) = \sigma(z) (1 - \sigma(z)).$$

6. Regularización

Un buen ajuste sobre los datos de entrenamiento no garantiza necesariamente una buena generalización. Una forma de controlar modelos con parámetros grandes es añadir una penalización a la función de coste. Para regularización L_2 ,

$$\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2.$$

El parámetro λ controla cuánto pesa esta penalización frente al ajuste a los datos.

1. Escriba el coste regularizado para regresión lineal.

2. Calcule

$$\frac{\partial J}{\partial \theta_j}, \quad j \geq 1.$$

3. Escriba por separado el caso $j = 0$.

4. Construya la actualización para $j \geq 1$.

5. Reorganice hasta obtener

$$\theta_j := \theta_j \left(1 - \frac{\alpha \lambda}{m} \right) - \text{término de datos.}$$

6. Interprete el factor

$$1 - \frac{\alpha \lambda}{m}.$$

7. Escriba el coste regularizado para regresión logística.

8. Obtenga el gradiente correspondiente.

9. Explique por qué normalmente no se regulariza θ_0 .

Referencias

Ng, A. Y. *CS229 Lecture Notes: Supervised Learning*. Stanford University.

Murphy, K. P. (2022). *Probabilistic Machine Learning: An Introduction*. MIT Press.

Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.

1) Regresión lineal multivariada desde la máxima Verosimilitud.

1.1) Determine la distribución de $Y^{(i)} / X = x^{(i)}$

$$\text{Como } Y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)} \quad \text{y} \quad \varepsilon^{(i)} \sim N(0, \sigma^2)$$

$$E[Y^{(i)} / X = x^{(i)}] = E[\theta^T x^{(i)}] + E[\varepsilon^{(i)}]$$

$$= \theta^T x^{(i)} + 0$$

$$= \theta^T x^{(i)}$$

$$\text{Var}[Y^{(i)} / X = x^{(i)}] = \sigma^2$$

Por lo tanto

$$Y^{(i)} / X = x^{(i)} \sim N(\theta^T x^{(i)}, \sigma^2)$$

1.2) Escriba $p(y^{(i)} | x^{(i)}; \theta)$

$p(y^{(i)} | x^{(i)}; \theta)$ es la función de densidad de una normal. Sustituimos la media ($\mu = \theta^T x^{(i)}$) y la varianza (σ^2).

$$p(y^{(i)} | x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}}$$

Esta es la probabilidad de observar $y^{(i)}$ dado $x^{(i)}$ y los parámetros θ .

3.3) Suponiendo independencia entre las observaciones, construya $L(\theta)$

La verosimilitud es la probabilidad de que todos los datos hayan ocurrido al mismo tiempo. Como asumimos que son independientes, multiplicamos las probabilidades de cada punto.

Tenemos n observaciones

$$D = \{(x^{(i)}, y^{(i)})\}_{i=1}^n$$

$$L(\theta) = \prod_{i=1}^n p(y^{(i)} | x^{(i)}; \theta)$$

$$= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right]$$

$$= \left[\frac{1}{\sqrt{2\pi\sigma^2}}\right]^n \prod_{i=1}^n \exp\left[-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right]$$

1.4) Obtenga $\ell(\theta) = \log L(\theta)$

$$\ell(\theta) = \log\left[\frac{1}{\sqrt{2\pi\sigma^2}}\right]^n = \sum_{i=1}^n \frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}$$

$$\rightarrow \ell(\theta) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y^{(i)} - \theta^T x^{(i)})^2$$

1.5) Identifique los términos que dependen de θ

El único término que depende de θ es

$$-\frac{1}{2\sigma^2} \sum_{i=1}^n (y^{(i)} - \theta^T x^{(i)})^2$$

1.6) Muestre que maximizar $l(\theta)$ equivale a minimizar la suma de residuos cuadradas

El primer término de $l(\theta)$ es constante. Además,

como $\frac{1}{2\sigma^2} > 0$, entonces

$$\text{maximizar} \quad -\frac{1}{2\sigma^2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2$$

equivale a minimizar

$$\sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2$$

esta cantidad es la suma de los residuos al cuadrado.

Por lo tanto, hemos demostrado que maximizar $l(\theta)$ equivale a minimizar la suma de los residuos al cuadrado.

1.7) Obtenga una función de coste de la forma

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Si definimos $h_{\theta}(x) = \theta^T x$, la función de coste queda

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

1.8) ¿Por qué $\frac{1}{2}$ y $\frac{1}{m}$ no cambian al minimizador?

Porque multiplicar una función por una constante positiva (como $\frac{1}{2}$ o $\frac{1}{m}$) no cambia al lugar donde está el mínimo.

Supongamos que

$$f(\theta) = \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$\rightarrow J(\theta) = \frac{1}{2m} f(\theta)$$

$$\text{si } f(\theta_1) < f(\theta_2) \rightarrow \frac{1}{2m} f(\theta_1) < \frac{1}{2m} f(\theta_2)$$

Si la función tiene su punto más bajo en O_i , y
la aplastamos o la estiramos verticalmente, el
valle sigue en el mismo O_i . El Y_{ij} se utiliza
para promediar al amor y al $1/2$ para que,
al derivar, se cancele el cuadrado.

2) Gradiente y descenso por gradiente

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i)^2$$

2.1) Calcular $\frac{\partial h_{\theta}(x^i)}{\partial \theta_j}$

Como $h_{\theta}(x^i) = \theta^T x^i$, donde $\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}$ y $x^i = \begin{bmatrix} 1 \\ x_1^i \\ \vdots \\ x_n^i \end{bmatrix}$

su producto es $h_{\theta}(x^i) = \theta_0 + \theta_1 x_1^i + \dots + \theta_j x_j^i + \dots + \theta_n x_n^i$

derivando respecto a un parámetro específico θ_j

$$\frac{\partial h_{\theta}(x^i)}{\partial \theta_j} = x_j^i$$

2.2) Use la regla de la cadena para hallar $\frac{\partial J}{\partial \theta_j}$

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i) \cdot x_j^i$$

2.3) Escriba el resultado como una suma sobre los m datos

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^n (h_{\theta}(x^i) - y^i) \cdot x_j^i$$

2.4) Construya $\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$

Para minimizar, nos movemos en la dirección contraria al gradiente (restamos)

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$$

El parámetro α se conoce como tasa de aprendizaje (learning rate). Sustituyendo el gradiente

$$\theta_j = \theta_j - \frac{\alpha}{m} \sum_{i=1}^n (h_{\theta}(x^i) - y^i) \cdot x_j^i$$

esta regla se conoce como la regla de descenso por gradiente para regresión lineal.

2.5) Escribe la actualización para $j=0, 1, \dots, n$

La regla se aplica a todos los parámetros $j=0, 1, \dots, n$

Por lo tanto

$$\theta_j \leftarrow \theta_j - \frac{\alpha}{n} \sum_{i=1}^m (h_{\theta}(x^i) - y^i) \cdot x_j^i$$

Para $j=0, 1, \dots, n$. Como $x_0^i = 1$, para el intercepto

$$\theta_0 \leftarrow \theta_0 - \frac{\alpha}{n} \sum_{i=1}^m (h_{\theta}(x^i) - y^i)$$

para θ_1

$$\theta_1 \leftarrow \theta_1 - \frac{\alpha}{n} \sum_{i=1}^m (h_{\theta}(x^i) - y^i) \cdot x_1^i$$

y así sucesivamente para todos los demás hasta θ_n .

2.6) Explique por qué los parámetros deben actualizarse simultáneamente

Porque conceptualmente lo que hacemos es

$$\theta^{\text{nuevo}} = \theta^{\text{viejo}} - \alpha \nabla J(\theta^{\text{viejo}})$$

Es decir, usamos los valores antiguos de los parámetros para calcular los gradientes y los nuevos parámetros.

Si actualizáramos primero θ_0 y luego lo usamos para calcular θ_1 , estaríamos calculando el gradiente incorrecto.

En otras palabras, porque el gradiente $\nabla J(\theta)$ corresponde a un mismo punto en el espacio de parámetros. Si actualizamos un parámetro antes que otro, estaríamos calculando los diferentes componentes del gradiente en puntos diferentes. Por eso, se debe calcular todos los nuevos valores usando los viejos y luego cambiarlos todos a la vez.

3) Ecuación normal

En esta parte buscamos la misma solución que el descenso por gradiente, pero mediante una solución analítica directa. La idea central es que en lugar de dar pasos, hay una fórmula que nos lleva al punto más bajo en un solo cálculo, usando matrices.

3.1) Expandir $(x\theta - y)^T(x\theta - y)$

$$\begin{aligned}(x\theta - y)^T(x\theta - y) &= [(x\theta)^T - y^T][x\theta - y] \\&= [\theta^T x^T - y^T][x\theta - y] \\&= \theta^T x^T x\theta - \theta^T x^T y - y^T x\theta + y^T y\end{aligned}$$

Pero como $y^T x\theta$ es un escalar, entonces

$$y^T x\theta = [y^T x\theta]^T = x^T \theta^T y$$

Así entonces

$$(x\theta - y)^T(x\theta - y) = \theta^T x^T x\theta - 2x^T \theta^T y + y^T y$$

3.2) Calcular $\nabla_{\theta} J(\theta)$

$$J(\theta) = \frac{1}{2m} (X\theta - y)^T (X\theta - y)$$

$$= \frac{1}{2m} [\theta^T X^T X \theta - 2\theta^T X^T y + y^T y]$$

$$\nabla_{\theta} J(\theta) = \frac{1}{2m} \left[\frac{\partial}{\partial \theta} (\theta^T X^T X \theta) - 2 \frac{\partial}{\partial \theta} (\theta^T X^T y) + \frac{\partial}{\partial \theta} (y^T y) \right]$$

Luego

$$\frac{\partial}{\partial \theta} [\theta^T X^T X \theta] = [X^T X + (X^T X)^T] \theta$$

$$= [X^T X + X^T X] \theta$$

$$= 2 X^T X \theta$$

donde se aplicó la propiedad

$$\frac{\partial}{\partial \theta} [\theta^T A \theta] = (A + A^T) \theta \quad \text{con } A = X^T X$$

Para el segundo término

$$\frac{\partial}{\partial \theta} [\theta^T x^T y] = x^T y$$

donde se aplicó la propiedad de

$$\frac{\partial}{\partial \theta} [\theta^T a] = a, \text{ con } a = x^T y$$

Como el tercer término no depende de $\theta \rightarrow \frac{\partial}{\partial \theta} [y^T y] = 0$

Así las cosas, tenemos

$$\nabla_{\theta} J(\theta) = \frac{1}{\cancel{2}m} [\cancel{2} x^T x \theta - \cancel{2} x^T y] = \frac{1}{m} [x^T x \theta - x^T y]$$

3.3 y 3.4) Imponga $\nabla_{\theta} J(\theta) = 0$ y obtenga $x^T x \theta = x^T y$

$$\text{Si } \nabla_{\theta} J(\theta) = 0 \rightarrow \frac{1}{m} [x^T x \theta - x^T y] = 0$$

$$\rightarrow x^T x \theta - x^T y = 0$$

$$\rightarrow x^T x \theta = x^T y$$

3.5) Si $X^T X$ es invertible, despeja θ

Si $X^T X$ es invertible, entonces multiplicamos por su inversa a ambos lados de la ecuación del punto anterior, así:

$$\cancel{[X^T X]^{-1}} \cancel{[X^T X]} \theta = [X^T X]^{-1} X^T y$$

$$\rightarrow \theta = (X^T X)^{-1} X^T y$$

3.6) Compare esta solución con descenso por gradiente.

Descenso por gradiente

- Iterativa (da pasos hasta converger)
- Funciona con millones de datos
- Siempre funciona si se elige bien α

Ecuación normal

- Analítica (Da la solución directa).
- Falla con millones de datos porque invertir una matriz enorme es muy lento.
- Puede fallar si $X^T X$ no es invertible (y: hay columnas repetidas o más características que datos).

4) Regresión logística desde la familia exponencial

4.1) Describa Bernoulli usando una exponencial

tenemos $p(y; \phi) = \phi^y (1-\phi)^{1-y}$ y queremos

escribirla como $p(y; \eta) = b(y) \exp[\eta^T(y) - a(\eta)]$

Usando la propiedad $a^b = e^{\ln a^b} = e^{b \ln a}$

$$\rightarrow \phi^y = e^{y \ln \phi} \quad y \quad (1-\phi)^{1-y} = e^{(1-y) \ln(1-\phi)}$$

$$\begin{aligned} \rightarrow p(y; \phi) &= e^{y \ln \phi} \cdot e^{(1-y) \ln(1-\phi)} \\ &= e^{(\ln \phi - \ln(1-\phi))y + \ln(1-\phi)} \\ &= \exp\left[y \ln\left(\frac{\phi}{1-\phi}\right) + \ln(1-\phi)\right] \end{aligned}$$

4.2) Identifique el parámetro natural η

De la ecuación anterior se puede ver fácilmente que

$$\eta = \ln\left(\frac{\phi}{1-\phi}\right) \text{ al compararla con la forma estándar.}$$

4.3) Muestre que $\eta = \ln \frac{\phi}{1-\phi}$

Como se vio en el inciso anterior $\eta = \ln \frac{\phi}{1-\phi}$

4.4) Despeje ϕ en función de η

$$\eta = \ln \frac{\phi}{1-\phi} \rightarrow e^{\eta} = \frac{\phi}{1-\phi}$$

$$\rightarrow e^{\eta} - \phi e^{\eta} = \phi$$

$$\rightarrow \phi [1 + e^{\eta}] = e^{\eta}$$

$$\rightarrow \phi = \frac{e^{\eta}}{1 + e^{\eta}}$$

$$\rightarrow \phi = \frac{1}{1 + e^{-\eta}}$$

Esta función se conoce
como función sigmoide
o función logística.

4.5) Si $\eta = \theta^T x$ obtenga $P_\theta(Y=1/X=x)$

En la regresión logística, decidimos que el parámetro natural η sea una combinación lineal de nuestras variables de entrada, es decir, $\eta = \theta^T x$.

Como ϕ es la probabilidad de que $Y=1$, entonces

$$P_\theta(Y=1/X=x) = \phi = \frac{1}{1 + e^{-\eta}} = \frac{1}{1 + e^{-\theta^T x}}$$

4.6) Defina esta cantidad como $h_\theta(x)$

$$h_\theta(x) = \frac{1}{1 + e^{-\theta^T x}}$$

La h viene de hipótesis

4.7) Obtenga $P_\theta(Y=0/X=x)$

Como Y solo puede tomar dos valores $Y \in \{0, 1\}$ las probabilidades deben sumar 1

$$\rightarrow P_\theta(Y=0/X=x) = 1 - P_\theta(Y=1/X=x) = 1 - \frac{1}{1 + e^{-\theta^T x}}$$

$$\rightarrow P_\theta(Y=0/X=x) = \frac{e^{-\theta^T x}}{1 + e^{-\theta^T x}}$$

5) Likelihood y función de coste logística

5.1) Escriba una única expresión para $p(y^i | x^i; \theta)$ válida para $y^i = 0$ y $y^i = 1$

Queremos una expresión que

- 1) Si $y^i = 1 \rightarrow$ devuelva $h_\theta(x)$
- 2) Si $y^i = 0 \rightarrow$ devuelva $1 - h_\theta(x)$

La expresión

$$p(y^i | x^i; \theta) = [h_\theta(x)]^{y^i} [1 - h_\theta(x)]^{1 - y^i}$$

cumple con las condiciones.

5.2) Construya la verosimilitud para n observaciones

Tenemos un conjunto de datos

$$D = \{(x^i, y^i)\}_{i=1}^n$$

La verosimilitud $L(\theta)$ es la probabilidad de todos los datos observados. Como asumimos que todos los observaciones

Son independientes entre si, multiplicamos las probabilidades individuales

$$L(\theta) = \prod_{i=1}^m P(y^i | x^i; \theta)$$

$$= \prod_{i=1}^m [h_{\theta}(x^i)]^{y^i} [1 - h_{\theta}(x^i)]^{1-y^i}$$

5.3) Calcule el log-verosimilitud

Aplicamos al logaritmo de la verosimilitud porque convierte la multiplicación en sumas y es más fácil de derivar. Además, los números no se vuelven increíblemente pequeños (evita problemas numéricos).

El log-verosimilitud se define como

$$l(\theta) = \log [L(\theta)]$$

Esta función nos dice que tan bien los parámetros θ explican los datos observados.

Nuestro objetivo será encontrar los valores de θ que maximizan esta función.

$$\begin{aligned}
 \rightarrow \ell(\theta) &= \log \left(\prod_{i=1}^n [h_{\theta}(x^i)]^{y^i} [1 - h_{\theta}(x^i)]^{1-y^i} \right) \\
 &= \sum_{i=1}^n \log \left([h_{\theta}(x^i)]^{y^i} [1 - h_{\theta}(x^i)]^{1-y^i} \right) \\
 &= \sum_{i=1}^n [y^i \log(h_{\theta}(x^i)) + (1-y^i) \log(1 - h_{\theta}(x^i))]
 \end{aligned}$$

5.4) Cambie el signo y normalice por n para obtener $J(\theta)$

En Machine Learning, por convención, minimizamos funciones de coste (no maximizamos verosimilitudes).

Entonces:

- 1) Cambiamos el signo: $-\ell(\theta)$ esto convierte maximizar en minimizar
- 2) Dividimos por n para obtener el promedio, de tal forma que el coste no depende del número de datos

$$J(\theta) = -\frac{1}{n} \ell(\theta)$$

Así entonces

$$J(\theta) = -\frac{1}{n} \sum_{i=1}^n [y^i \log(h_{\theta}(x^i)) + (1-y^i) \log(1-h_{\theta}(x^i))]$$

Otra razón por la que se cambia el signo de $J(\theta)$ es porque normalmente los algoritmos de optimización, como el descenso por gradiente, se plantean como un problema de minimización.

La función anterior es la función de coste de regresión logística. También se llama entropía cruzada binaria. Es la función que vamos a minimizar para encontrar los mejores θ .

5.5) Identifique la entropía cruzada binaria

La expresión para $J(\theta)$ en el ítem anterior es conocida como la entropía cruzada binaria. Esta entropía cruzada mide la diferencia entre dos distribuciones de probabilidad: la distribución real y^i que observamos, que son 0 ó 1, y la distribución estimada; las probabilidades $h_{\theta}(x^i)$ que predice el modelo.

5.6) Calcola $\frac{\partial J}{\partial \theta_j}$

$$\begin{aligned}\frac{\partial J(\theta)}{\partial \theta_j} &= -\frac{1}{n} \sum_{i=1}^n \left[\frac{y^i}{h_\theta(x^i)} \frac{\partial h_\theta(x^i)}{\partial \theta_j} + \frac{1-y^i}{1-h_\theta(x^i)} \frac{\partial (1-h_\theta(x^i))}{\partial \theta_j} \right] \\ &= -\frac{1}{n} \sum_{i=1}^n \left[\frac{y^i}{h_\theta(x^i)} - \frac{1-y^i}{1-h_\theta(x^i)} \right] \frac{\partial h_\theta(x^i)}{\partial \theta_j}\end{aligned}$$

Come $h_\theta(x^i) = [1 + e^{-\theta^T x^i}]^{-1}$

$$\rightarrow \frac{\partial h_\theta(x^i)}{\partial \theta_j} = -[1 + e^{-\theta^T x^i}]^{-2} \cdot e^{-\theta^T x^i} \cdot \frac{\partial [-\theta^T x^i]}{\partial \theta_j}$$

Puro

$$\theta^T x^i = [\theta_0, \theta_1, \theta_2, \dots, \theta_n] \begin{bmatrix} 1 \\ x_1^i \\ x_2^i \\ \vdots \\ x_n^i \end{bmatrix} = \theta_0 + \theta_1 x_1^i + \theta_2 x_2^i + \dots + \theta_n x_n^i$$

$$\rightarrow \frac{\partial}{\partial \theta_j} [\theta^T x^i] = x_j^i$$

$$\rightarrow \frac{\partial}{\partial \theta_j} h_\theta(x^i) = -h_\theta^2(x^i) \cdot e^{-\theta^T x^i} \cdot [-x_j^i]$$

$$e^{-\theta^T x^i} = \frac{1 - h_\theta(x^i)}{h_\theta(x^i)}$$

$$\begin{aligned} \rightarrow \frac{\partial h_\theta(x^i)}{\partial \theta_j} &= h_\theta^2(x^i) \cdot \frac{1 - h_\theta(x^i)}{h_\theta(x^i)} x_j^i \\ &= h_\theta(x^i) [1 - h_\theta(x^i)] x_j^i \end{aligned}$$

Así entonces

$$\frac{\partial J(\theta)}{\partial \theta_j} = -\frac{1}{m} \sum_{i=1}^m \left[\frac{y^i}{h_\theta(x^i)} - \frac{1 - y^i}{1 - h_\theta(x^i)} \right] h_\theta(x^i) [1 - h_\theta(x^i)] x_j^i$$

$$= -\frac{1}{m} \sum_{i=1}^m \left[y^i (1 - h_\theta(x^i)) - (1 - y^i) h_\theta(x^i) \right] x_j^i$$

$$= -\frac{1}{m} \sum_{i=1}^m [y^i - h_\theta(x^i)] x_j^i$$

finalmente

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{n} \sum_{i=1}^n [h_{\theta}(x^i) - y^i] x_j^i$$

5.7) Escriba la regla de descenso por gradiente.

La regla de descenso por gradiente es

$$\theta_j \leftarrow \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$$

$$\rightarrow \theta_j \leftarrow \theta_j - \frac{\alpha}{n} \sum_{i=1}^n [h_{\theta}(x^i) - y^i] x_j^i$$

para $j = 0, 1, \dots, n$

5.8) Compare este gradiente con el de regresión lineal
puede ser útil recordar que

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad \sigma'(z) = \sigma(z)(1 - \sigma(z))$$

El gradiente de la regresión lineal

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{n} \sum_{i=1}^n [h_{\theta}(x^i) - y^i] x_j^i$$

donde $h_{\theta}(x^i) = \theta^T x_i$ [función lineal]

El gradiente de regresión logística

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{n} \sum_{i=1}^n [h_{\theta}(x^i) - y^i] x_j^i$$

donde $h_{\theta}(x^i) = \frac{1}{1 + e^{-\theta^T x_i}}$ (función sigmoide)

Tienen la misma forma, pero lo único que cambias es la definición de $h_{\theta}(x^i)$

- Esto es importante porque podemos usar el mismo algoritmo de descenso por gradiente para ambos modelos. Solo cambiamos la función $h_{\theta}(x)$.

• Se puede ver que en ambos casos el gradiente es al error $(h - y)$ multiplicado por la característica x_j . Esto es muy intuitivo; si el error es grande, ajustamos más y si es pequeño, ajustamos menos.

6) Regularización

Si tenemos un modelo muy complejo, con muchos parámetros. Este modelo podría memorizar los datos de entrenamiento en lugar de aprender el patrón general. Esto se llama sobreajuste. La regularización castiga a los parámetros por ser demasiado grandes. Así el modelo se ve forzado a ser más simple y generaliza mejor a datos nuevos.

La penalización L_2 (Ridge) añade a la función de coste el término

$$\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

donde λ controla la fuerza de la penalización

6.1) Escriba el coste regularizado para regresión lineal

Al agregar la penalización, el coste regularizado queda como

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i)^2 + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

6.2) Calcule $\frac{\partial J}{\partial \theta_j}$, $j \geq 1$

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i) x_j^i + \frac{\lambda}{2m} [2\theta_j]$$

$$= \lambda \theta_j / m + \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i) x_j^i$$

6.3) Escriba ~~por~~ separado el caso $j=0$

$$\frac{\partial J(\theta)}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i) x_0^i$$

6.4) Construya la actualización para $j \geq 1$

$$\theta_j \leftarrow \theta_j - \alpha \frac{\partial J(\theta)}{\partial \theta_j}$$

$$\rightarrow \theta_j \leftarrow \theta_j - \alpha \left[\frac{\lambda \theta_j}{m} + \frac{1}{m} \sum_{i=1}^m (h_\theta(x^i) - y^i) x_j^i \right]$$

$$\theta_j \leftarrow \theta_j - \alpha \frac{\lambda}{m} \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^i) - y^i) x_j^i$$

6.5) Reorganice hasta obtener

$$\theta_j := \theta_j \left(1 - \alpha \frac{\lambda}{m} \right) - \text{término de datos}$$

$$\theta_j \leftarrow \theta_j \left(1 - \alpha \frac{\lambda}{m} \right) - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^i) - y^i) x_j^i$$

6.6) Interprete el factor $1 - \alpha \frac{\lambda}{m}$

Este factor es llamado el factor de contracción o weight decay (decremento del peso)

Interpretación

- 1) Efecto: En cada paso de actualización, al parámetro θ_j se reduce o recoge un poco antes de restarle el error de los datos.
- 2) Si $\lambda > 0$: El factor es menor que 1, así θ_j disminuye ligeramente en cada iteración.
- 3) Si $\lambda = 0$: El factor es 1, y reparamos la actualización sin regulación.

6.7) Escriba el coste regularizado para regresión logística.

El coste regularizado para la regresión logística al agregar la penalización L_2 queda como:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^i \log h_{\theta}(x^i) + (1-y^i) \log (1-h_{\theta}(x^i))] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

6.8) obtenga el gradiente correspondiente.

para $j \geq 1$

$$\frac{\partial J(\theta)}{\partial \theta_j} = -\frac{1}{m} \sum_{i=1}^m \left[y^i \frac{h_\theta(x^i)(1-h_\theta(x^i))}{h_\theta(x^i)} x_j^i - \frac{(1-y^i)h_\theta(x^i)(1-h_\theta(x^i))x_j^i}{1-h_\theta(x^i)} \right]$$

$$+ \frac{\lambda}{m} \theta_j$$

$$= -\frac{1}{m} \sum_{i=1}^m \left[y^i - y^i h_\theta(x^i) + y^i h_\theta(x^i) \right] x_j^i + \frac{\lambda}{m} \theta_j$$

$$\rightarrow \frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m [h_\theta(x^i) - y^i] x_j^i + \frac{\lambda}{m} \theta_j$$

para $j=0$

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m [h_\theta(x^i) - y^i] x_0^i$$

$$= \frac{1}{m} \sum_{i=1}^m [h_\theta(x^i) - y^i]$$

6.9) Explique por qué normalmente no se regulariza θ_0 .

θ_0 no se regulariza porque es el término de sesgo/intercepto y su función es desplazar al modelo, no controlar la magnitud de los efectos de las características.

En otras palabras, el parámetro θ_0 no se regulariza porque no multiplica a ninguna característica de entrada, por lo que su valor no afecta la complejidad ni la flexibilidad del modelo. La regularización L_2 busca controlar la magnitud de los coeficientes que acompañan a las variables predictoras ($\theta_1, \theta_2, \dots, \theta_n$) para evitar que el modelo se vuelva demasiado sensible a pequeñas variaciones en los datos, pero el sesgo θ_0 simplemente desplaza la predicción hacia arriba o hacia abajo sin cambiar la forma de la función. Si regularizáramos θ_0 , estaríamos forzando artificialmente

al modelo a tener en intercepto cercano a cero, lo cual no tiene justificación estadística y podría introducir en riesgo innecesario en las predicciones, especialmente cuando los datos no están centrados en el origen. Por esta razón, es una convención estándar en la práctica excluir θ_0 de la ~~regularización~~ y solo aplicar la regularización a los coeficientes que realmente controlan la influencia de las características.