

Reto: Física computacional Avanzada

Profesor. Hernán Salinas,*

PACS numbers:

A. Principio Varaicional de Gibss

Consideremos un sistema estadístico cuyos microestados están descritos por configuraciones $\mathbf{s} \in \mathcal{S}$, y a cada configuración le corresponde una energía $E(\mathbf{s})$. A una temperatura T , la distribución de equilibrio del sistema está dada por la distribución de Boltzmann $p_B(\mathbf{s})$,

$$p_B(\mathbf{s}) = \frac{1}{Z} e^{-\beta E(\mathbf{s})},$$

es la función de partición. A partir de la descripción energética del sistema, nuestro objetivo es construir un modelo paramétrico $q_\theta(\mathbf{s})$ que aproxime la distribución de equilibrio $p_B(\mathbf{s})$ y permita generar nuevas configuraciones representativas del sistema. Esta distribución puede aproximarse con un modelos probabilísticos parametrizados, en nuestro acaso utilizaremos un Trasnfomer autoregresivo, que representa esta distribución mediante el producto de probabilidades condicionales:

$$q_\theta(\mathbf{s}) = \prod_{i=1}^N q_\theta(s_i | s_1, \dots, s_{i-1}),$$

cada factor expresa la probabilidad de una componente s_i dados los valores de las componentes anteriores, mientras que θ denota los parámetros de la red neuronal.

El problema consiste entonces en ajustar estos parámetros para que $q_\theta(\mathbf{s})$ se aproxime a $p_B(\mathbf{s})$. Para cuantificar la discrepancia entre ambas distribuciones, utilizaremos la divergencia de Kullback–Leibler:

$$D_{\text{KL}}(q_\theta \| p_B) = \sum_{\mathbf{s}} q_\theta(\mathbf{s}) \ln \frac{q_\theta(\mathbf{s})}{p_B(\mathbf{s})}.$$

Desarrollando el logaritmo y empleando la distribución de Boltzmann, tenemos que:

$$D_{\text{KL}}(q \| p_B) = \sum_{\mathbf{s}} q(\mathbf{s}) \ln q(\mathbf{s}) + \beta \sum_{\mathbf{s}} q(\mathbf{s}) E(\mathbf{s}) + \ln Z \sum_{\mathbf{s}} q(\mathbf{s}).$$

Como q es una distribución de probabilidad,

$$\sum_{\mathbf{s}} q(\mathbf{s}) = 1,$$

tenemos que:

$$D_{\text{KL}}(q \| p_B) = \sum_{\mathbf{s}} q(\mathbf{s}) \ln q(\mathbf{s}) + \beta \sum_{\mathbf{s}} q(\mathbf{s}) E(\mathbf{s}) + \ln Z.$$

El segundo término corresponde directamente a la energía promedio evaluada sobre la distribución q :

$$\langle E \rangle_q = \sum_{\mathbf{s}} q(\mathbf{s}) E(\mathbf{s}).$$

Por otra parte, la entropía de Gibbs-Shannon asociada con q es

$$S[q] = -k_B \sum_{\mathbf{s}} q(\mathbf{s}) \ln q(\mathbf{s}).$$

Por tanto,

$$\sum_{\mathbf{s}} q(\mathbf{s}) \ln q(\mathbf{s}) = -\frac{S[q]}{k_B}.$$

La divergencia KL puede escribirse entonces como

$$D_{\text{KL}}(q \| p_B) = -\frac{S[q]}{k_B} + \beta \langle E \rangle_q + \ln Z.$$

y el término entrópico puede escribirse como

$$-\frac{S[q]}{k_B} = -\beta T S[q].$$

Así,

$$D_{\text{KL}}(q \| p_B) = \beta [\langle E \rangle_q - T S[q]] + \ln Z.$$

La divergencia viene dada por:

$$D_{\text{KL}}(q \| p_B) = \beta F[q] - \beta F_B,$$

donde, $F_B = -\frac{1}{\beta} \ln Z$. y $F[q] = \langle E \rangle_q - T S[q]$. Como la divergencia de Kullback–Leibler satisface $D_{\text{KL}}(q \| p_B) \geq 0$, se obtiene $F[q] \geq F_B$. La igualdad se alcanza cuando $q(\mathbf{s}) = p_B(\mathbf{s})$. Por tanto, $F_B = \min_q F[q]$, y la distribución que alcanza este mínimo es precisamente la de Boltzmann. En un modelo parametrizado $q_\theta(\mathbf{s})$, este resultado conduce al problema de optimización

$$\theta^* = \arg \min_{\theta} F[q_\theta] = \arg \min_{\theta} D_{\text{KL}}(q_\theta \| p_B),$$

donde

$$F[q_\theta] = \langle E \rangle_{q_\theta} - TS[q_\theta] \\ = \sum_{\mathbf{s}} q_\theta(\mathbf{s}) E(\mathbf{s}) + k_B T \sum_{\mathbf{s}} q_\theta(\mathbf{s}) \ln q_\theta(\mathbf{s}).$$

El modelo q_θ genera configuraciones del sistema, y sus parámetros se ajustan buscando un equilibrio entre reducir la energía media y aumentar la entropía, según la temperatura considerada.

Para minimizar la energía libre respecto a los parámetros del modelo, calculamos su gradiente:

$$\nabla_\theta F[q_\theta] = \sum_{\mathbf{s}} \nabla_\theta q_\theta(\mathbf{s}) [E(\mathbf{s}) + k_B T (\ln q_\theta(\mathbf{s}) + 1)].$$

Aquí suponemos que la energía $E(\mathbf{s})$ y la temperatura T son independientes de θ . Como la distribución está normalizada,

$$\sum_{\mathbf{s}} \nabla_\theta q_\theta(\mathbf{s}) = \nabla_\theta \sum_{\mathbf{s}} q_\theta(\mathbf{s}) = 0,$$

el término constante desaparece. Utilizando la identidad

$$\nabla_\theta q_\theta(\mathbf{s}) = q_\theta(\mathbf{s}) \nabla_\theta \ln q_\theta(\mathbf{s}),$$

obtenemos [1, 2]

$$\nabla_\theta F[q_\theta] = \sum_{\mathbf{s}} q_\theta(\mathbf{s}) [E(\mathbf{s}) + k_B T \ln q_\theta(\mathbf{s})] \nabla_\theta \ln q_\theta(\mathbf{s}) \\ = \langle [E(\mathbf{s}) + k_B T \ln q_\theta(\mathbf{s})] \nabla_\theta \ln q_\theta(\mathbf{s}) \rangle_{q_\theta}.$$

Un mínimo interior satisface la condición de estacionariedad $\nabla_\theta F[q_{\theta^*}] = 0$. En la práctica, buscamos el mínimo mediante actualizaciones de descenso por gradiente:

$$\theta_{t+1} = \theta_t - \eta \nabla_\theta F[q_{\theta_t}],$$

donde $\eta > 0$ es la tasa de aprendizaje.

B. El Transformer como distribución variacional

Utilizaremos un Transformer autoregresivo para representar la distribución $q_\theta(\mathbf{s})$ de un sistema de N espines, $s_i \in \{-1, +1\}$. Fijamos un orden de recorrido de los sitios y escribimos

$$q_\theta(\mathbf{s}) = \prod_{i=1}^N q_\theta(s_i | s_{<i}), \quad s_{<i} = (s_1, \dots, s_{i-1}).$$

El Transformer calcula cada una de estas probabilidades condicionales. Sus parámetros θ incluyen los embeddings, los bloques de atención y la capa de salida.

1. Cálculo de las probabilidades

Representamos los valores -1 y $+1$ mediante dos tokens e incorporamos un token de inicio, BOS. Para evaluar una configuración, utilizamos la secuencia de entrada desplazada

$$(\text{BOS}, s_1, \dots, s_{N-1}),$$

cuyas salidas predicen, respectivamente,

$$(s_1, s_2, \dots, s_N).$$

Los embeddings de los tokens se combinan con información de posición. La máscara causal permite que la salida en la posición i dependa únicamente del token de inicio y de los espines $s_{<i}$.

Si $\mathbf{h}_i \in \mathbb{R}^d$ es la representación interna en esa posición, la capa de salida calcula dos logits:

$$\mathbf{z}_i = W_{\text{out}} \mathbf{h}_i + \mathbf{b}, \quad W_{\text{out}} \in \mathbb{R}^{2 \times d}.$$

La función softmax los transforma en probabilidades:

$$q_\theta(s_i = a | s_{<i}) = \frac{\exp(z_i^{(a)})}{\exp(z_i^{(-1)}) + \exp(z_i^{(+1)})}, \quad a \in \{-1, +1\}.$$

Por ejemplo, si en una posición el modelo produce

$$q_\theta(s_i = -1 | s_{<i}) = 0,3, \quad q_\theta(s_i = +1 | s_{<i}) = 0,7,$$

el siguiente espín se muestrea con esas probabilidades. Repitiendo este procedimiento obtenemos una configuración $\mathbf{s} \sim q_\theta$.

Para calcular su logaritmo de probabilidad, seleccionamos en cada posición la probabilidad del espín observado y sumamos:

$$\ln q_\theta(\mathbf{s}) = \sum_{i=1}^N \ln q_\theta(s_i | s_{<i}).$$

La generación es secuencial; una vez disponible la configuración, todas sus probabilidades condicionales pueden evaluarse en una sola pasada con máscara causal.

2. Estimación de la energía libre

En cada iteración generamos un lote de M configuraciones independientes con los parámetros actuales:

$$\mathbf{s}^{(1)}, \dots, \mathbf{s}^{(M)} \sim q_\theta.$$

Para cada configuración calculamos dos cantidades:

$$E_m = E(\mathbf{s}^{(m)}), \quad \ell_m = \ln q_\theta(\mathbf{s}^{(m)}).$$

La energía se obtiene del Hamiltoniano de Ising. Consideraremos una red cuadrada de $L \times L$ espines con condiciones periódicas, interacción ferromagnética $J = 1$ y campo externo $h = 0$:

$$E_m = - \sum_{\langle i,j \rangle} s_i^{(m)} s_j^{(m)},$$

donde cada par de primeros vecinos se cuenta una sola vez. Trabajaremos en unidades con $k_B = 1$, de modo que

$$f_m = E_m + T\ell_m.$$

El logaritmo de probabilidad ℓ_m se obtiene de las salidas del Transformer. El promedio del lote proporciona un estimador de la energía libre:

$$\hat{F}_\theta = \frac{1}{M} \sum_{m=1}^M f_m.$$

3. Actualización de los parámetros

El gradiente derivado anteriormente se estima mediante

$$\hat{\mathbf{g}}_\theta = \frac{1}{M} \sum_{m=1}^M f_m \nabla_\theta \ell_m.$$

Esta expresión incorpora la dependencia de la distribución de muestreo respecto a los parámetros del modelo [1].

Para implementarla mediante diferenciación automática, construimos la función auxiliar

$$\mathcal{L}_{\text{aux}}(\theta) = \frac{1}{M} \sum_{m=1}^M \text{stopgrad}(f_m) \ell_m.$$

La operación stopgrad conserva el valor numérico de su argumento y lo trata como constante al derivar. Por tanto,

$$\nabla_\theta \mathcal{L}_{\text{aux}} = \hat{\mathbf{g}}_\theta.$$

Durante este cálculo, las configuraciones muestreadas se mantienen fijas y la retropropagación actúa sobre sus logaritmos de probabilidad.

Así, $\hat{F}_\theta$ permite evaluar la energía libre y $\mathcal{L}_{\text{aux}}$ proporciona el gradiente requerido para entrenar el modelo. Actualizamos los parámetros mediante

$$\theta_{t+1} = \theta_t - \eta \hat{\mathbf{g}}_{\theta_t},$$

o mediante un optimizador como Adam.

El ciclo de entrenamiento consiste en generar configuraciones, evaluar sus energías y logaritmos de probabilidad, calcular el gradiente y actualizar el Transformer. En la siguiente iteración, el nuevo lote se genera con los parámetros actualizados.

C. Algoritmo de entrenamiento para el modelo de Ising

Su tarea será implementar el siguiente algoritmo para aproximar la distribución de equilibrio del modelo de

Ising mediante un Transformer autoregresivo. Consideraremos una red cuadrada de $L \times L$ sitios, con $N = L^2$ espines $s_i \in \{-1, +1\}$ y condiciones de frontera periódicas. La energía de una configuración será

$$E(\mathbf{s}) = -J \sum_{\langle i,j \rangle} s_i s_j - h \sum_i s_i,$$

donde cada par de primeros vecinos se cuenta una sola vez. Para la implementación inicial, utilice $J = 1$, $h = 0$ y unidades en las que $k_B = 1$, con una temperatura fija $T > 0$.

1. Definir la distribución autoregresiva

Ordene los sitios de la red por filas y represente cada configuración como una secuencia de N tokens. El Transformer deberá calcular

$$q_\theta(\mathbf{s}) = \prod_{i=1}^N q_\theta(s_i | s_{<i}).$$

Utilice embeddings de los espines, información de posición y una máscara causal. Para predecir los espines $(s_1, \dots, s_N)$, la entrada será la secuencia desplazada

$$(\text{BOS}, s_1, \dots, s_{N-1}),$$

donde BOS es el token de inicio.

En cada posición, una capa lineal seguida de softmax deberá producir las probabilidades de los dos valores posibles:

$$q_\theta(s_i = a | s_{<i}) = \text{softmax}_a(W_{\text{out}}\mathbf{h}_i + \mathbf{b}), \quad a \in \{-1, +1\}.$$

2. Inicializar el entrenamiento

Inicialice los parámetros θ del Transformer y el optimizador. Defina el tamaño del lote M , la tasa de aprendizaje η y el número de iteraciones K .

3. Generar un lote de configuraciones

En cada iteración, genere M configuraciones independientes utilizando los parámetros actuales:

$$\mathbf{s}^{(1)}, \dots, \mathbf{s}^{(M)} \sim q_\theta.$$

Para cada configuración, comience con el token BOS y muestree secuencialmente

$$s_i^{(m)} \sim q_\theta(s_i | s_{<i}^{(m)}), \quad i = 1, \dots, N.$$

En cada paso, añada el espín generado a la secuencia de entrada. Realice este muestreo sin construir un grafo de diferenciación.

4. Evaluar la energía y la probabilidad

Reconstruya cada configuración como una matriz de $L \times L$ espines y calcule

$$E_m = -J \sum_{x,y} s_{x,y}^{(m)} \left(s_{x+1,y}^{(m)} + s_{x,y+1}^{(m)} \right) - h \sum_{x,y} s_{x,y}^{(m)},$$

donde los índices se interpretan módulo L .

Evalúe nuevamente las configuraciones con el Transformer, esta vez habilitando la diferenciación automática. Calcule

$$\ell_m = \ln q_\theta(\mathbf{s}^{(m)}) = \sum_{i=1}^N \ln q_\theta \left(s_i^{(m)} \mid s_{<i}^{(m)} \right).$$

Para mayor estabilidad numérica, utilice log-softmax sobre los logits y seleccione en cada posición el valor correspondiente al espín muestreado.

El muestreo y esta evaluación deben utilizar los mismos parámetros y la misma distribución. Para esta implementación, utilice el Transformer sin dropout.

5. Estimar la energía libre

Calcule para cada muestra

$$f_m = E_m + T \ell_m.$$

La energía libre variacional se estima mediante

$$\hat{F}_\theta = \frac{1}{M} \sum_{m=1}^M f_m.$$

Registre también la energía media y la entropía estimada:

$$\hat{U}_\theta = \frac{1}{M} \sum_{m=1}^M E_m, \quad \hat{S}_\theta = -\frac{1}{M} \sum_{m=1}^M \ell_m.$$

Estas cantidades satisfacen

$$\hat{F}_\theta = \hat{U}_\theta - T \hat{S}_\theta.$$

6. Construir el estimador del gradiente

Utilice el gradiente de la energía libre:

$$\nabla_\theta F_\theta = \langle [E(\mathbf{s}) + T \ln q_\theta(\mathbf{s})] \nabla_\theta \ln q_\theta(\mathbf{s}) \rangle_{q_\theta}.$$

Su estimador mediante el lote es

$$\hat{\mathbf{g}}_\theta = \frac{1}{M} \sum_{m=1}^M f_m \nabla_\theta \ell_m.$$

Para calcularlo mediante retropropagación, construya la función auxiliar

$$\mathcal{L}_{\text{aux}} = \frac{1}{M} \sum_{m=1}^M \text{stopgrad}(f_m) \ell_m.$$

La operación stopgrad trata f_m como una constante durante la derivación, de modo que

$$\nabla_\theta \mathcal{L}_{\text{aux}} = \hat{\mathbf{g}}_\theta.$$

La energía libre estimada se utiliza para evaluar el entrenamiento; la función auxiliar se utiliza para obtener el gradiente.

7. Actualizar los parámetros

Reinicie los gradientes acumulados, aplique retropropagación a $\mathcal{L}_{\text{aux}}$ y actualice los parámetros con Adam o descenso por gradiente. En este último caso,

$$\theta_{t+1} = \theta_t - \eta \hat{\mathbf{g}}_{\theta_t}.$$

Repita los pasos 3 a 7 durante K iteraciones. Cada iteración deberá utilizar un nuevo lote generado por la distribución actual.

8. Evaluar el modelo entrenado

Genere un lote independiente de evaluación y estime la energía libre por espín, la energía media por espín y la magnetización absoluta:

$$\frac{\hat{F}_\theta}{N}, \quad \frac{\hat{U}_\theta}{N}, \quad \left\langle \left| \frac{1}{N} \sum_i s_i \right| \right\rangle_{q_\theta}.$$

Valide primero la implementación en una red pequeña, por ejemplo $L = 3$ o $L = 4$, para la cual pueda enumerar todas las configuraciones. Calcule

$$Z = \sum_{\mathbf{s}} e^{-E(\mathbf{s})/T}, \quad F_B = -T \ln Z,$$

y compare los resultados del modelo con los valores exactos. Verifique además la normalización de q_θ y la relación

$$D_{\text{KL}}(q_\theta \| p_B) = \frac{F_\theta - F_B}{T}.$$

La cota $F_\theta \geq F_B$ corresponde al valor esperado exacto; las estimaciones con lotes finitos presentan fluctuaciones estadísticas. Como resultado de la implementación, presente las curvas de entrenamiento, las comparaciones con la enumeración exacta y ejemplos de configuraciones generadas por el Transformer. —————

* Electronic address: hernan.salinas@udea.edu.co

¹ Dian Wu, Lei Wang, and Pan Zhang. Solving statistical mechanics using variational autoregressive networks. *Physical Review Letters*, 122(8):080602, 2019. doi: 10.1103/PhysRevLett.122.080602. URL <https://doi.org/10.1103/PhysRevLett.122.080602>.

² Piotr Białas, Piotr Korcyl, Tomasz Stebel, Adam Stefański, and Dawid Zapolski. Sampling two-dimensional spin systems with transformers. *arXiv preprint arXiv:2604.27738*, 2026. doi: 10.48550/arXiv.2604.27738. URL <https://arxiv.org/abs/2604.27738>.